

Hongpeng Jin, Yanzhao Wu 佛罗里
达国际大学, 美国佛罗里达州迈阿密 {hjin
008, yawu}@fiu.edu

Abstract—大型语言模型 (LLM) 表现出卓越的类人预测能力。然而, 部署大语言模型以在边缘提供高效、自适应的推理服务具有挑战性。本文提出了一种新颖的大语言模型云边缘协作框架 (CE-CoLLM) 来应对这些挑战。首先, 我们将云端和边缘之间的 LLM 上下文数据传输确定为关键的性能瓶颈, 这会带来大量的通信开销, 主导整体推理延迟, 并使 LLM 的原生云边缘协作效率低下。其次, 我们在 CE-CoLLM 中引入了一套新技术, 包括延迟感知提前退出机制和高效的云上下文管理, 这些技术共同减少了通信开销并保持了 LLM 推理的准确性。第三, 我们设计了两种自适应推理模式来适应不同的边缘环境: (1) 低延迟独立边缘推理模式, 即使在不稳定的网络条件下也能实现可靠的边缘侧独立 LLM 推理; (2) 高精度云边协同推理模式, 自适应地利用云资源来提高预测精度。对多个基准数据集的大量实验表明, 与传统的基于云的 LLM 部署相比, CE-CoLLM 将整体推理时间缩短了高达 13.81%, 并将超过 84.53% 的计算工作负载从云端卸载到边缘, 且不牺牲预测精度。该代码在 GitHub 上提供: <https://github.com/mlsysx/CE-CoLLM>。

Index Terms—大语言模型、LLM部署、云边协作、云服务、自适应 LLM 推理、边缘人工智能。

一、简介

大语言模型 (LLM) 已经展示了显着的预测能力, 改变了从自然语言处理 (NLP) 到关键决策任务等不同领域[1]-[5]。人们越来越有兴趣将大语言模型强大的预测性能直接扩展到边缘设备, 以获得好处, 例如低推理延迟、增强的隐私保护以及独立于网络连接的可靠推理[6]-[9]。然而, 实现这些目标面临着严峻的挑战。一方面, 由于计算和内存资源有限, 直接在资源受限的边缘设备上部署全面的 LLM 通常是不切实际的[6]、[10]-[12], 通常需要模型压缩或修剪技术, 从而损害模型的准确性[13]-[16]。另一方面, 仅仅依靠传统的基于云的 LLM 部署[17]-[19], 利用云中的大量计算能力, 引入了固有的性能问题, 例如依赖于网络的通信延迟和漏洞




图 1. CE-CoLLM 与 Naive Cloud-Edge Deployment 在 Alpaca 和 XSum 数据集上的每次响应平均传输数据大小和云请求率的比较。条形图表示传输的数据大小 (对数刻度, KB), 而实线表示云请求率 (百分比)。结果表明, CE-CoLLM 显著降低了通信开销和对云请求的依赖。

服务或网络中断 [8]、[9]、[20]-[22]。这些限制凸显了探索云边缘协作策略的迫切需要, 该策略有可能利用云计算和边缘计算的优势, 在边缘提供高效、自适应且可靠的基于 LLM 的服务。

最近的几项研究已经做出了早期尝试, 以实现 LLM 部署的云边缘协作 [8]、[9]、[23]。一种流行的方法是混合部署策略, 其中在边缘部署小语言模型 (SLM) 来处理简单的令牌, 而复杂的令牌则卸载到云中强大的 LLM [8]、[23]。虽然很有前景, 但此类方法通常会导致冗余计算或资源利用率不佳。一种更集成的替代方案是将单个 LLM 跨云和边缘进行分区以执行协作推理 [9]。然而, 由于每个令牌在云端和边缘之间迭代传输大量上下文数据 (例如隐藏状态), 这种分割模型部署引入了大量的通信开销, 如图 2(b) 所示。我们的研究表明, 上下文数据的频繁传输在整体推理延迟中占主导地位, 使得简单的云边缘协作 LLM 部署速度缓慢且对于现实应用程序来说不切实际。

为了应对这些关键挑战, 本文介绍了 CE-CoLLM, 这是一种针对大语言模型的新型云边缘协作框架。图 1 显示了 CE-CoLLM 和原生云边缘部署在每个响应和云的平均传输数据大小方面的实验比较




图2. 图(a)展示了Cloud LLM部署的架构。边缘设备通过API请求访问LLM推理服务。图(b)是Naïve Cloud-Edge Deployment的架构。在此设置中，每个令牌推理的隐藏状态都会从边缘设备传输到云端。云端计算仅在接收到这些隐藏状态后才开始。

Alpaca [24] 和 XSum [25] 数据集上的请求率。与简单的云边缘部署相比，CE-CoLLM 显着降低了通信开销和云请求率。我们做出了三项原创贡献。First,我们进行了实证分析，以显示在简单的云边缘部署中传输上下文数据所造成的大量通信开销。Second,我们提出了CE-CoLLM框架，它集成了一套新颖的组件，包括延迟感知提前退出机制和云上下文管理，以有效缓解通信瓶颈。CE-CoLLM提供两种灵活的推理模式来适应不同的边缘环境：（1）低延迟独立边缘推理和（2）高精度协作云边缘推理。Third,通过对流行基准数据集的全面实验，我们证明CE-CoLLM通过大幅减少通信开销，显着优于简单的云边缘协作，从而降低端到端推理延迟，同时保持可比较的预测精度。

二.大语言模型部署策略

在本节中，我们介绍部署大语言模型（LLM）的三种主要策略：云部署、边缘部署和云边协作部署。

云 LLM 部署是一种流行的策略，它通过利用充足的云计算资源来实现全面的大语言模型（LLM）推理。流行的基于 LLM 的服务，例如 ChatGPT [17]、[18] 和 Claude [19]，托管在云中，为边缘端用户提供对这些强大的 LLM 的远程访问，如图 2(a) 所示。然而，云LLM部署高度依赖于网络连接和服务可用性。由于提示、响应和中间数据的传输，这种依赖性会产生显着的往返通信延迟，这使得基于云的LLM服务容易受到网络不稳定或云端负载激增造成的中断[16], [26]，特别是阻碍边缘的实时应用程序。

边缘LLM部署直接在边缘设备（例如移动或物联网设备）上执行LLM，使推理更接近最终用户。代表性框架包括 ChatRTX [27] 和 Ollama [28]，它们减少网络依赖性并通过本地推理实现低延迟服务

边缘。然而，由于边缘设备的计算、内存和存储资源有限，在边缘设备上部署全面的 LLM 具有挑战性。为了适应这些约束，通常使用量化或修剪等技术来压缩模型[29]-[31]。虽然这些方法有效地减小了模型大小，但它们可能会无意中损害预测准确性或降低模型处理复杂任务的能力[13]、[15]、[16]，从而限制了它们在需要高质量 LLM 推理的应用程序中的实用性。

云边缘协作LLM部署利用云的广泛计算能力，同时利用边缘设备的低延迟优势。跨云和边缘环境的 LLM 部署通常分为两大类。（1）*Separate Model Deployment*: 全面的 LLM 部署在云端，而小语言模型（SLM）运行在边缘。复杂的任务被路由到云端以保持预测的准确性。然而，如果边缘和云端处理相同的输入，则此策略可能会引入冗余推理开销，从而导致资源利用率不佳。此外，维持边缘和云之间一致的上下文和状态可能具有挑战性[8]、[23]。（2）*Split Model Deployment*: LLM 分为边缘和云分区，初始层（边缘分区）部署在边缘设备上，其余层（云分区）托管在云端。这种分割模型部署策略旨在保持全面大语言模型的准确性。然而，由于 LLM [32] 的自回归性质，其中每个令牌都是基于先前的令牌生成的，因此会导致每个生成的令牌在边缘和云之间频繁传输大量中间数据。如图 1 所示，大量传输数据会带来较高的通信延迟，通常主导整体推理延迟。

为了克服与拆分模型部署相关的通信挑战，我们提出了 CE-CoLLM，这是一种针对大语言模型的新型云边缘协作框架。CE-CoLLM 支持云端和边缘之间的自适应推理任务分配，有效地将计算工作负载从云端卸载到边缘，以提高资源利用率并减少通信开销。此外，它还为边缘侧用户提供边缘独立模式，即使云网络连接中断，也能确保边缘的弹性和高效推理。

三. CE-COLM 概述

在本节中，我们概述了我们提出的 CE-CoLLM 框架，该框架旨在为大语言模型实现高效且自适应的云边缘协作。CE-CoLLM 包含三个关键功能组件：（1）延迟感知提前退出机制，（2）异步上下文数据上传，以及（3）高效上下文管理。如图 4（左）所示，CE-CoLLM 支持独立边缘推理和自适应云边协同推理模式。我们观察到，并非所有代币生成都需要完整的 LLM 推理。图 3 显示了令牌生成置信度得分的分布，呈现出长尾模式，其中大多数

生成的代币集中在高置信度端附近。具体来说，Alpaca 数据集 [24] 上的 47.89% 和 XSum 数据集 [25] 上的 68.26% 的标记在中间早期退出层的置信度得分高于 0.8。这表明在到达 LLM 的最后一层之前，可以以高置信度生成很大一部分令牌，从而为消除后续层中不必要的计算提供了机会。这一观察结果激发了 CE-CoLLM 的核心设计，它具有延迟感知的提前退出机制，可终止中间层对高置信度令牌的推理。此外，提前退出机制提供了一种将 LLM 拆分为多个分区的自然方式。前几层以及一个或多个早期退出点仅构成 LLM 的一小部分，可以部署在资源受限的边缘设备上，而其余层则部署在云中。这种设计允许边缘设备以高置信度高效处理大多数令牌，同时将更具挑战性的案例（即低置信度令牌）卸载到云端以继续推理，从而确保自适应且高效的 LLM 部署。下面我们将描述 CE-CoLLM 在促进大语言模型高效、自适应云边缘协作方面的关键组件。

A. Latency-aware 提前退出 Mechanism

我们将延迟感知提前退出机制纳入 CE-CoLLM，以优化大语言模型的云边缘协作。如图4（左）所示，该机制在 LLM 的中间层集成了多个早期退出点。最初的几层配备了早期退出点，构成了适合部署在资源受限的边缘设备上的轻量级边缘分区，而其余层则形成了云分区，以便在云中执行。在推理过程中，每个标记首先通过边缘分区进行处理，并在每个出口点进行评估。如果令牌的置信度分数 ($conf$) 超过预定义阈值 (θ)，则直接在早期退出点本地生成，无需云支持。置信度得分计算如下：

$$conf = \max_i \frac{\exp(z_i)}{\sum_{j=1}^V \exp(z_j)},$$

其中 $\{z_1, z_2, \dots, z_V\}$ 表示大小为 V 的词汇表的输出 logits， $i, j \in \{1, 2, \dots, V\}$ 。如果最终边缘侧提前退出点的置信度分数仍然低于阈值 θ ，则令牌将被卸载到云，其中使用云分区完成剩余的推理。

此设计在 CE-CoLLM 中实现了两种自适应操作模式：(1) *Edge Standalone 推理 Mode (Low-Latency Mode)* 专为网络连接有限或不可靠的场景而设计。在这种模式下，边缘侧 LLM 推理独立运行，通过边缘侧早期退出点在本地生成令牌，而不依赖于云。这确保了基于 LLM 的服务不间断和低延迟响应（参见表 I 中的 CE-CoLLM（独立）性能）。(2) 在网络稳定的情况下，

Adaptive 云边协同推理

Mode (High-Accuracy Mode) 作为默认模式，预测精度较高。在




图 3. Alpaca 数据集早期退出层的 词元 置信度得分分布，显示出偏向高置信度得分的长尾模式，其中 50% 的 词元 置信度得分超过 0.77，25% 的 词元 超过 0.98。

在此模式下，如果令牌的置信度分数在边缘保持低于预定义阈值 θ ，CE-CoLLM 会将令牌及其必要的上下文信息发送到云以完成剩余的推理。这种设计使边缘侧 LLM 推理能够有效地处理大多数令牌生成，同时利用云对一些具有挑战性的令牌的支持来保持预测准确性，如图 4（右）所示。可以调整阈值 θ 以控制边缘和云之间的工作负载分配。默认情况下，我们建议设置 $\theta = 0.8$ 以实现推理延迟和预测精度之间的平衡。

B. Asynchronous Contextual Data Upload

图 1 说明，在调用低置信度令牌的云支持时传输大量上下文数据（例如，隐藏状态）会产生大量通信开销。为了解决这个问题，CE-CoLLM 引入了异步机制来上传上下文数据。由于大多数令牌可以在边缘放心地生成，CE-CoLLM 利用这个机会通过与正在进行的边缘端推理并行上传上下文数据来将数据传输与同步推理过程解耦。具体来说，一旦边缘侧 LLM 推理到达预定义的模型层并触发上传操作（自动或满足某些条件，例如置信度阈值），它就会主动将当前上下文数据传输到云端上下文管理器。这种设计确保，如果最终需要云支持，必要的上下文信息已经可用或即将传输，从而允许云端推理以最小的数据传输延迟开始。通过将边缘计算与数据传输重叠，CE-CoLLM 有效地屏蔽了很大一部分通信开销，从而显着减少了整体推理延迟。此外，为了进一步优化通信效率，我们将传输的数据从 float32 转换为 float16，从而在不影响模型精度的情况下将数据大小减半，如第 IV-B 节中所验证的。




图 4. CE-CoLLM 架构概述和工作流程：（左）跨边缘和云部署 CE-CoLLM，在边缘有两个早期退出点；（右）端到端云边缘推理工作流程，其中置信度得分 ≥ 0.8 的令牌是通过早期退出点在本地生成的，而低于阈值的令牌则被卸载到云端以继续推理。

C. Cloud Support for LLM 推理

云端 LLM 分区会损害未部署在边缘的剩余 LLM 层，其目的是继续对边缘侧卸载的低置信度令牌进行推理。云端 LLM 推理融合了三个关键机制来支持高效、可扩展的云边协作。（1）*Context Manager* 作为核心组件，管理每个边缘客户端的上下文数据。它存储从边缘客户端异步上传的上下文数据（例如隐藏状态），以确保在请求云端 LLM 推理时所有必要的上下文可用。上下文管理器还维护在云端推理期间生成的键值（KV）缓存，在整个令牌生成序列中保留它们，以避免对先前处理的令牌进行冗余计算。未使用的上下文数据和键值（KV）缓存会在会话完成时或指定的不活动时间后自动清除，从而确保资源的高效利用。（2）云服务器使用 *Single-词元 Response* 为每个云推理请求仅返回一个令牌，而不是整个预测概率向量。这种设计有效地减少了通信开销，同时仍然支持后续在边缘生成令牌。（3）*Dual APIs* 由云服务器提供，支持上下文数据上传和推理处理的单独执行路径，允许两个操作并行进行。这些机制使云服务器能够有效地支持边缘客户端对低置信度令牌进行持续的 LLM 推理，同时降低通信和计算成本。该设计支持自适应、高效且可扩展的云边缘协作，以便向多个边缘客户端提供基于 LLM 的服务。

每个早期退出点的置信度得分。一旦置信度分数达到或超过阈值 ($conf \geq \theta$)，就会在本地生成令牌，而无需调用云支持。与此同时，CE-CoLLM 与正在进行的边缘推理并行地将上下文数据异步更新到云端。这种主动传输使云服务器为潜在的云支持请求做好准备。如果令牌的置信度分数在最终边缘侧出口点仍然低于阈值 θ ，则边缘客户端请求云支持。云端上下文管理器检索上传的上下文数据和存储的 KV 缓存，以允许云端 LLM 分区恢复并完成剩余的 LLM 推理。然后，生成的令牌返回到边缘客户端，边缘客户端将其附加到令牌序列并继续生成下一个令牌。重复此过程直至生成完成。

总之，CE-CoLLM 通过三种协调机制有效解决了云边缘协作 LLM 部署中的通信瓶颈：（1）延迟感知提前退出机制，（2）异步上下文数据上传，以及（3）高效上下文管理。这种设计使 CE-CoLLM 能够在边缘处理大多数令牌预测，从而显著地将计算负载从云端卸载到边缘，从而确保高效的资源利用，同时保持可比的预测精度。

四. 实验分析

我们主要从两个角度进行实验分析来评估 CE-CoLLM：

（1）评估与现有部署策略相比运行时性能的改进，包括更快的推理和减少的通信开销；（2）验证 CE-CoLLM 的预测准确性与广泛使用的基于云的 LLM 部署相当。本节重点分析四种关键 LLM 部署策略的绩效。（1）

Cloud LLM Deployment：第二节中介绍的传统策略，如图 2(a) 所示，作为我们的准确性基线。（2）

Naïve Cloud-Edge Deployment：基线

D. 云边协同

Workflow

CE-CoLLM 的端到端推理工作流程如图 4 所示（右，默认 $\theta=0.8$ ）。对于每个输入提示，推理在边缘设备上开始，其中边缘侧 LLM 分区处理输入并评估

表 I 不同 LLM 部署策略的绩效比较

Dataset	Deployment Strategy	Total Cost (s)	Cloud Cost (s)	Edge Cost (s)	Comm Cost (s)
Alpaca	Cloud LLM Deployment	370.166 $\pm$ 1.692	369.799 $\pm$ 1.682	0	0.367 $\pm$ 0.013
	Naïve Cloud-Edge Deployment	3371.761 $\pm$ 34.023	253.358 $\pm$ 1.695	241.428 $\pm$ 8.832	2876.975 $\pm$ 24.815
	CE-CoLLM (standalone)	201.574 $\pm$ 0.278	0	201.574 $\pm$ 0.278	0
	CE-CoLLM (collaborative)	<u>319.057</u> $\pm$ 0.438	112.723 $\pm$ 0.211	192.204 $\pm$ 0.437	14.130 $\pm$ 0.181
XSum	Cloud LLM Deployment	392.466 $\pm$ 7.075	392.012 $\pm$ 7.128	0	0.454 $\pm$ 0.106
	Naïve Cloud-Edge Deployment	19108.662 $\pm$ 211.580	271.661 $\pm$ 5.321	411.340 $\pm$ 2.520	18425.868 $\pm$ 207.460
	CE-CoLLM (standalone)	221.388 $\pm$ 0.865	0	221.388 $\pm$ 0.865	0
	CE-CoLLM (collaborative)	<u>375.999</u> $\pm$ 0.720	60.652 $\pm$ 0.133	258.383 $\pm$ 0.595	56.963 $\pm$ 0.137

将 LLM 拆分为单独的云和边缘部署的策略，如图 2(b) 所示。(3) *CE-CoLLM (standalone)*: 我们提出的 CE-CoLLM 框架的独立模式，在边缘独立运行。(4)

CE-CoLLM (collaborative): 我们的 CE-CoLLM 框架的自适应云边协作推理模式，使用 $\theta = 0.8$ 的最佳置信阈值。

实验设置：我们使用配备两个早期退出点[34]的 7B LLaMA 模型[33]评估 CE-CoLLM，该模型经过训练，一旦置信度超过预定义阈值 (θ)，就通过在早期退出处终止推理过程来实现自适应 LLM 推理。云和边缘分区分别部署在云服务器和边缘设备上。云服务器配备了单个 NVIDIA A100 GPU，在所有部署策略中都是一致的，以确保公平比较。我们主要使用两个代表性数据集 Alpaca [24] 和 XSum [25] 来评估 LLM 推理性能。为了验证不同下游任务的推理准确性，我们使用 BoolQ [35] 和 QuAC [36] 进行问答，使用 IMDB [37] 进行情感分析，使用 XSum 进行摘要。

评估指标：我们使用两类指标评估这些 LLM 部署策略：(1) *runtime performance metrics*，包括总推理时间成本、边缘计算时间成本、云计算时间成本和通信时间成本，以及 (2) *accuracy metrics*，包括 BoolQ 和 IMDB 的精确匹配 (EM) [38]、QuAC 的 F1 分数和 XSum 的 ROUGE-L [39]。

A. Runtime Performance Analysis

我们首先在配备 NVIDIA A100 GPU 的单边缘设备上评估运行时性能，使用来自 Alpaca（相对较短的提示，范围从 13 到 43 个令牌）和 XSum（相对较长的提示，范围从 200 到 500 个令牌）随机选择的 100 个样本。LLM 为每个提示生成最多 100 个令牌。主要实验重复五次，结果以平均值和标准差 (mean $\pm$ std) 形式报告。表 I 列出了 100 个提示的累积时间成本，分为云计算、边缘计算和通信时间成本。我们强调三个有趣的观察结果。

First，简单的云边缘部署面临着过高的通信成本，使其不切实际

对于现实世界的应用程序。在 Alpaca 数据集上处理单个案例平均需要 33.72 秒，在 XSum 数据集上处理单个案例平均需要 191.09 秒，这主要是由于将所有请求发送到云端的通信开销过大。相比之下，如图 1 所示，CE-CoLLM 在 Alpaca 上将云请求显着减少到 49.58%，在 XSum 上减少了 27.73%，同时显着减少了每个请求传输的平均数据，在 Alpaca 上从 112,128 KB 减少到 956.62 KB（减少了 99.15%），在 Alpaca 上从 673,520.03 KB 减少到 3763.61 KB XSum（减少 99.44%）。*Second*，CE-CoLLM 显着优于传统的云 LLM 部署，并提供更高的效率和推理速度。如表一所示，CE-CoLLM 在 Alpaca 上实现了 319 秒的推理，在 XSum 上实现了 376 秒的推理，而云 LLM 部署的推理速度为 370 秒和 392 秒，分别相当于 13.81% 和 4.19% 的性能提升。此外，CE-CoLLM 有效地将计算从云端卸载到边缘，将 Alpaca 上的云执行时间成本降低到 113 秒，XSum 上的云执行时间成本降低到 61 秒，与云 LLM 部署相比，分别减少了 69.52% 和 84.53%。工作负载向边缘的这种实质性转移使云能够显着提高计算效率，并有可能支持使用相同资源的更多并发边缘客户端。*Third*，CE-CoLLM 提供灵活的部署模式，以适应不同的边缘环境和网络条件。单机模式推理速度最快，Alpaca 为 201.57 秒，XSum 为 221.39 秒，同时完全消除了对云的依赖，适合网络连接不稳定的恶劣场景。同时，自适应云边协同推理模式在 Alpaca 上大幅降低云计算负载 69.52%，在 XSum 上降低 84.53%，同时利用云保持推理精度（见表二）。

B. Impact on LLM 推理 Accuracy

然后，我们在三个代表性下游任务中评估 CE-CoLLM 与传统的基于云的 LLM 部署相比对预测准确性的影响：(1) 用于问答的 BoolQ 和 QuAC，(2) 用于情感分析的 IMDB，以及 (3) 用于摘要的 XSum。表二给出了实验结果。总体而言，我们观察到

表 II CE-COLLM（独立模式和协作模式）与云 LLM 部署之间的精度比较

Task Type	Dataset	CE-CoLLM		Cloud LLM Deployment
		Standalone	Collaborative	
Question	BoolQ (EM)	0.4900	0.6580	0.6460
Analysis	QuAC (F1)	0.2740	0.2890	0.2910
Sentiment Analysis	IMDB (EM)	0.6840	0.7240	0.7240
Summarization	XSum (Rouge-L)	0.1917	0.2250	0.2275

云边协同推理模式下的CE-CoLLM（协作）实现了与基于云的LLM部署相当的预测精度。具体来说，对于问答任务，CE-CoLLM在BoolQ上的准确度为0.658，在QuAC上的准确度为0.289，与云LLM部署分别达到的0.646和0.291的准确度非常接近。对于IMDB上的情感分析，CE-CoLLM的准确性与基于云的LLM部署相同。在XSum上的摘要任务中，CE-CoLLM达到了0.225的准确率，与云LLM部署的0.2275的准确率相当。这些实验结果进一步验证了CE-CoLLM保持了与基于云的LLM部署相同的推理精度。在独立边缘推理模式下，精度仅略有下降，同时在边缘提供可靠、低延迟的推理，无需依赖云支持。

总体而言，与现有的LLM部署策略相比，CE-CoLLM在多个维度上实现了显著的性能改进。与简单的云边缘部署相比，CE-CoLLM通过大幅降低云请求速率和传输数据量来有效缓解通信瓶颈，使云边缘协作对于实际应用程序而言更加高效。*Second*, CE-CoLLM在推理速度方面显著优于传统的基于云的LLM部署，同时有效地将计算从云端卸载到边缘并保持推理准确性，证明了所提出的CE-CoLLM框架的有效性。*Third*, CE-CoLLM提供独立的边缘推理模式，即使在不稳定的网络条件下也能确保服务不间断，从而与依赖云的LLM部署策略相比增强了整体系统的弹性。这些优势使CE-CoLLM成为一种高度实用的解决方案，可在不同的边缘环境中提供高效且自适应的基于LLM的服务。

五、相关工作

相关研究可概括为三大类：（1）云边协作机器学习，（2）提前退出机制，（3）大语言模型。

云边缘协作机器学习利用云服务器的高计算能力和边缘设备的低延迟优势，跨云和边缘有效地分配机器学习（ML）工作负载。虽然大多数现有工作[40]、[41]侧重于部署传统的深度神经网络（DNN），但云边缘协作LLM部署

由于大语言模型固有的迭代推理循环造成的高通信开销，面临着独特的挑战。最近的一些研究已经做出了探索法学硕士云边缘协作的早期尝试。例如，[8]在边缘部署小语言模型（SLM），同时将具有挑战性的代币卸载到基于云的LLM，并且[9]使用动态编程拆分LLM以优化吞吐量和延迟。然而，这些现有的云边缘LLM部署方法仍然面临着高通信开销和对云的严重依赖，使它们容易受到网络中断的影响。

提前退出机制提供了一种动态调整深度神经网络推理深度的有效方法，通过允许DNN在中间层终止推理来实现更快的自适应输入处理[42]-[45]。一些研究已将早期退出机制纳入计算机视觉模型[45]、[46]和语言模型[34]、[47]-[49]，包括最近的大语言模型[50]-[54]。然而，很少有研究调查利用早期退出机制来实现自适应云边缘协作以部署法学硕士的有效框架。

大语言模型（LLM）在各个领域取得了显著的成功[55]-[57]，以GPT系列[58]-[60]、ChatGPT[17]为代表，以及开源模型，如LLaMA[33]、[61]、[62]和Mistral[63]-[65]。尽管它们的预测能力令人印象深刻，但高计算需求对在边缘提供基于LLM的服务提出了严峻的挑战[10]、[66]-[68]。为了应对这些挑战，我们提出了一个高效且自适应的云边缘协作框架，以增强基于LLM的边缘服务。

六. 结论

本文介绍了CE-CoLLM，这是一种新颖的云边缘协作框架，可通过可选的云支持加速边缘的LLM推理。*First*, 我们识别并量化了原生云边缘LLM部署中的大量通信开销，其中上下文数据传输主导推理延迟。*Second*, 我们建议CE-CoLLM通过LLM部署的高效和自适应云边缘协作来有效解决这一关键的通信瓶颈。*Third*, 对多个基准数据集的综合实验表明，CE-CoLLM显著降低了整体LLM推理延迟、云计算负载和通信开销，同时保持了相当的预测精度。总体而言，CE-CoLLM提供了一种有效且可靠的解决方案，可在边缘提供高效且自适应的基于LLM的服务。

致谢

作者感谢国家人工智能研究资源 (NAIRR) Pilot (NAIRR 240244)、OpenAI 和 Amazon Web Services 对本研究结果的部分贡献。本材料中表达的任何意见、发现、结论或建议均为作者的观点，并不一定反映上述资助机构和公司的观点。

- [1] T. Teubner, C. M. Flath, C. Weinhardt, W. van der Aalst 和 O. Hinz, “欢迎来到 chatgpt 等人的时代, 大语言模型的前景”, *Business & Information Systems Engineering*, 卷. 65, 没有. 2, 第 95–101 页, 2023 年. [在线]. 可用: <https://doi.org/10.1007/s12599-023-00795-x> [2] H. Naveed, A. U. Khan, S. Qiu, M. Saqib, S. Anwar, M. Usman, N. Barnes 和 A. Mian, “大语言模型的综合概述”, *arXiv preprint arXiv:2307.06435*, 2023 年. [3] Y. Chang, X. Wang, J. 王, 吴, 杨, 朱, 陈, , 易, 王, 王, 叶, 张, 张, 余, 杨, 谢, “大语言模型评估综述”, *ACM Trans. Intell. Syst. Technol.*, 卷. 15, 没有. 2024 年 3 月 3 日. [在线]. 可用: <https://doi.org/10.1145/3641289> [4] B. C. Das, M. H. Amini 和 Y. Wu, “大语言模型的安全和隐私挑战: 一项调查”, *ACM Comput. Surv.*, 卷. 57, 没有. 2025 年 2 月 6 日. [在线]. 网址: <https://doi.org/10.1145/3712001> [5] R. Rangaraj, J. Shi, A. Shiri, R. Paudel, Y. Wu 和 G. Narasimhan, “大型时间序列模型在水文学中的效果如何? 大沼泽地水位预测研究”, *arXiv e-prints*, 第 14 页. arXiv:2505.01415, 2025 年 5 月. [6] Y. Wu, L. Liu 和 R. Kompella, “边缘高效视频分析的并行检测”, *2021 IEEE Third International Conference on Cognitive Machine Intelligence (CogMI)*, 2021 年, 第 01-10 页. [7] S. V. Ganesh, Y. Wu, G. Liu, R. Kompella 和 L. Liu, “增强边缘设备上的对象跟踪性能”, *2023 IEEE 5th International Conference on Cognitive Machine Intelligence (CogMI)*, 2023 年, 第 83-92 页. [8] Z. Hao, H. Jiang, S. Jiang, J. Ren 和 T. Cao, “用于边云协作推理的混合 slm 和 llm”, 见 *Proceedings of the Workshop on Edge and Mobile Foundation Models*, ser. EdgeFM '24. 美国纽约州纽约市: 计算机协会, 2024 年, 第 14 页. 36-41. [在线的]. 可用: <https://doi.org/10.1145/3662006.3662067> [9] M. Zhang, X. Shen, J. Cao, Z. Cui 和 S. Jiang, “Edgeshard: 通过协作边缘计算进行高效 llm 推理”, *IEEE Internet of Things Journal*, 卷. 12, 没有. 10, 第 13 119–13 131, 2025. [10] Y. Wu, L. Liu, C. Pu, W. Cao, S. Sahin, W. Wei, 和 Q. Zhang, “深度学习作为服务框架的比较测量研究”, *IEEE Transactions on Services Computing*, 卷. 15, 没有. 1, 第 551–5 66 页, 2022 年. [11] M. Xu, D. Cai, W. Yin, S. Wang, X. Jin 和 X. Li u, “基础模型的资源高效算法和系统: 一项调查”, *ACM Comput. Surv.*, 卷. 57, 没有. 2025 年 1 月 5 日. [12] G. Qu, Q. Chen, W. Wei, Z. Lin, X. Chen 和 K. Huang, “大语言模型的移动边缘智能: 当代调查”, *IEEE Communications Surveys & Tutorials*, 第 1-1 页, 2025 年. [13] W. Huang, Y. Liu, H. Qin, Y. Li, S. Zhang, X. Liu, M. Magno 和 X. Qi, “Billm: 突破 llms 训练后量化的极限”, *Proceedings of the 41st International Conference on Machine Learning*, ser. ICML'24. JMLR.org, 2024 年. [14] A. Kundu, Y. C. F. Lim, A. Che w, L. Wynter, P. Chong 和 R. Lee, “为边缘应用有效提炼大语言模型”, 载于 *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 6: Industry Track)*, Y. Yang, A. Davani, A. Sil 和 A. Kumar, 编辑. 墨西哥墨西哥城: 计算语言学协会, 2024 年 6 月, 第 52-62 页. [15] S. M a, H. Wang, L. Ma, L. Wang, W. Wang, S. Huang, L. Dong, R. Wang, J. Xu 和 F. Wei, “1 位大语言模型时代: 所有大语言模型均采用 1.58 位”, *arXiv e-prints*, 第 15 页. arXiv:2402.17764, 2024 年 2 月. [16] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. 陈, W.-C. Wang, G. Xiao, X. Dang, C. Gan 和 S. Han, “Awq: 设备上 llm 压缩和加速的激活感知权重量化”, 见 *Proceedings of Machine Learning and Systems*, P. Gibbons, G. Pekhimenko 和 C. D. Sa, 编辑, 卷. 6, 2024 年, 第 87-100 页. [17] L. Ouyang, J. Wu, X. Jiang 等人, “训练语言模型以遵循人类反馈的指令”, 载于 *Advances in Neural Information Processing Systems*, S. Kojima, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho 和 A. Oh, 编辑, 卷. 35. Curran Associates, Inc., 2022 年, 第 27 730–27 744 页. [18] OpenAI, J. Achiam, S. Adler, S. Agarwal 等人, “GPT-4 技术报告”, *arXiv e-prints*, 第 35 页. arXiv: 2303.08774, 2023 年 3 月.
- [19] Anthropic, “克劳德: 人工智能助理模型”, <https://www.anthropic.com/claude>, 2024 年, 访问时间: 2024-10-29. [20] V. Ganatra, A. Parayil, S. Ghosh, Y. Kang, M. Ma, C. Bansal, S. Nath 和 J. Mace, “检测胜于治疗: 云事件视角”, 参见 *Proceedings of the 31st ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering*, ser. ESEC/FSE 2023. 美国纽约州纽约市: 计算机协会, 2023 年, 第 1 页. 1891–1902. [21] Y. Chen, H. Xie, M. Ma, Y. Kang, X. Gau, L. Shi, Y. Cao, X. Gau, H. Fan, M. Wen, J. Zeng, S. Ghosh, X. Zhang, C. Zhang, Q. Lin, S. Rajmohan, D. Zhu 和 T. Xu, “通过大语言模型对云事件进行自动根本原因分析”, 载于 *Proceedings of the Nineteenth European Conference on Computer Systems*, ser. EuroSys '24. 美国纽约州纽约市: 计算机协会, 2024 年, 第 14 页. 674–688. [22] Y. Ding, C. Niu, F. Wu, S. Tang, C. Lyu 和 G. Chen, “通过基于云的历史 llm 交互增强设备上 llm 推理”, 在 *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, ser. KDD' 24. 美国纽约州纽约市: 计算机协会, 2024 年, 第 14 页. 597–608. [23] 苹果, “苹果智能: 为我们其他人服务的人工智能”. <https://www.apple.com/apple-intelligence/>, 2024 年, 访问时间: 2024 年 10 月 29 日. [24] R. Taori, I. Gulrajani, T. Zhang, Y. Dubois, X. Li, C. Guestrin, P. Liang 和 T. B. Hashimoto, “斯坦福羊驼: 遵循指令的美洲驼模型”, https://github.com/tatsu-lab/stanford_alpaca, 2023. [25] S. Narayan, S. B. Cohen 和 M. Lapata, “不要给我细节, 只给我摘要! 用于极端摘要的主题感知卷积神经网络”, 见 *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, E. Riloff, D. Jiang, J. Hockenmaier 和 J. Tsujii, 编辑. 比利时布鲁塞尔: 计算语言学协会, 10 月至 11 月 2018 年, 第 1797–1807 页. [26] X. Miao, G. Oliaro, Z. Zhang, X. Cheng, H. Jin, T. Chen 和 Z. Jia, “迈向高效的生成式大型语言模型服务: 从算法到系统的调查”, *arXiv e-prints*, 第 17 页. arXiv:2312.15234, 2023 年 12 月. [27] NVIDIA, “Chatrtx: 通过 RTX 上的 nvidia ai 为消费者带来生成式人工智能”, <https://www.nvidia.com/en-us/ai-on-rtx/ch>, 访问时间: 2024-10-29. [28] Ollama, “Ollama: 开放大语言模型 api”, <https://ollama.com/>, 2024 年, 访问时间: 2024 年. Sun, Z. Liu, A. Bair 和 J. Z. Kolter, “一种简单有效的大语言模型修剪方法”, 参见 *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. [在线]. 可用: <https://openreview.net/forum?id=PxoFut3dWW> [30] T. Dettmers, R. Svirschevski, V. Egiazarian, D. Kuznedelev, E. Frantar, S. Ashkboos, A. B. Orzunov, T. Hoefler 和 D. Alistarh, “Spqr: 近无损 LLM 权重压缩的稀疏量化表示”, 参见 *The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024*. OpenReview.net, 2024. [在线]. 可用: <https://openreview.net/forum?id=Q1u25ahSuy> [31] E. Frantar 和 D. Alistarh, “Sparsegpt: 可以一次性准确地修剪大规模语言模型”, *Proceedings of the 40th International Conference on Machine Learning*, ser. ICML'23. JMLR.org, 2023. [32] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser 和 I. Polosukhin, “注意力就是你所需要的”, 见 *Advances in Neural Information Processing Systems*, I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan 和 R. Garnett, 编辑, 卷. 30. Curran Associates, Inc., 2017 年. [33] H. Touvron, L. Martin, K. Stone 等人, “Llama 2: 开放基础和微调聊天模型”, *arXiv e-prints*, 第 34 页. arXiv:2307.09288, 2023 年 7 月. [34] Y. Chen, X. Pan, Y. Li, B. Ding 和 J. Zhou, “Ee-llm: 具有 3d 并行性的早期退出大型语言模型的大规模训练和推理”, 在 *Proceedings of the 41st International Conference on Machine Learning*, ser. ICML'24. JMLR.org, 2024 年. [35] C. Clark, K. Lee, M.-W. Chang, T. Kwiatkowski, M. Collins 和 K. Toutanova, “BoolQ: 探索自然语言问题的惊人难度”, 载于 *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, J. Burstein, C. Doran 和 T. Solorio, 编辑. 明尼苏达州明尼阿波利斯: 计算语言学协会, 2019 年 6 月, 第 2924-2936 页.

[36] E. Choi, H. He, M. Iyyer, M. Yatskar, W.-t. Yih, Y. Choi, P. Liang 和 L. Zettlemoyer, “QuAC: 上下文中的问答”, 参见 *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, E. Riloff, D. Jiang, J. Hockenmaier 和 J. Tsujii, 编辑。比利时布鲁塞尔: 计算语言学协会, 10 月至 11 月 2018 年, 第 2174–2184 页。[在线的]。可用: <https://aclanthology.org/D18-1241/> [37] A. L. Maas, R. E. Daly, P. T. Pham, D. Huang, A. Y. Ng 和 C. Potts, “学习用于情感分析的词向量”, 载于 *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, D. Lin, Y. Matsumoto 和 R. Mihalcea, 编辑。美国俄勒冈州波特兰: 计算语言学协会, 2011 年 6 月, 第 142–150 页。[在线的]。可用: <https://aclanthology.org/P11-1015/> [38] P. Rajpurkar, J. Zhang, K. Lopyrev 和 P. Liang, “SQuAD: 机器理解文本的 100,000+ 个问题”, 见 *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, J. Su, K. Duh 和 X. Carreras, 编辑。德克萨斯州奥斯汀: 计算语言学协会, 2016 年 11 月, 第 2383–2392 页。[在线的]。可用: <https://aclanthology.org/D16-1264> [39] C.-Y. Lin 和 F. J. Och, “使用最长公共子序列和跳过二元组统计数据自动评估机器翻译质量”, *Proceedings of the 42nd Annual Meeting of the Association for Computational Linguistics (ACL-04)*, 西班牙巴塞罗那, 2004 年 7 月, 第 605–612 页。[在线的]。可用: <https://aclanthology.org/P04-1077> [40] Y. G. au, W. Wang, D. Wang, H. Wang 和 Z. Zhang, “通信约束下的云边缘推理: 数据量化和提前退出”, *2022 International Symposium on Wireless Communication Systems (ISWCS)*, 2022 年, 第 1–6 页。[41] D. Xu, X. He, T. Su 和 Z. Wang, “云、边缘和终端设备上的神经网络分区调查”, *arXiv e-prints*, 第 11 页。arXiv:2304.10020, 2023 年 4 月。[42] A. Graves, “循环神经网络的自适应计算时间”, *arXiv e-prints*, 第 14 页。arXiv:1603.08983, 2016 年 3 月。[43] R. Schwartz, G. Stanovsky, S. Swayamdipta, J. Dodge 和 N. A. Smith, “适合这项工作的工具: 匹配模型和实例复杂性”, 载于 *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, D. Jurafsky, J. Chai, N. Schuster 和 J. Tetreault, 编辑。在线: 计算语言学协会, 2020 年 7 月, 第 6640–6651 页。[在线的]。可用: <https://aclanthology.org/2020.acl-main.593> [44] T. Schuster, A. Fisch, T. Jaakkola 和 R. Barzilay, “通过置信自适应变压器实现一致加速推理”, *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, M.-F. Moens, X. Huang, L. Specia 和 S. W.-t. 嗯, 编辑。在线和多米尼加共和国蓬塔卡纳: 计算语言学协会, 2021 年 11 月, 第 4962–4979 页。[在线的]。可用: <https://aclanthology.org/2021.emnlp-main.406> [45] F. Ilhan, K.-H. Chow, S. Hu, T. Huang, S. Tekin, W. Wei, Y. Wu, M. Lee, R. Kompella, H. Latapie, G. Liu 和 L. Liu, “利用 eenet 进行自适应深度神经网络推理优化”, 载于 *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2024 年 1 月, 第 1373–1382 页。[46] S. Teerapittayanon, B. McDanel 和 H. Kung, “Branchynet: 通过早期退出神经网络进行快速推理”, *2016 23rd International Conference on Pattern Recognition (ICPR)*, 2016 年, 第 2464–2469 页。[47] W. Liu, P. Zhou, Z. Wang, Z. Zhu, H. Deng 和 Q. Ju, “FastBERT: 具有自适应推理时间的自蒸馏 BERT”, 见 *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, D. Jurafsky, J. Chai, N. Schuster 和 J. Tetreault, 编辑。在线: 计算语言学协会, 2020 年 7 月, 第 6035–6044 页。[在线的]。可用: <https://aclanthology.org/2020.acl-main.537/> [48] L. Hou, Z. Huang, L. Shang, X. Jiang, X. Chen 和 Q. Liu, “Dynabert: 具有自适应宽度和深度的动态 bert”, 见 *Proceedings of the 34th International Conference on Neural Information Processing Systems*, 序列号。NIPS '20。美国纽约州 Red Hook: Curran Associates Inc., 2020 年。[49] W. Zhou, C. Xu, T. Ge, J. McAuley, K. Xu 和 F. Wei, “Bert 失去耐心: 快速而稳健的推理并提前退出”, 见 *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan 和 H. Lin, 编辑, 卷。33。Curran Associates, Inc., 2020, 第 18330–18341 页。[50] L. Del Corro, A. Del Giorno, S. Agarwal, B. Yu, A. Awadallah 和 S. Mukherjee, “SkipDecode: 自回归跳跃解码

高效 LLM 推理的批处理和缓存”, *arXiv e-prints*, 第 arXiv:2307.02628, 2023 年 7 月。[51] S. Bae, J. Ko, H. Song 和 S.-Y. Yun, “具有同步并行解码的自回归语言模型的快速且鲁棒的早期退出框架”, 参见 *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, H. Bouamor, J. Pino 和 K. Bali, 编者, 新加坡: 计算语言学协会, 2023 年 12 月, 第 5910–5924 页。[在线]: <https://aclanthology.org/2023.emnlp-main.362> [52] S. Tang, Y. Wang, Z. Kong, T. Zhang, Y. Li, C. Ding, Y. Wang, Y. Liang 和 D. Xu, “您需要多重退出: 加速统一视觉语言模型的动态早期退出”, 载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023 年 6 月, 第 10781–10791 页。[53] N. Varshney, A. Chatterjee, M. Parmar 和 C. Baral, “通过 ‘LITE’ 指令调整启用中间层解码来研究 LLaMA 推理的加速”, *Findings of the Association for Computational Linguistics: NAACL 2024*, K. Duh, H. Gomez 和 S. Bethard, 墨西哥城, 计算语言学协会, 2024 年 6 月, 第 3656–3677 页。[在线]。https://aclanthology.org/2024.findings-naacl.232 [54] X. Pan, Y. Chen, Y. Li, B. Ding 和 J. Zhou, “EE-Tuning: 用于调整早期退出大语言模型的经济且可扩展的解决方案”, p. arXiv: 2402.00518, 2024 年 2 月。[55] J. Kaddour, J. Harris, M. Mozes, H. Bradley, R. Raileanu 和 R. McHardy, “大语言模型的挑战和应用” *arXiv e-prints*, 第 arXiv: 2307.10169, 2023 年 7 月。[56] S. Hu, T. Huang, K.-H. Chow, W. Wei, Y. Wu 和 L. Liu, “Zipzap: 用于区块链大规模欺诈检测的语言模型的有效训练”, 《WWW ’24》, 美国纽约协会。计算机, 2024 年, 第 2807–2816 页。[在线]: <https://doi.org/10.1145/3589334.3645352> [57] J. Shi, A. Shirali, B. Jin, S. Zhou, W. Hu, R. Rangaraj, S. Wang, J. Han, Z. Wang, U. Lall, Y. Wu, L. Bobadilla, 和 G. Narasimhan, “天气预报的深度学习和基础模型: 一项调查”, *arXiv e-prints*, 第 arXiv: 2501.06907, 2025 年 1 月。[58] A. Radford, K. Narasimhan, T. Salimans 和 I. Sutskever, “通过生成预训练提高语言理解”, 2018 年。[59] A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever *et al.*, “语言模型是无监督的多任务学习者”, *OpenAI blog*, 第 1 卷, 第 8 期, 第 9 页, 2019 年。[60] T. Brown, B. Mann, N. Ryder 等人, “语言模型是小样本学习者”, *Advances in Neural Information Processing Systems*, H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan 和 H. Lin, Eds., 第 33 卷。Curran Associates, Inc., 2020 年, 第 1877–1901 页。[61] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave 和 G. Lample, “LLaMA: 开放且高效的基础语言模型”, *arXiv e-prints*, 第 arXiv:2302.13971, 2023 年 2 月。[62] A. Dubey, A. Jauhri, A. Pandey 等人, “The Llama 3 Herd of Models”, *arXiv e-prints*, p. arXiv:2407.21783, 2024 年 7 月。[63] A. Q. Jiang, A. Sablayrolles, A. Mensch 等人, “Mistral 7B”, *arXiv e-prints*, p. arXiv:2310.06825, 2023 年 10 月。[64] A. Q. Jiang, A. Sablayrolles, A. RoUX 等, “Mixtral of Experts”, *arXiv e-prints*, p. arXiv:2401.04088, 2024 年 1 月。[65] P. Agrawal, S. Antoniak, E. B. Hanna 等 al., “Pixtral 12B”, *arXiv e-prints*, p. arXiv: 2410.07073, 2024 年 10 月。[66] H. Jin, W. Wei, X. Wang, W. Zhang 和 Y. Wu, “重新思考大语言模型时代的学习率调整”, *2023 IEEE 5th International Conference on Cognitive Machine Intelligence (CogMI)*, 2023 年, 第 177 页。112–121. P. Patel, E. Choukse, C. Zhu, A. Shah, I. G. oiri, S. Maleki 和 R. Bianchini, “Splitwise: 使用相分裂的高效生成 LLM 推理”, *2024 ACM/IEEE 51st Annual International Symposium on Computer Architecture (ISCA)*, 美国加利福尼亚州洛杉矶阿拉米托斯: IEEE 计算机协会, 2024 年 7 月, 第 112 页。118–132。可用: <https://doi.ieeeecomputersociety.org/10.1109/ISCA59077.2024.00019> [68] Z. Zhou, X. Ning, K. Hong, T. Fu, J. Xu, S. Li, Y. Lou, L. Wang, Z. Yuan, X. Li, S. Yan, G. Dai, X.-P. Y. Dong 和 Y. Wang, “大语言模型的高效推理调查”, *arXiv e-prints*, arXiv: 2404.14294, 2024 年 4 月。