

CoGenesis: 一个用于协作大语言模型和小语言模型以安全上下文感知地遵循指令的框架

张凯言，王建宇，华尔模，齐碧清 丁宁 周博文 清华
大学，北京理工大学 哈尔滨工业大学

摘要

随着语言模型（LMs）的发展，它们接触到私人数据的情况越来越不可避免，而且将它们（尤其是较小的模型）部署在个人设备上，如 PC 和智能手机，已成为一种普遍趋势。在充满用户信息的场景中，使模型既能保护用户隐私，又能高效执行命令，成为一项重要的研究课题。在本文中，我们提出了 CoGenesis，一种整合大模型（托管在云基础设施上）和小模型（部署在本地设备上）的协作生成框架，以合理地解决隐私问题。最初，我们设计了一个管道，用于创建个性化写作指令数据集，并丰富了大量上下文细节，作为这一研究问题的测试平台。随后，我们基于草图和 logits 分别引入了两种 CoGenesis 变体。我们的实验结果基于我们合成的数据集和另外两个开源数据集表明：




图 1: ① 上下文感知指令遵循示例。② 大型语言模型（LLM）在有上下文时表现出色，但存在隐私风险。③ 专用的小型语言模型（SLM）在本地设备上运行对隐私友好，但表现较差。④ LLM 与 SLM 的协作可提升隐私性和性能。

1 引言

大型语言模型（LLMs）在推动人工智能方面显示出显著潜力，表现出卓越的指令遵循能力，并在写作、编码等各类任务中取得优异表现，

通讯作者 本文将大型语言模型（LLMs）定义为既包括封闭源又包括开源模型，旨在实现通用应用和高级性能，并用于云端部署。相反，小型语言模型（SLMs）指为特定任务定制并部署在本地设备上的模型。

以及其他基于文本的活动（Achiam 等，2023；Bubeck 等，2023；Touvron 等，2023a,b）。基于大语言模型（LLM）的人工智能助手在执行指令、协助写作任务以及加速工作流程中起着关键作用，从而促进内容创新（Zhang 等，2023a；Haase 和 Hanel，2023）。LLM 通常需要大量上下文信息，以生成更个性化和有效的内容，这归功于其上下文学习能力（Brown 等，2020）。检索增强生成（RAG）（Gao 等，2023）已被证明在引入额外上下文以提升 LLM 输出的信息量和个性化方面具有益处。然而，目前的指令执行任务在设计中往往未能考虑丰富的用户上下文（Wang 等，2023c；Xu 等，2023b；Ding 等，2023）。整合个人

经验和活动日志可以显著增强这些指令的有效性，这被称为情境感知指令遵循。

尽管取得了进展，最复杂的 LLM，包括 GPT-4、Claude 和 Gemini，主要还是商业化并部署在云服务上。这种基于 API 的部署确保了 LLM 的隐私，但可能会损害用户隐私（Xiao 等 Zhang 等）。虽然像 Llama-2（Touvron 等）、Qwen（Bai 等）和 Mistral（Jiang 等）这样更强大的 LLM 正在开源，但在有限资源的本地设备上稳定部署仍然具有挑战性。最近在配备了数十亿参数的小型 LM（SLM）方面的进展，使其能够部署在消费者桌面和智能手机上，并实现令人满意的性能（Bai 等；

如图 所示，考虑以下情景：较小的个性化语言模型（SLM）部署在资源有限的用户设备上。这些 SLM 在处理指令时可以访问设备上的私人数据和活动日志。相比之下，更高级的通用大型语言模型（LLM）在云服务上运行，仅接收一般性指令。在此设置中，LLM 提供高级知识，如更深入的规划、更优的纲要，甚至“暗知识”。与此同时，SLM 利用由 LLM 提供的上下文信息和知识，共同生成个性化内容。当前针对基于 API 服务的隐私保护方法有限（Cummings 等）；它们要么只能处理带有文本净化的简单分类任务（Kan 等；Chen 等，

总体而言，我们的贡献可概括如下：（1）我们引入了结合大量用户隐私上下文信息的上下文感知指令跟随任务。为支持该任务，我们设计了一个四步数据构建过程，并合成了一定数量的指令数据以进行实验验证。（2）我们研究了 LLM 和 SLM 在该任务上的表现。我们的发现表明，当提供上下文时，SLM 可以超过缺乏上下文的 LLM，但仍落后于具备上下文的 LLM 的表现。（3）针对上下文感知指令生成，我们提出了 CoGenesis 框架。CoGenesis 包括基于草图和基于逻辑的变体，以促进大语言模型与小语言模型之间的协作。这种方法不仅保护了上下文隐私，同时也确保了性能提升。

2 上下文感知的指令遵循

2.1 任务定义

当前的指令格式要么由独立指令组成，要么由附加输入的指令组成（Wang 等，）。虽然这些指令通常涵盖写作、搜索和编码等通用任务，但这些输入通常包含特定任务信息，例如表格和编码问题。我们将上下文感知的指令执行任务归类于可控条件文本生成领域（Zhang 等，），通过额外的个人上下文丰富标准指令。该任务，专注于生成与用户特定数据相关的响应，这些数据标注了隐私和个人风格，由指令和上下文信息指导。它强调了上下文整合对于提升输出个性化和相关性的意义，正式

$$\mathcal{T}(t, \mathcal{C}) : r = g(t, \mathcal{C}; \theta) \tag{1}$$

这个生成模型具有参数，旨在个体数据属性的细微上下文中自适应地响应用户指令。

2.2 数据构建

如图 左侧所示，我们概述了一个新颖的四步流程，用于制定面向不同用户群体的上下文感知指令，以便让 AI 助手生成个性化和富有创意的文本。我们的方法从




图 2：此插图展示了构建过程和上下文感知指令的示例。

创建详细的用户群画像，捕捉人口统计、职业背景和兴趣，以识别特定的人工智能应用场景。然后详细描述个人用户档案，融入独特的写作风格、虚构的个人信息以及智能设备使用情况，以构建用于人工智能写作任务的细致人物。这些档案为设计与每个人物生活方式和数字互动相契合的写作任务提供依据，确保任务的现实性和相关性。最后，我们生成个性化文本，准确反映人物的职业和个人经历，展示我们的方法在为人工智能辅助文本生成生成连贯、特定情境内容方面的有效性。

示例在图 2 的右侧进行了说明，其中用户指令包括通用部分和个人部分。后者结合所提供的个人资料、经验、活动和先前文章，构成了隐私敏感的上下文信息。

3 协作生成框架

3.1 CoGenesis 概述

我们提出了 CoGenesis 框架，该框架利用了两种不同规模模型的优势：一个参数为 10^9 的大语言模型（LLM）和一个参数为 10^6 的小语言模型（SLM）。该框架以融合策略为核心，记作 $\mathcal{F}$ ，可以智能地结合两种模型的输出。具体来说， $\mathcal{F}$ 仅根据通用指令 u 生成回复，而 $\mathcal{F}$ 在生成输出时同时考虑用户指令 u 和额外的个人上下文 c 。融合策略

$\mathcal{F}$ 旨在协同融合 $\mathcal{F}_L$ 和 $\mathcal{F}_S$ 的输出。从直觉上看，组合后的性能预计不仅会超越各个模型的性能，还会接近 $\mathcal{F}_L$ 如果它处理了 c 的性能。

在我们的协作框架中，内容的草图（或轮廓）以及来自大型语言模型（LLM）的下一个标记的 logits 被视为高层次知识的形式。函数 $\mathcal{F}_L$ 的两种方法分别被识别为基于草图的方法和基于 logit 的方法。基于草图的方法与模型无关，而基于 logit 的方法在我们当前的配置中要求 LLM 和 SLM 使用相同的分词器。在接下来的章节中，我们将依次详细介绍函数 $\mathcal{F}_L$ 的这两种实现。

3.2 基于草图的共生成

认识到大型语言模型（LLMs）在规划方面的优势以及小型语言模型（SLMs）在制作情境化回应方面的能力，我们引入了一种“先草拟 - 再 LL”的方法，以协同它们在个性化内容生成中的能力。如图 2 左侧所示，该方法包括两个关键步骤：

步骤 1：通过大语言模型生成草图。鉴于成本高且复杂，尤其是依赖 API 的大语言模型，我们通过直接向大语言模型提供通用指令 u 来简化这一过程。内容的草图 r_{sketch} 是通过使用采样策略从大语言模型进行文本解码而得出的，可以简明地表示为：

$$r_{\text{sketch}} = \text{Decoding}_{\text{LLM}}(t; \theta_L) \quad (2)$$

步骤 2：通过 SLM 进行内容个性化。在获取草图之后，SLM 会利用它，




图 3: 此图展示了 CoGenesis 框架的两种协作生成变体。

结合初始指令 和个人上下文 ，定制个性化内容 。此阶段侧重于微调 SLM 的参数以优化内容相关性和个性化：

$$\hat{r} = \arg \max_r P(r|t, \mathcal{C}, r_{\text{sketch}}; \theta_s) \quad (3)$$

在这个公式中， 表示最终的、定制化的内容，是给定指令 、上下文 以及草稿 的情况下生成的概率 ，参数为 。这种方法阐明了在不需要调整参数的情况下，如何利用大型语言模型

（LLM）进行基于用户提示的基础文本草稿创作，以及使用小型语言模型（SLM）进行进一步内容精炼。这确保最终输出与用户的具体要求及其交互历史相一致，并凸显出 LLM 和 SLM 在个性化内容创作中既不同又互补的作用。

3.3 基于 Logit 的 CoGenesis

语言模型最后一层产生的 logits 蕴含丰富信息，反映了模型的内部黑暗知识。以往的研究，如对比解码（Li 等， ）和模拟器调优（Mitchell 等， ），已经探索了将 LLM 和 SLM 的 logits 协同使用，以减少幻觉（Sennrich 等， ）、增强推理能力（O’ Brien 和 Lewis， ）以及简化 LLM 的微调过程（Liu 等， ）。受到这些工作的启发，我们的基于 logits 的策略涉及在不同输入下整合 LLM 与 SLM 的 logits，确保协作决定下一个 token。我们方法的一个显著特点是模型的上下文暴露不同：SLM 可以访问 th

完整的隐私上下文，而 LLM 只提供了宽泛的指令，如图 所示。

将响应序列定义到第 个标记为 ，并将第 个标记在词汇表上的概率由 LLM 和 SLM 生成分别记为 和 ，我们利用一个轻量级的组合模型，记为 CombModel，参数为 ，来推导最终组合概率 的融合权重 。基于 logit 的方法计算过程如下：

$$p_k^s = \theta_s(r_{<k}, t, \mathcal{C}), p_k^l = \theta_l(r_{<k}, t) \quad (4)$$

$$w = \text{CombModel}(p_k^l, p_k^s) \quad (5)$$

$$p_k^c = w \cdot p_k^s + (1 - w) \cdot p_k^l \quad (6)$$

4 个实验

4.1 数据集

合成数据集。按照 中概述的构建过程，我们使用 GPT-4 合成了一个上下文感知指令跟随数据集。由于成本考虑，我们基于数百张群体画像构建了一个代表数千名虚构用户的数据集。在进行质量和格式筛选后，我们最终获得了 1,500 名用户用于训练和验证。此外，我们从多样化的群体画像中选择了大约 200 名用户作为测试集。

开源数据集。除了我们的合成上下文感知指令数据集外，我们还使用公开可访问的个性化上下文写作数据集，尽管它们仅限于电子邮件和学术等领域的特定任务。

论文。具体来说，我们使用 LaMP 中处理过的
鳄梨研究电子邮件和引用网络论文数据集

（Salemi 等，[2023](#)）。此外，我们进一步优化
这些数据集，以便生成电子邮件正文和论文摘要，
同时将同一用户之前的电子邮件和论文作为上下文
信息考虑在内。

关于合成和处理过的数据集的更多详细信息可以在附录中找到。

4.2 基线

设置。我们在实验中主要评估四种配置：带上下文的 LLM。我们为 LLM 提供额外的上下文，以便生成个性化内容。这是一个上限，可能会影响上下文隐私。不带上下文的 LLM。鉴于上下文数据隐私的重要性，建议将对基于云的 LLM 的请求限制为一般指令。此设置作为下限，能够保护用户隐私。带上下文的 SLM。该设置建立了保护隐私的本地个性化生成基线。带上下文的 LLM。这是我们提出的大型模型与小型模型协作生成的方法。在此框架下，我们评估基于草图和基于 logit 的方法。

模型。我们的 LLM 选择涵盖了商业 API 型和开源模型。在商业部分，我们主要关注 GPT-3.5-turbo 和 GPT-4-turbo。在开源领域，我们选择了 Llama-2（Touvron 等，[2023](#)）、Qwen（版本 1 和 1.5 的 72B）（Bai 等，[2023](#)）以及 Mistral（Jiang 等，[2023](#)）系列中最大的模型。关于 SLM，我们优先选择最近发布的拥有数十亿参数的模型。这包括 TinyLlama（Zhang 等，[2023](#)）、Qwen（版本 1 和 1.5 的 1.8B）、StableLM 以及 H2O-Danube（Singer 等，[2023](#)）。对于 LLM 和 SLM，我们的重点是聊天版本，使用每个模型的默认模板进行协作

此外，零样本大语言模型（LLM）在有上下文的和无上下文的设置中都被使用。对于有上下文的序列语言模型（SLM），我们同时包含零样本和微调模型，而在 LLM 有上下文的 SLM 中仅使用微调的 SLM。关于 LLM 的提示和 SLM 的微调细节的更多信息，请参见附录。

²<https://github.com/QwenLM/Qwen1.5>

³<https://huggingface.co/stabilityai>

4.3 评估指标

在指令遵循评估中，基于大语言模型（LLM）的评估者如 GPT-4 已显示出高度的一致性和有效性（Chang 等，[2023](#)），尤其是在个性化内容生成方面，其一致性优于人工评估者（Wang 等，[2023](#)）。因此，我们采用 GPT-4-turbo 作为评判者，从多个角度评估生成的内容。本次评估涵盖若干标准：个性化、与用户特征的匹配性、帮助性、相关性、深度、创造力以及细节水平，这些标准共同构成整体评分（[表 1](#)）。为了进一步分析性能，我们引入了两个不同的提示：一个包含用户上下文（[表 1](#)），另一个不包含用户上下文（[表 1](#)），从而能够对 LLM 在个性化内容生成和广义指令遵循方面进行比较评估。
A

4.4 主要结果

如表 1 所示，我们从以下几个方面分析实验结果：

关于大型语言模型的结果。在有上下文设置中，GPT-4-turbo 在所有指标和数据集上均优于其他模型，其次是 Qwen-Chat(v1.5)，表现第二好。在无上下文设置中也观察到类似的结果。然而，将两种设置进行比较发现，在缺乏上下文信息的情况下，所有大型语言模型在个性化和整体评分方面的表现都会下降，这凸显了上下文的重要性。有趣的是，虽然上下文在有上下文设置中对评分有很大影响，但在无上下文设置中对评分的影响可忽略不计，这反映了大型语言模型在遵循一般指令方面的高级能力。此外，当我们将我们合成的上下文感知数据集和电子邮件数据集与论文摘要数据集进行比较时，后者表现出有限的个性化因素，从而在无上下文设置中表现出较高性能。

SLM 的结果。零样本 SLM 表现出高度变化的性能，受预训练和监督微调因素的影响。值得注意的是，StableLM-Zephyr 取得了最高性能，H2O-Danube-Chat 和 Qwen-Chat(v1.5) 紧随其后，竞争第二名。有趣的是，在上下文优势下，零样本 SLM 在某些场景中可以超过 LLM 的表现。

Model	Params	Context-aware Instructions			Avocado Emails			Academic Paper Abstracts		
		Ovl.(w)	Per.	Ovl.(w/o)	Ovl.(w)	Per.	Ovl.(w/o)	Ovl.(w)	Per.	Ovl.(w/o)
zero-shot LLM with context (upper bound)										
L1 GPT-4-turbo	N/A	8.85	8.90	8.54	8.31	7.71	8.05	8.64	8.47	8.68
L2 GPT-3.5-turbo	N/A	8.30	8.33	7.58	7.70	7.45	7.57	7.97	7.88	8.29
L3 Llama-2-Chat	70B	7.78	7.98	7.96	7.00	7.18	8.05	7.48	7.12	8.32
L4 Qwen-Chat(v1)	72B	8.38	8.38	8.14	7.62	7.10	7.70	7.90	7.62	8.24
L5 Qwen-Chat(v1.5)	72B	8.70	8.67	8.26	8.20	7.69	7.80	8.52	8.16	8.60
L6 Mixtral-8x7b	47B	8.12	8.22	7.96	7.35	6.88	6.92	7.92	7.62	8.08
zero-shot LLM w/o context (lower bound)										
L1 GPT-4-turbo	N/A	6.10	6.46	8.75	5.10	3.79	8.58	8.42	7.94	8.73
L2 GPT-3.5-turbo	N/A	4.34	3.76	7.47	3.72	3.03	7.61	3.37	3.59	6.04
L3 Llama-2-Chat	70B	4.74	4.60	8.12	3.38	3.52	8.04	6.74	6.18	7.90
L4 Qwen-Chat(v1)	72B	3.70	3.38	7.72	3.28	2.38	7.50	6.42	5.54	7.90
L5 Qwen-Chat(v1.5)	72B	5.86	5.98	8.52	5.83	4.40	8.54	7.92	7.16	8.28
L6 Mixtral-8x7b	47B	5.32	5.08	8.14	3.38	3.52	8.04	6.74	6.18	7.90
zero-shot SLM with context										
S1 StableLM-Zephyr	1.6B	6.88	6.82	6.68	6.03	5.49	6.51	7.32	6.94	8.14
S2 H2O-danube-chat	1.8B	6.56	6.94	6.60	4.77	5.00	6.57	5.98	5.54	6.94
S3 TinyLlama-Chat	1.1B	1.72	1.84	2.14	4.00	3.54	5.40	1.96	1.88	4.24
S4 Qwen-Chat(v1)	1.8B	5.78	5.50	6.00	4.91	4.54	6.49	4.46	5.04	6.74
S5 Qwen-Chat(v1.5)	1.8B	6.86	6.86	7.20	5.51	4.89	6.14	6.42	6.14	7.78
netuned SLM (+ LLM) with context										
S1 StableLM-Zephyr + L1 sketch	1.6B	8.30	8.56	7.73	7.58	6.70	7.20	7.96	7.64	8.18
	mixed	8.48 _{↑0.18}	8.56 _{↑0.00}	7.98 _{↑0.25}	7.68 _{↑0.10}	6.62 _{↓0.08}	7.48 _{↑0.28}	8.28 _{↑0.32}	7.48 _{↓0.16}	8.38 _{↑0.20}
S2 H2O-danube-chat + L1 sketch	1.8B	7.64	7.58	7.00	6.50	6.16	6.34	7.70	7.30	8.06
	mixed	7.84 _{↑0.20}	7.78 _{↑0.20}	7.14 _{↑0.14}	7.14 _{↑0.64}	6.72 _{↑0.56}	7.52 _{↑1.18}	8.10 _{↑0.40}	7.28 _{↓0.02}	8.18 _{↑0.12}
S3 TinyLlama-Chat + L1 sketch + L3 logits	1.1B	7.42	7.66	6.78	6.12	5.92	6.20	7.66	7.32	8.18
	mixed	7.66 _{↑0.24}	7.14 _{↓0.52}	6.82 _{↑0.04}	6.58 _{↑0.46}	6.02 _{↑0.10}	6.60 _{↑0.40}	7.72 _{↑0.06}	7.36 _{↑0.04}	8.10 _{↓0.08}
	mixed	7.76 _{↑0.34}	7.74 _{↑0.08}	7.06 _{↑0.28}	6.06 _{↓0.06}	6.16 _{↑0.24}	6.94 _{↑0.74}	8.14 _{↑0.48}	7.34 _{↑0.02}	8.04 _{↓0.14}
S4 Qwen-Chat(v1) + L1 sketch + L4 logits	1.8B	7.44	7.76	7.02	7.00	6.71	7.06	7.84	7.36	8.18
	mixed	7.80 _{↑0.36}	7.82 _{↑0.06}	7.64 _{↑0.62}	7.18 _{↑0.18}	6.44 _{↓0.27}	7.28 _{↑0.22}	8.02 _{↑0.18}	7.70 _{↑0.34}	8.34 _{↑0.16}
	mixed	8.12 _{↑0.68}	8.20 _{↑0.44}	7.86 _{↑0.84}	7.48 _{↑0.48}	6.44 _{↓0.27}	7.46 _{↑0.40}	7.92 _{↑0.08}	7.16 _{↓0.20}	8.30 _{↑0.12}
S5 Qwen-Chat(v1.5) + L1 sketch + L5 logits	1.8B	8.08	8.12	7.40	6.34	5.56	6.54	7.68	7.30	8.18
	mixed	8.18 _{↑0.10}	7.98 _{↓0.14}	7.62 _{↑0.22}	6.54 _{↑0.20}	5.84 _{↑0.28}	6.74 _{↑0.20}	8.10 _{↑0.42}	7.24 _{↓0.06}	8.32 _{↑0.14}
	mixed	8.28 _{↑0.20}	8.22 _{↑0.10}	7.80 _{↑0.40}	6.66 _{↑0.32}	5.70 _{↑0.14}	7.12 _{↑0.58}	8.14 _{↑0.46}	7.28 _{↓0.02}	8.40 _{↑0.22}

表 1: 该表显示了 LLM 和 SLM 在有上下文和无上下文设置下的表现。我们将最佳结果**标粗**，第二名下划线，并使用 _↑ 和 _↓ 标注每个 SLM 的变动。

缺乏上下文。然而，LLM 在没有上下文的情况下整体得分始终优于 SLM，突显了其在通用指令生成方面的卓越能力。经过微调后，SLM 的表现超过了许多有上下文的 LLM，显示了专业化的优势。然而，SLM 的表现仍未达到最强大的 LLM（如 GPT-4-turbo 和 Qwen-Chat(v1.5)）的水平。这些结果凸显了专用 SLM 与 LLM 协作的潜力，以实现更好的个性化得分、更深入的写作以及增强的指令泛化能力。

混合尺度模型合作的结果。在我们对混合尺度模型合作的探索中，我们对所有 SLM 使用基于草图的方法，而在 Llama 和 Qwen 模型家族中则仅使用基于逻辑的方法。此比较表明，混合尺度模型之间的合作所取得的结果可与单独的 LLM 相媲美，同时也更加安全。

保护隐私。协作努力通常会提升 SLM 的总体评分，无论是在有用户上下文还是无用户上下文的评估中。然而，特别是融入基于草图的协作，可能会略微降低个性化评分，因为依赖于在没有上下文的情况下进行推理的 LLM。在基于 logit 和基于草图的方法之间，前者证明更为有效，这取决于 SLM 和 LLM 是否使用相同的分词器。总体而言，这种混合规模模型之间的协作策略为平衡效率和隐私考虑提供了一个有前景的途径，尽管它仍然需要进一步的优化以提高性能。

4.5 消融研究

4.5.1 基于草图的共生成

草图与完整内容。图 对比了仅使用草图与使用 LLM 提供的完整内容的效果。研究结果表明，通常加入完整内容更有利




图 4：使用草图与完整内容的 SLM 性能比较。




图 5：使用由各种模型生成的草图的 StableLM 性能。

与不使用任何内容或仅使用草图相比，会降低模型性能。这种差异可以归因于潜在的冗余信息过载。如（[Weston 和 Sukhbaatar](#)）中所探讨，内容过多并不一定能提升性能，反而可能引入多余的细节。

草图的泛化能力。对于通过 GPT-4 生成的草图进行微调的小型模型，我们通过在测试中使用来自各种大型语言模型（LLM）的草图来探索其泛化潜力。具体来说，我们重点关注进行详细消融分析。图显示，相较于，使用来自其他 LLM 的草图会稍微负面影响整体和个性化评分，但在缺少上下文的情况下提升整体评分。这表明由不同模型生成的草图存在差异，并表现出有限的泛化能力。

4.5.2 基于 Logit 的 CoGenesis

Logits 融合策略。我们在中实现了一个可学习的模型，旨在合并来自上下文无关的 LLM 和包含上下文的 SLM 的 logits。此外，我们探索了简单的最大值和平均值池化策略，这些策略被认为是稳健的基线方法（Ormazabal 等，）。根据表，最大值和平均值池化方法都提升了 SLM 的性能，其中最大值池化

Models \ Metric	Ovl.(w)	Per.	Ovl.(w/o)
Qwen-72B-Chat (with context)	8.38	8.38	8.14
Qwen-72B-Chat (w/o context)	3.70	3.38	7.72
Qwen-1.8B-Chat (netuned)	7.44	7.76	7.02
Mean Pooling Fusing	7.76	7.84	7.42
Max Pooling Fusing	7.90	7.94	7.52
Learnable Weights Fusing	8.12	8.20	7.86

表 2：平均融合和最大融合策略与我们的可学习融合模型的比较。

Model and Setting	Win/Tie/Lose (%)	BLEU	ROUGE-L
SLM netuned	-/50/-	2.07	13.95
LLM w/ context	38/2/10	2.61	14.66
LLM w/o context	3/0/47	1.51	13.54
Sketch-based CoGen	27/3/20	1.81	12.98
Logits-based CoGen	32/5/13	2.30	14.18

表 3：人工评估和自动评估结果（Qwen-72B/1.8BasLLM/SLM）

证明其优越性。尽管如此，鉴于大语言模型（LLM）和小语言模型（SLM）的输入条件不同，在上下文感知环境中，可学习的融合模型变得至关重要，显著优于简单的池化技术。

大型语言模型 (LLM) 和小型语言模型 (SLM) 的输出值。在融合模型中，我们使用自适应权重整合来自 LLM 和 SLM 的输出值。图展示了由和生成的输出，使用颜色编码的权重来划分各自的贡献：红色表示 SLM，蓝色表示 LLM，白色表示均衡权重 0.5。观察可知，LLM 主要影响生成内容的轮廓，而 SLM 在大多数标记上发挥更重要的作用，凸显了协作的重要性。

4.6 人类评估

大型语言模型的评估尚未被证明是万无一失的；因此，我们进行了人工评估。为了简化这一评估的复杂性，指示了标注人员




图 6：生成过程中每个 Token 的 LLM 和 SLM Logits 权重可视化。蓝色表示 SLM 的贡献，红色表示 LLM 的贡献，颜色越深表示权重越高。

将各种设置下的结果与微调后的 SLM 进行比较，记录结果为赢 / 平 / 输，模仿 lmsys/chatbot-arena-leaderboard 中使用的方法。此外，我们使用传统的词汇重叠指标，如 BLEU 和 ROUGE-L，通过 evaluate 库计算。

如表 所示，人类评估结果与 GPT-4 评估结果一致，其中 CoGenesis 的表现优于未微调的 SLM 和无上下文 LLM，并且与有上下文的 LLM 表现接近。

Settings	Ovl.(w/)	Per.	Ovl.(w/o)
LLM w/ context	8.38	8.38	8.14
LLM w/o context	3.70	3.38	7.72
FT SLM (rk=0 toks)	7.44	7.76	7.02
LLM+SLM (rk=8 toks)	7.72	7.96	7.38
LLM+SLM (rk=16 toks)	7.78	7.84	7.22
LLM+SLM (rk=32 toks)	7.94	7.98	7.30
LLM+SLM (rk=64 toks)	7.94	8.04	7.54
LLM+SLM (rk=128 toks)	7.98	8.06	7.44
Logit-based CoGenesis	8.12	8.20	7.86

表 4：基于 Logit 的 CoGenesis 中使用的首个标记数量的比较分析。

5 讨论

虽然我们的实验仅限于使用相同分词器的同一系列模型，但这些方法有可能通过分词器对齐策略扩展（Fu 等人，；Wan 等人，）。这一原理与其他基于 logits 的解码技术相一致，例如推测解码、对比解码。通过对齐具有不同分词器的模型的 tokens 和概率，有可能在各种 LLM 和 SLM 之间促进知识转移。

最近的研究表明，有可能根据下一个词元的分布来重建提示（Morris 等。）。然而，提取的准确性，尤其是精确匹配分数，仍然令人沮丧地低。此外，由于在我们的实验中仅使用了每个词元的前 k 个 logits，重建的成本高得令人望而却步。因此，基于 logits 的协作仍然足够

安全，并可以通过实施加密和噪声添加算法进一步增强。如表 所示，我们研究了基于 logit 的 CoGenesis 方法，该方法通过仅上传前几个 token 而非整个响应来增强隐私。这种方法受“良好的开端促进有效完成”原则的启发（Jain 等 王和周），表明来自大型语言模型（LLM）对前几个 token 的初始指导可以引导小型语言模型（SLM）独立生成剩余的响应。性能数据显示，当仅将 8、16 或 32 个 token 传输到云端 LLM 时，相比单独微调的 SLM，性能有所提升，而整个响应通常超过 500 个 token。增加传输的 token 数量可以提高 LLM SLM 的性能，使我们能够在增强性能与重新

6 相关工作

大型语言模型的出现已经彻底改变了指令执行领域，模型正在被训练

⁴<https://huggingface.co/spaces/lmsys/chatbot-arena-leaderboard>

⁵<https://github.com/huggingface/evaluate>

在多样且复杂的指令集上，使其能够执行从创意写作（Franceschelli 和 Musolesi, 2023）到编码（Qian 等, 2023）和调试（Jimenez 等, 2023）的各种任务。对高质量指令数据的收集推动（Wang 等, 2023c；Ding 等, 2023；Xu 等, 2023a）促成了专有和开源中等规模语言模型的发展，这些模型善于遵循指令。然而，依赖诸如 ChatGPT 和 GPT-4 的云端专有模型来执行指令引发了显著的隐私问题，因为上传敏感数据可能带来潜在风险（Achiam 等, 2023；Team 等, 2023；Liu 等, 2023）。为缓解这些风险，各种隐私保护技术被应用，尽管在完全保护用户数据方面存在局限性（Cummings 等, 2023；Kan 等, 2023；Chen 等, 2023b；Wu 等, 2023）。此外，在

与此同时，混合规模模型协作的探索成为应对大型语言模型（LLMs）固有的可扩展性、效率（Xia 等, 2024）和隐私（Yao 等, 2023）挑战的一个有前景的途径。虽然更大的模型因能力增强而受益，但其高推理成本和隐私问题与较小模型的低成本和更高可访问性形成对比（Bai 等, 2023；Gunasekar 等, 2023；Zhang 等, 2024；Grangier 等, 2024；Singer 等, 2024）。该领域的研究分为协作训练和推理策略，包括离线调优（Xiao 等, 2023）和推测性解码（Leviathan 等, 2023），旨在利用大模型和小模型的优势（Mitchell 等, 2023；Liu 等, 2024）。本文特别研究协作推理方法，包括基于草图和基于 Logit 的方法，以提高 LLMs 的效率和隐私保护，提出了一个有前景的方向。

7 结论

本文研究了上下文感知的指令执行，通过提供详细的用户隐私信息来丰富提示。我们概述了一个用于

创建上下文感知的指令。为了减轻隐私问题，我们引入了 CoGenesis，这是一个使用草图和对数几率的 SLM 与 LLM 之间的协作框架。我们的结果强调了混合规模模型协作的优势，表明了未来研究的有益方向。

限制

本研究探讨了上下文感知的指令跟随，介绍了大型模型与小型模型之间协作的策略，以解决隐私问题。我们开发了一个用于上下文感知指令跟随的合成数据集，以实证测试我们的方法。我们的研究表明，这种模型协作可以显著减轻使用基于公共 API 的大语言模型时的隐私风险。然而，我们的数据集规模有限，并且是专门为初步验证而制作的。未来的工作将侧重于扩展该数据集，以提高其质量、真实性和多样性。此外，我们提出的方法，特别是基于 logits 的方法，目前仅限于共享相同分词器的模型。还需要在分词器对齐方面进行进一步研究，以扩大我们策略的适用性。

伦理声明

大型语言模型（LLM）的出现凸显了在人工智能领域中迫切需要解决隐私和安全问题。本文集中讨论了由 LLM 的上下文感知指令执行应用所带来的隐私挑战，并提出了在不影响模型有效性的前提下缓解这些问题的方法。我们强调保护用户数据的伦理必要性，采取的策略包括使用 GPT-4 生成合成数据集进行训练和测试。这种方法确保我们的研究不会通过潜在的数据泄露而影响现实世界的用户隐私。本质上，我们的工作不仅旨在提升 LLM 的技术能力，同时通过创新和安全的数据处理实践维护用户隐私，从而坚持最高的伦理责任标准。

致谢

本工作得到了中国国家重点研发计划（编号：2022ZD0119101）的支持。我们对匿名评审的宝贵意见表示感谢。

参考文献 乔什·阿奇亚姆, 史蒂文·阿德勒, 桑德希尼·阿加尔瓦尔, 拉玛

Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altenschmidt, Sam Altman, Shyamal Anadkat 等人. 2023 年. 《GPT-4 技术报告》. arXiv 预印本 arXiv:2303.08774.

白金泽、白帅、楚云飞、崔泽宇、党凯、邓晓东、范杨、葛文斌、韩宇、黄飞等. 2023. Qwen 技术报告. arXiv 预印本 arXiv:2309.16609. Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell 等. 2020. 语言模型是少样本学习者. 《神经信息处理系统进展》, 33:1877–1901. Sébastien Bubeck, Varun Chandrasekaran, Ronen Eldan, Johannes Gehrke, Eric Horvitz, Ece Kamar, Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lundberg 等. 2023. 人工通用智能的火花: GPT-4 的早期实验. arXiv 预印本 arXiv:2303.12712. 常宇鹏、王旭、王金东、吴元、杨林毅、朱凯杰、陈浩、易晓源、王存祥、王一东等. 2023. 大型语言模型评估综述. 《ACM 智能系统与技术汇刊》. 陈立昌、李世阳、闫俊、海

第 3029–3051 页, 新加坡. 计算语言学协会。

Giorgio Franceschelli 和 Mirco Musolesi.

2023. 关于大型语言模型的创造力. arXiv 预印本 arXiv:2304.00008. Yao Fu, Hao Peng, Litu Ou, Ashish Sabharwal, 和 Tushar Khot. 2023. [将较小的语言模型专门化以进行多步推理](#). 发表在 第 40 届国际机器学习大会论文集, 机器学习研究论文集第 202 卷, 页码 10421–10430. PMLR.

Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, 和 Haofen Wang. 2023. 大型语言模型的检索增强生成: 综述. arXiv 预印本 arXiv:2312.10997. David Grangier, Angelos Katharopoulos, Pierre Ablin, 和 Awni Hannun. 2024. 基于有限领域数据进行廉价推理的专用语言模型. arXiv 预印本 arXiv:2402.01093. Suriya Gunasekar, Yi Zhang, Jyoti Aneja, Caio César Teodoro Mendes, Allie Del Giorno, Sivakanth Gopi, Mojan Javaheripi, Piero Kauffmann, Gustavo de Rosa, Olli Saari

Roxana Geambasu、Matthew Jagielski、Yangsibo Huang、Peter Kairouz、Gautam Kamath、Sewoong Oh、Olga Ohrimenko 等人. 2023 年. 《隐私下一前沿的挑战》. arXiv 预印本 arXiv:2304.06929.

宁丁, 陈宇林, 徐博凯, 秦宇佳, 沈丁湖, 刘志远, 孙茂松, 周博文. 2023. [通过扩展高质量指导性对话提升聊天语言模型](#). 载于《2023 年自然语言处理实证方法会议论文集》

姚顺宇, 裴科新, O r Press 和卡尔蒂克

- Narasimhan. 2023. Swe-bench: 语言模型能否 mod-ELS 是否能解决现实世界的 GitHub 问题? arXiv 预印本 arXiv:2310.06770。
- 阚志刚, 乔林波, 于昊, 彭立文, 易夫高, 李东升。2023 年。在远程对话系统中保护用户隐私: 一种基于文本清理的隐私保护框架。arXiv 预印本 arXiv:2306.08223。
- 贾里德·卡普兰, 萨姆·麦康利什, 汤姆·亨尼根, 汤姆·B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, 和 Dario Amodei。2020. 神经语言模型的扩展规律。arXiv 预印本 arXiv:2001.08361。
- 雅尼夫·列维亚坦, 马坦·卡尔曼, 尤西·马蒂亚斯。2023. 通过推测解码从变换器快速推理。在国际机器学习大会, 页码 19274–19286。PMLR。
- 项丽莎·李, 阿里·霍尔茨曼, 丹尼尔·弗里德, 珀西·梁, Jason Eisner、Tatsunori Hashimoto、Luke Zettlemoyer 和 Mike Lewis。2022. 对比解码: 作为优化的开放式文本生成。arXiv 预印本 arXiv:2210.15097。
- 刘艾丽莎、韩晓创、王一中、尤利娅 Tsvetkov, Yejin Choi, 和 Noah A Smith。2024. 代理调优语言模型。arXiv 预印本 arXiv:2401.08565。
- 杨柳、姚元顺、让·弗朗索瓦·通、晓颖张若诚, 郭浩成, 叶戈尔·克洛奇科夫, 穆罕默德·法伊兹·陶克, 李航。2023. 《值得信赖的大型语言模型: 评估大型语言模型对齐的调查与指南》。arXiv 预印本 arXiv:2308.05374。
- 埃里克·米切尔、拉斐尔·拉法伊洛夫、阿尔奇特·夏尔马、切尔西 Finn 和 Christopher D Manning。2023. 使用小型语言模型对大型语言模型进行微调的模拟器。arXiv 预印本 arXiv:2310.12962。
- MLC 团队。2023 年。[https://arxiv.org/abs/2310.12962](#)。John Xavier Morris, Volodymyr Kuleshov, Vitaly Shmatikov 和 Alexander M Rush。2023. [文本嵌入揭示的信息\(几乎\)和文本本身一样多](#)。发表于 2023 年自然语言处理实证方法会议。
- 约翰·泽维尔·莫里斯, 赵文婷, 贾斯汀·T·邱, Vi-伊塔利·什马蒂科夫 和 亚历山大·M·拉什。2024. [语言模型反演](#)。收录于第十二届国际学习表征大会。
- 肖恩·奥布莱恩 和 迈克·刘易斯。2023 年。对比去编码提高了大型语言模型的推理能力。arXiv 预印本 arXiv:2309.09117。
- Aitor Ormazabal、Mikel Artetxe 和 Eneko Agirre。2023 年。[CombLM: 通过小型微调模型适应黑箱语言模型](#)。发表于 2023 年自然语言处理经验方法会议论文集, 第 2961–2974 页,
- 新加坡。计算语言学协会
抽动
症。
- Ajay Patel, Delip Rao, Ansh Kothary, Kathleen McKeown, 和 Chris Callison-Burch。2023. [通过提示大语言模型学习可解释的风格嵌入](#)。《计算语言学协会会议论文集: EMNLP 2023》, 第 15270–15290 页, 新加坡。计算语言学协会。
- 陈乾、辛聪、程阳、陈维泽, 苏宇生, 徐巨源, 刘志远, 孙茂松。2023. 面向软件开发的交互式代理。arXiv 预印本 arXiv:2307.07924。
- 拉斐尔·拉法伊洛夫, 阿尔奇特·夏尔马, 埃里克·米切尔, 斯特凡诺 Ermon, Christopher D Manning, 和 Chelsea Finn。2023. 直接偏好优化: 你的语言模型实际上是一个奖励模型。arXiv 预印本 arXiv:2305.18290。
- 阿利雷扎·萨莱米, 谢舍拉·迈索尔, 迈克尔·本德尔斯基, 和哈密德·扎马尼。2023 年。《Lamp: 当大型语言模型遇上个性化》。arXiv 预印本 arXiv:2304.11406。
- Rico Sennrich、Jannis Vamvas 和 Alireza Mohammadshahi。2023. 通过源对比和语言对比解码缓解机器翻译中的幻觉和偏离目标。arXiv 预印本 arXiv:2309.07098。
- Philipp Singer, Pascal Pfeiffer, Yauhen Babakhin, Maximilian Jeblick、Nischay Dhankhar、Gabor Fodor 和 Sri Satish Ambati。2024. H2o-danube-1.8 b 技术报告。arXiv 预印本 arXiv:2401.16818。
- 双子座团队, 罗汉·阿尼尔, 塞巴斯蒂安·博尔乔吴永辉, Jean-Baptiste Alayrac, 余家辉, Radu Soricut, Johan Schalkwyk, Andrew M Dai, Anja Hauth 等人。2023. Gemini: 一系列高性能多模态模型。arXiv 预印本 arXiv:2312.11805。
- Hugo Touvron、Thibaut Lavril、Gautier Izacard、Xavier Martinet、Marie-Anne Lachaux、Timothée Lacroix、Baptiste Rozière、Naman Goyal、Eric Hambro、Faisal Azhar 等人。2023a. Llama: 开放且高效的基础语言模型。arXiv 预印本 arXiv:2302.13971。
- Hugo Touvron、Louis Martin、Kevin Stone、Peter Albert、Amjad Almahairi、Yasmine Babaei、Nikolay Bashlykov、Soumya Batra、Prajwal Bhargava、Shruti Bhosale 等人。2023b. Llama 2: 开放的基础模型和微调聊天模型。arXiv 预印本 arXiv:2307.09288。Lewis Tunstall、Edward Beeching、Nathan Lambert,
- Nazneen Rajani、Kashif Rasul、Younes Belkada、Shengyi Huang、Leandro von Werra、Clémentine Fourrier、Nathan Habib 等人。2023 年。Zephyr: 语言模型对齐的直接蒸馏。arXiv 预印本 arXiv:2310.16944。

万凡琦, 黄新亭, 蔡登, 全晓军, 魏碧, 史书铭. 2024. [大语言模型的知识融合](#)

王亮, 南阳, 黄晓龙, 杨林君, Rangan Majumder 和 Furu Wei. 2023a. 利用大型语言模型改进文本嵌入. arXiv 预印本 arXiv:2401.00368.

王学志, 周丹尼. 2024. [思维链无提示推理](#)

王亚清, 姜杰谱, 张明阳, 程李一亮, 梅巧珠, 迈克尔·本德尔斯斯基. 2023b. 使用大型语言模型的个性化文本生成自动评估. arXiv 预印本 arXiv:2310.11593.

王一中, Yeganeh Kordi, Swaroop Mishra, Al-Isa Liu, Noah A. Smith, Daniel Khashabi, 和 Hannaneh Hajishirzi. 2023c. [自我指导: 通过自我生成的指令对齐语言模型](#). 《第 61 届计算语言学协会年会论文集 (第 1 卷: 长篇论文)》, 第 13484–13508 页, 加拿大, 多伦多. 计算语言学协会.

安娜·韦格曼、马里恩·施拉格恩和董阮. 2022 年. [相同作者还是仅仅相同主题? 面向内容无关的风格表示](#). 《第七届自然语言处理表示学习研讨会论文集》, 第 249–268 页, 爱尔兰都柏林. 计算语言学协会.

赖伟, 江子豪、黄伟然、李超 Sun. 2023. Instructiongpt-4: 用于微调 minigpt-4 的 200 条指令范例. arXiv 预印本 arXiv:2308.12067.

杰森·韦斯顿和赛因巴亚尔·苏赫巴塔尔. 2023. 系统 2 注意力 (这也是你可能需要的东西). arXiv 预印本 arXiv:2311.11829.

Tong Wu、Ashwinee Panda、Jiachen T Wang 和 Prateek Mittal. 2023. 面向大型语言模型的隐私保护上下文学习. arXiv 电子预印本, 页码 arXiv–2305.

夏鹤明, 杨哲, 董庆修, 王佩怡, 李勇奇, 葛涛, 刘天宇, 李文杰, 隋志方. 2024. 解锁大语言模型推理中的效率: 投机性解码的综合调研. arXiv 预印本 arXiv:2401.07851.

肖光轩, 吉林, 韩松. 2023. 离站 - 调优: 无需完整模型的迁移学习. arXiv 预印本 arXiv:2302.04870.

宿灿, 孙清风、郑凯、耿修博、Pu Zhao, Jiazhan Feng, Chongyang Tao, 和 Daxin Jiang. 2023a. Wizardlm: 赋能大型语言模型以遵循复杂指令. arXiv 预印本 arXiv:2304.12244.

徐灿文, 郭大雅, 段南, 朱利安·麦考利. 2023b. Baize: 一个在自我对话数据上进行参数高效调优的开源聊天模型. arXiv 预印本 arXiv:2304.01196.

姚一凡, 段金浩, 徐凯迪, 蔡元方, Eric Sun 和 Zhang Yue. 2023. 大型语言模型 (LLM) 安全性和隐私的调查: 好的、坏的和丑的. arXiv 预印本 arXiv:2312.02003.

张超宁, 张晨爽, 郑胜, 余桥, 李承浩, 张梦春, 苏米特·库马尔·达姆, 朱·缅特·荏瓦尔, 叶林顿, 乐朗辉, 等. 2023a. 关于生成式人工智能 (AIGC) 的完整综述: 从 GPT-4 到 GPT-5 的 ChatGPT 是否就是你所需要的一切? arXiv 预印本 arXiv:2303.11717.

张汉青, 宋浩林, 李少宇, 周明, 以及宋大卫. 2023b. 《使用基于变压器的预训练语言模型进行可控文本生成的调查》. ACM 计算机评论, 56(3):1–37.

张凯言, 丁宁, 齐碧青, 朱学凯, 辛-魏龙, 周博文. 2023c. [CRaSh: 聚类、移除与共享在无需完整大语言模型的情况下增强微调](#). 收录于 2023 年自然语言处理实证方法会议论文集, 第 9612–9637 页, 新加坡. 计算语言学协会.

张培元、曾光涛、王天多和魏璐. 2024. Tinyllama: 一个开源的小型语言模型. arXiv 预印本 arXiv:2401.02385.

徐周, 金竹卢, 陶桂, 若天马, 费子初, 王宇然, 丁勇, 张一博, 张琪, 和 黄轩晶. 2022. [TextFusion: 通过令牌融合实现隐私保护的预训练模型推理](#). 载于《2022 年自然语言处理实证方法会议论文集》, 第 8360–8371 页, 阿布拉比, 阿拉伯联合酋长国. 计算语言学协会.

周欣、易路、马若天、归涛、王雨然、Yong Ding, Yibo Zhang, Qi Zhang, 和 Xuanjing Huang. 2023. [TextObfuscator: 通过混淆词表示使预训练语言模型成为隐私保护者](#). 载于《计算语言学协会会议论文集: ACL 2023》, 第 5459–5473 页, 加拿大多伦多. 计算语言学协会.

数据集详情

A.1 上下文感知指令

构建上下文感知指令的四个步骤如下。

群体画像。我们首先从现实世界构建高度多样化的用户群体画像，涵盖大学生、程序员以及各种其他职业等广泛群体。对于每个群体，我们定义其年龄范围，确定其专业领域或职业，并列举典型活动和爱好，以捕捉该群体的独特兴趣。此外，我们还描述这些群体可能在何种具体场景中使用 AI 助手进行个性化和创意文本生成，无论是在工作还是个人生活中。这类使用场景的示例包括撰写商务邮件、撰写创意博客、撰写学术论文以及创作长篇推文。

用户档案。在建立了多样化的用户群体画像的基础上，我们接下来开发具有丰富细节的个人用户档案。强调一致性和真实性，我们的流程包括四个步骤：1) 个人写作风格：针对每个角色量身定制独特的语言使用和表达方式。2) 私人信息：为每个档案创建 5-10 个虚构细节，包括生活事件和技术互动。3) 智能设备使用：为每个档案生成 5-10 条虚构活动记录，涵盖消息、购买、日程等。我们的目标是为各种 AI 写作应用塑造独特、多维的角色。

写作任务说明。在此阶段，我们为角色设计文本创作任务，确保与他们的职业、爱好和生活方式保持一致。这些任务与他们的手机活动记录和个人信息密切相关，将角色的经历、社交媒体活动和 AI 助手互动融入叙事中。对于每个角色，我们开发一个既真实又符合情境的任务。

个性化生成。在这里，我们根据特定的指导方针生成个性化文本。我们的重点是创作真实且连贯的叙述，生动地反映每个角色的职业和个人生活。通过适应用户独特的写作风格，我们旨在创造个性化且具有风格特色的内容。为了确保在各项任务中的连贯性和相关性，每项任务的内容都是按顺序生成的。

按照这四个步骤，我们利用 GPT-4 创建带有用户上下文和响应的指令，以用于后续实验。

A.2 LaMP 数据集处理

为了在 LaMP 6 中的 Avocado Research Email 和 Citation Network Papers 数据集里最小化目标内容与用户简介之间的个性化差距，我们实现了一个两步处理方法。首先，我们使用 `intfloat/e5-mistral-7b-instruct` 嵌入（Wang 等，）检索与用户简介最匹配的内容。随后，我们使用风格嵌入（Wegmann 等，；Patel 等，）对目标内容和整个简介进行编码，仅选择最具个性化的样本。此外，LaMP 中样本的内容长度和简介差异显著，范围从 10 到 100,000 个标记，超过了现代模型的上下文长度能力。因此，我们选择了论文摘要长度最少为 128 个字符、电子邮件正文长度最少为 64 个字符，且两者的最大长度均为 1024 个字符的样本。

A.3 数据集统计

最终处理数据集的统计结果列于表。

Dataset	Context-aware	Avocado Emails	Paper Abstracts
Total Users	1736	N/A	N/A
Avg Profile Length	1182	618	1000
Output Length	155	178	158
Train Samples	1346	1,137	1,448
Dev Samples	150	127	161
Test Samples	240	346	357

Table 5: The table presents the statistics of constructed dataset and public datasets.

我们的合成指令数据集包括多种类型的指令，例如准备演讲、设计计划等。所有这些任务都要求模型利用个人上下文信息，包括以前的活动和日程安排。为说明这一点，我们展示了在构建的数据集中最常见的前 10 个根动词和前 10 个直接名词对象，如图所示

⁶<https://lamp-benchmark.github.io/download>
⁷<https://github.com/openai/tiktoken/>

Verb	Percent (%)	Verb	Percent (%)
write	19.4	post	24.0
draft	16.0	article	13.8
compose	13.9	speech	12.5
create	11.5	proposal	10.2
develop	8.7	guide	7.2
prepare	8.2	series	4.4
craft	6.3	piece	4.7
curate	4.5	plan	3.2
design	2.1	outline	3.0
script	2.0	email	2.8

Table 6: The top 10 most common root verbs and top 10 direct noun objects in our constructed datasets.

B 型号详情

对于所有开源的大型语言模型，我们使用 vLLM 进行高效推理，设置温度为 0.7，top-p 为 0.9，最大新生成的 token 数为 1024。

关于小型语言模型（SLMs）的专门化，我们在不同的模型和数据集上应用了一系列学习率 {5e-6, 8e-6, 1e-5, 2e-5, 5e-5}。此外，我们实施了早停策略，根据验证性能确定最佳模型作为专门化模型。我们使用批量大小为 8、最大序列长度为 4096，在四块 A6000 48GB GPU 上对每个模型进行微调。

对于组合模型，我们采用一个三层神经网络，使用 ReLU 激活函数，并应用 sigmoid 激活函数来确定最终权重。在每个生成步骤中，仅使用来自 LLM 和 SLM 的前 10 个 logits。中间隐藏层的大小分别配置为 512 和 16。模型使用学习率 2e-3 和批量大小 2 进行训练。组合模型在训练数据集上进行训练，LLM 和 SLM 均分配相同的目标响应。此外，还采用基于验证集性能的提前停止策略来选择最佳组合模型。对于上述所有实验，我们使用三个不同的随机种子计算平均得分。

C 评估详情

由于评估相关的成本，我们仅评估部分测试样本。为了考虑 GPT-4 评估的稳定性，我们绘制了一条曲线，说明评分与评估样本数量之间的关系。如图所示




图 7：此图说明了 GPT-4 作为评审的评估一致性和稳定性。

在图 中，一旦样本数量达到 100，结果就会稳定。因此，我们从测试集中随机选择了 100 个样本，其中只有 80 个样本被用于广泛认可的基准测试 MT-Bench。

D 提示详情

用于查询大型语言模型（LLM）的提示，包括有上下文和无上下文的提示，列在表 中。用于提取大纲的提示示例见表 中。用于基于 GPT-4 的评估的提示如表 所示。

相关工作

E.1 遵循指令与隐私

大型语言模型（LLM）在经过高质量指令数据的训练并校准以符合人类意图后，已经获得了在一系列活动中执行指令的能力，例如创意写作（Franceschelli 和 Musolesi, 2023）、编程（Qian 等, 2023）、调试（Jimenez 等, 2023）以及各种其他基于文本的任务（Bubeck 等, 2023）。当代关于指令遵循的研究优先考虑高质量数据的获取（Wang 等, 2023c），这些数据涵盖了不同复杂度（Xu 等, 2023a）和多样性（Ding 等, 2023；Cui 等, 2023）的指令，同时确保最小化数据集规模以实现有效的泛化（Chen 等, 2023a；Wei 等, 2023）。得益于这些技术进步以及对齐算法（Rafailov 等, 2023），具有约一百亿参数的中等规模语言模型已被开源，并且在执行指令方面表现出色。

⁸<https://github.com/vllm-project/vllm>

⁹<https://huggingface.co/spaces/lmsys/mt-bench>

尽管如此，像 ChatGPT、GPT-4、Claude 和 Gemini 这样的顶级聊天模型仍然是专有的，这在很大程度上是出于商业考虑，因此我们的指令数据必须上传到云端 (Achiam 等 Team 等)。虽然这些模型在日常专业和个人事务中作为强大的人工智能助手，但它们也带来了显著的隐私风险 (Liu 等)。为了解决隐私问题，大型语言模型采用了各种技术 (Cummings 等)，包括文本清理 (Kan 等)、差分隐私 (Chen 等 Wu 等) 和隐藏表示 (Zhou 等 <b67)

此外，当前的指令数据集主要涵盖通用领域，对上下文信息建模的关注不足。最相关的工作涉及个性化响应生成，其发展源自传统基准 (Salemi 等, 2023; Wang 等, 2023b)。将大量上下文信息整合到通用开放域指令中仍然是一个持续探索的领域。本文旨在探讨上下文感知的指令制定，以推动在指令遵循领域中对隐私考虑的研究。

E.2 混合规模模型合作

语言模型中的“规模定律”假设参数数量更多的模型具有更强的能力 (Kaplan 等, 2020)。然而，这些更强大的模型也面临与更高的推理成本、效率 (Xia 等, 2024) 以及隐私问题 (Yao 等, 2023) 相关的挑战。相反，参数数量在 10 亿到 20 亿之间的小型模型由于其越来越令人印象深刻的性能而受到欢迎 (Bai 等, 2023; Gunasekar 等, 2023; Zhang 等, 2024; Grangier 等, 2024; Singer 等, 2024)。这些专用模型具有更低的推理成本，并且可以在消费者级桌面电脑和智能手机上部署 (MLC 团队, 2023)。混合规模模型之间的协作代表了一条有前景的研究途径。目前该领域的研究主要分为两类：训练和推理。在协作训练方面，已经提出了离线微调 (Offsite-tuning) 作为一种方法来原型化

涉及使用源自大语言模型 (LLMs) 的模拟器，对其在特定下游数据上进行微调，并随后将学到的参数整合回 LLMs。在推理方面，诸如推测解码 (Leviathan 等 Xia 等) 和对比解码 (Li 等 O’ Brien 和 Lewis) 等技术旨在通过利用较小的草稿模型或专家模型来增强和加速 LLMs 的推理过程。此外，模拟器微调 (Mitchell 等) 和代理微调 (Liu 等) 已被设计用于节省大模型的微调成本；然而，它们也可以被视为推理过程中的一种协作解码形式。本文重点研究推理过程中的协作，具体

SYSTEM PROMPT FOR REQUEST WITHOUT CONTEXT

You are now a helpful personal AI assistant. Aim for insightful and high-quality solutions that make users satisfied.

SYSTEM PROMPT FOR REQUEST WITH CONTEXT IN CONTEXT-AWARE

You are now a helpful personal AI assistant. You should emulate the author's style and tone based on provided history content. Your responses should be detailed and informative, using the personal information reasonably in the user's profile. Aim for insightful and high-quality solutions that make users satisfied.

SYSTEM PROMPT FOR REQUEST WITH CONTEXT IN PERSONALIZED EMAILS AND PAPERS

You are now a helpful personal AI assistant. You should emulate the author's style and tone based on provided history content. Your responses should be detailed and informative, matching the author's unique writing approach. Aim for insightful and high-quality solutions that make users satisfied.

FEW-SHOT INSTRUCTION FOR REQUEST WITH CONTEXT IN CONTEXT-AWARE

User Profile
{profile}

User Writing History
{history}

Task
{task}

FEW-SHOT INSTRUCTION FOR REQUEST WITHOUT CONTEXT IN CONTEXT-AWARE

{task}

FEW-SHOT INSTRUCTION FOR REQUEST WITH CONTEXT IN PERSONALIZED EMAILS

History Emails
{examples}

Task
Compose an email for the subject '{task}' that matches the author's unique style and tone.

FEW-SHOT INSTRUCTION FOR REQUEST WITHOUT CONTEXT IN PERSONALIZED EMAILS

Compose an email for the subject '{task}'

FEW-SHOT INSTRUCTION FOR REQUEST WITH CONTEXT IN PERSONALIZED PAPERS

History Paper Abstracts
{examples}

Task
Compose an abstract for the title '{task}' that matches the author's unique content, style and tone.

FEW-SHOT INSTRUCTION FOR REQUEST WITHOUT CONTEXT IN PERSONALIZED PAPERS

Compose an abstract for the title '{task}'

表 7: 帶上下文和不帶上下文查詢大型語言模型的提示。

用于提取上下文感知大纲的提示。

你是一个组织者，负责仅提供回答问题的骨架（而不是完整内容）。将骨架以编号要点（1.、2.、3.等）形式提供，以回答问题。每个骨架点不写完整句子，每点应非常简短，仅3-5个词。通常，骨架应包含8-15个要点。你可以参考以下示例：

任务：为您的每月晚宴制定营销脚本：创建一个脚本，突出您的每月晚宴作为一个社交网络平台。

框架：1. 温暖灯光的餐厅 2. 精美陶瓷餐具和美食佳肴 3. 柔和的音乐背景 4. 邀请开场 5. 嘉宾到场及交流 6. 主持人欢迎致辞 7. 精心搭配的菜品与美酒 8. 嘉宾热烈讨论 9. 特邀嘉宾演讲 10. 晚餐后的交流休息区 11. 在线社区延续 12. 下次活动日期突出显示 13. 以徽标和联系信息结束

[Task2]: Comp 写一篇关于桥梁设计演变的反思性文章：托马斯凭借他在桥梁设计方面的专利，可以讨论桥梁工程、现代的挑战以及未来的展望。
evolution of bri

大纲：1. 桥梁简介 2. 早期桥梁：材料、原理 3. 罗马拱桥、混凝土的使用 4. 工业革命：铁、钢 5. 布鲁克林大桥：设计标志 6. 20 世纪的进展：材料、技术 7. 现代挑战：可持续性、气候 8. 未来技术：智能材料、传感器 9. 道德考虑、安全 10. 结论：适应与进步

现在，请为以下问题提供提纲。{question}

提取电子邮件大纲的提示。

你是一个组织者，负责仅提供回答问题的骨架（而不是完整内容）。将骨架以编号要点（1.、2.、3.等）形式提供，以回答问题。每个骨架点不写完整句子，每点应非常简短，仅3-5个词。通常，骨架应包含8-15个要点。你可以参考以下示例：

任务：撰写主题为“T-Mobile Sidekick 首发，FileMaker 推出移动数据库，及更多！”的电子邮件 骨架：1. JavaWorld 技术小贴士引言 2. T-Mobile Sidekick 首发 3. FileMaker 移动数据库发布 4. Palm OS 5 设备发布 5. 移动安全进展 6. 通讯系统更新 7. 客户服务指南 8. JavaWorld 团队签名 9. 编辑与广告联系方式 10. 隐私政策提示 11. 版权声明

任务：撰写一封主题为“tomcat4, servlet.jar 设置在哪儿???”的电子邮件

骨架：1. Tomcat 4 servlet.jar 文件位置？ 2. 浏览 Tomcat 目录。 3. Tomcat 4 的规格说明。 4. 设置 web 应用程序。 5. Servlet 的重要性。 6. 文档探索。 7. 请求专家建议。 8. 配置文件设置？ 9. 感谢与期待。 10. 附言：合作的价值。

现在，请为以下问题提供提纲。{question}

提取论文大纲的提示。

你是一个组织者，负责仅提供回答问题的框架（而不是完整内容），从高层次角度。以编号列表的形式提供框架（1. 2. 3.等）来回答问题。每个框架点不要写完整句子，每个点只用几个字。通常，框架应包含8-15个点。你可以参考以下示例：

任务：为标题《用于迁移学习的锚点适配器集成》撰写摘要

骨架：1. 迁移学习的重要性 2. 传统方法的局限性 3. 锚点适配器的集成介绍 4. 锚适配器概念 5. 鲁棒性的集成策略 6. 混合损失函数的制定 7. 异构领域的实验 8. EAA 优于最新技术 9. 新颖的可迁移性指标介绍 10. 贡献：集成与领域适配的结合

任务：为标题《软件架构中的可变性：前进的道路》撰写摘要

骨架：1. 软件架构演化 2. VARSA 研讨会介绍 3. 以往工作的基础 4. 挑战与机遇 5. 主旨演讲、研究、合作 6. 捕捉和利用可变性 7. 认知与技术负担 8. 可变性对质量的影响 9. 生命周期集成 10. 研究议程提案 11. 跨学科对话 12. 工具、技术、理论进展 13. 战略方向路线图 14. 会议的本质与目标

现在，请为以下问题提供提纲。{question}

表 8：用于提取大纲的提示。

评估指导生成内容整体质量的说明。 说明

请作为一个公正的评估者，评估 AI 助手对下列用户问题的回答质量。你的评估应重点关注回答与用户个性化资料和写作历史的匹配程度。评估因素包括回答是否遵循用户的个人风格、是否与其资料一致、是否有帮助、相关性、准确性、深度、创造力以及细节程度。开始评估时请提供简短说明，并尽量保持客观。提供说明后，你必须按照以下格式对回答进行评分（1 到 10 分）：“ 评分 ”，例如：“评分： ”。

用户资料和写作历史 {profile_info} {writing_history}

[Question]
{question}

助手回答的开始 {answer}
助手回答的结束

评估值指导：对未使用档案的生成内容整体质量进行评估 指令

请充当一名公正的裁判，并评估 AI 助手对下面显示的用户问题所提供回答的质量。您的评估应考虑回答的有用性、相关性、准确性、深度、创造性以及细节程度等因素。请在评估开始时提供简短的解释，并尽量保持客观。在提供解释之后，您必须按照严格的格式对回答进行 1 到 10 分的评分：“ 评分 ”，例如：“评分： ”。

[Question]
{question}

助手回答的开始 {answer}
助手回答的结束

评估我确保生成内容与个人资料一致的说明 struction

E.

[Ins
请充当一名公正的裁判，根据 AI 助手的回应与用户个人资料和写作历史的契合程度进行评估。重点评估回应的个性化方面，包括其是否遵循用户独特的风格、偏好，以及是否与用户资料一致。考虑回应多大程度上满足用户的个人需求和兴趣。开始评估时，请先提供简短的说明，并尽量保持客观。在提供说明后，您必须按照以下格式严格对回应进行评分：“ 评分 ”，例如：“评分： ”。

[User Profile and Writing History]
{profile_info}
{writing_history}

[Question]
{question}

[The Start of Assistant's Answer]
{answer}
[The End of Assistant's Answer]

表 9：用于基于 GPT-4 的评估的提示。