

边缘 SLM 和云 LLM 之间的协作推理和学习：算法、执行和开放挑战的调查

李森耀，中国华中科技大学计算机科学与技术学院王浩照，华中科技大学计算机科学与技术学院徐文超，中国香港科技大学集成系统与设计系张锐，华中科技大学计算机科学与技术学院宋果，中国香港科技大学计算机科学与工程系袁静玲，武汉理工大学交通物联网湖北省重点实验室 钟先，武汉理工大学交通物联网湖北省重点实验室

张天伟，新加坡南洋理工大学计算与数据科学学院李瑞轩，华中科技大学计算机科学与技术学院，中国

随着大语言模型 (LLM) 的发展，由于对延迟、隐私、成本和个性化的担忧，仅在云中部署它们或为边缘设备压缩它们已经不够了。这项调查探索了一种协作范例，其中基于云的 LLM 和边缘部署的小语言模型 (SLM) 在推理和训练方面进行合作。我们提出了边缘云协作策略的统一分类。为了进行推理，我们在任务和令牌粒度上将方法分类为任务分配、任务划分和基于混合的协作，包括自适应调度、资源感知卸载、推测性解码和模块化路由。对于训练，我们回顾了分布式自适应技术，包括参数对齐、修剪、双向蒸馏和小模型引导优化。我们进一步总结了数据集、基准测试和部署案例，并重点介绍了隐私保护方法和垂直应用。这项调查为 LLM-SLM 协作、桥接系统和算法协同设计提供了第一个系统基础，以实现高效、可扩展和值得信赖的边缘云智能。

CCS 概念： • 计算方法→分布式人工智能；神经网络；嵌入式和网络物理系统；云计算。

• 计算机系统组织 →

Authors' Contact Information: Senyao Li, School of Computer Science and Technology, Huazhong University of Science and Technology, Wuhan, China; Haozhao Wang, School of Computer Science and Technology, Huazhong University of Science and Technology, Wuhan, China; Wenchao Xu, Division of Integrative Systems and Design, Hong Kong University of Science and Technology, Hong Kong, China; Rui Zhang, School of Computer Science and Technology, Huazhong University of Science and Technology, Wuhan, China; Song Guo, Department of Computer Science and Engineering, Hong Kong University of Science and Technology, Hong Kong, China; Jingling Yuan, yjl@whut.edu.cn, Hubei Key Laboratory of Transportation Internet of Things, Wuhan University of Technology, Wuhan, China; Xian Zhong, zhongx@whut.edu.cn, Hubei Key Laboratory of Transportation Internet of Things, Wuhan University of Technology, Wuhan, China; Tianwei Zhang, College of Computing and Data Science, Nanyang Technological University, Singapore; Ruixuan Li, rxli@hust.edu.cn, School of Computer Science and Technology, Huazhong University of Science and Technology, Wuhan, China.

1 简介

大语言模型 (LLM) [139-142] 在广泛的自然语言处理任务中表现出了卓越的熟练程度。然而，它们大量的计算和内存需求使得在资源受限的边缘设备上部署变得令人望而却步[24,25,187]。随着大数据、云计算和边缘计算的快速发展，边云协同智能已成为释放数据价值和提供无处不在的人工智能的有前景的范例[35,55,163,255]。这种范例将云的计算能力和泛化能力与边缘的响应能力和适应性结合起来[5, 176]。

我们不仅仅压缩边缘部署的大型模型，而是专注于跨基于云的 LLM 和边缘部署的小语言模型 (SLM) 的架构、算法、执行和隐私的系统协同优化 [232,233,235,236]。通过利用功能共享、任务划分和知识转移，LLM 和 SLM 协作在异构环境中提供高效、可靠的智能服务 [224-226]。现有的以云为中心的方法利用集中式大语言模型来实现强泛化，但会带来高延迟、隐私风险和对本地环境的适应性较差[57,197,247]。相比之下，以边缘为中心的方法提供快速响应和个性化，但受到设备上计算和通用性的限制[25,118,237-239]。之前的调查已经研究了以云为中心、以边缘为中心和设备到设备的协作范例，但每种范例在实际部署中都面临着关键限制[162]。LLM-SLM 协作范例通过实现大型云模型和小型设备上模型之间的分层协作来统一这些优势 [6, 14]。

与联邦学习 [47, 279] 或模型压缩 [20] 不同，这种方法将 LLM 和 SLM 视为不同但交互式的代理 [72, 261]，从而在边缘云连续体中实现更加动态和模块化的协作。然而，实现这一愿景在推理和训练方面都面临着一些挑战。从推理角度来看，LLM和SLM之间的架构异构使得统一调度和部署变得复杂；不同的任务粒度、资源预算和延迟限制使得协调模型执行变得困难[228, 230]；网络不稳定性限制了模型之间的高频交互[21]，例如模型交换[22]或交叉注意力融合，这对于维持语义一致性和响应能力至关重要。在训练方面，数据分布[23]、任务表述和模型架构的异质性阻碍了有效的知识转移，特别是对于假设结构或目标对齐的蒸馏和适应方法。此外，非独立同分布边缘数据的盛行 [159, 279] 以及个性化模型行为的需求加剧了这个问题，因为局部微调可能导致过度拟合，而集中更新则有可能稀释关键的边缘特定或因果相关模式 [11, 71]。这些相互交织的因素共同强调需要对异构模型之间的协作学习和推理框架进行更有原则的设计。

这些限制催生了专用的 LLM-SLM 协作框架，该框架具有结构感知、分布式稳健性，并且能够在动态、资源受限的条件下提供高效、可靠和通用的情报。

2021年，阿里巴巴达摩院和浙江大学进行了首次大规模的云边协同调查[262]，确定了三种协同范式。2022年，阿里巴巴十大技术趋势强调“云端大模型与边缘小模型的共同进化”，强调智能、隐私感知的终端服务[242]。高通在 2023 年发布了混合 AI 白皮书 [243, 245] 呼应了这一点，提倡在 LLM 和 SLM 之间进行智能工作负载划分，以解决延迟、效率、隐私和个性化问题。这些发展反映了从集中式大语言模型管道向混合边缘云架构的转变，并得到新兴工业规模框架的支持。Walle [264] 提供了一个用于开发、部署和运行时的端到端系统，支持跨 300+ 任务的云边缘协作，每日调用次数超过 100 亿次，通过轻量级边缘推理引擎支持个性化推荐、多模式理解和实时 3D 渲染。Luoxi [265]采用“慢-快”学习策略，其中云大语言模型生成潜在表示，以协助在边缘设备上实时进行快速、个性化的推理




图 1. 云边协作工作流程概述：(a) 训练和 (b) 推理。

反馈。InfiGUIAgent [266]通过两阶段微调演示了多模式场景中 GUI 交互的分层边缘推理。现实世界的应用进一步强调了这种范式的必要性：在视觉和图形领域（城市视频分析[184]、自动驾驶[55, 56]、XR）、语言任务（虚拟助手[240, 241]、输入方法、对话代理）以及个性化推荐[30, 63, 221]。边缘智能还扩展到多模式和基于传感器的领域，例如医疗诊断[225]、智能家居[204]和工业监控，其中能源效率和响应能力至关重要。这些学术和工业界的努力共同凸显了云边缘 LLM-SLM 协作的技术可行性和实际紧迫性，激发了对现有范式、系统设计和开放挑战的全面调查。

1.1 相关调查及其范围

徐等人。[25]首次系统概述了整个 AIGC 服务生命周期，从数据收集和训练到推理，并提出了用于移动网络的协作云边基础设施。曲等人。[4]回顾移动网络边缘的 LLM 部署，强调资源高效技术、架构设计和边缘 LLM 缓存。相比之下，徐等人。[246]优先考虑系统级优化，例如模型压缩和令牌修剪，以加速推理并提高部署效率。对于任务卸载和资源分配，Wang 等人。[250]对移动云卸载中的任务迁移进行建模，而[249]将强化学习应用于 CETCN 场景中的调度。徐等人。[248]调查了分布式设备上的去中心化持续学习，对减轻灾难性遗忘和分布转移的三种算法策略进行了分类。在此基础上，Niu 等人。[163]从系统、算法和应用的角度全面回顾了设备侧小模型和基于云的大模型之间的协作学习机制。在沟通受限的情况下，Zhang 等人。[24]提出了空地协同推理策略，Lin 等人。[187]引入了用于 6G 网络中自然语言任务的多代理 LLM 框架。陈等人。[162]系统地总结了 LLM-SLM 协作范例、流水线、路由、蒸馏和融合，作为高效、自适应智能系统的基础策略。现有的调查往往狭隘地关注系统部署或孤立的技术（例如蒸馏、管道），并且缺乏统一的算法




图 2. 大型边缘云和 SLM 之间的协作范例概述，沿两个轴构建：推理协作和训练协作。

对协作大小模型训练和推理的看法。至关重要的是，没有一个将协作抽象到结构化设计空间中，也没有提供捕获边缘云设置中异构模型之间的功能角色和交互边界的分类法。

相比之下，这项调查首次全面审查了大语言模型和 SLM 之间的推理时间协作和训练时间协调。如图1和表1所示，我们提出了协作范式的统一分类，包括任务分配、任务划分和混合（具有任务级和令牌级粒度），并分析它们与算法原理和系统约束的一致性。在训练方面，我们总结了协作适应方法，包括双向蒸馏、量化、剪枝和低秩近似，这些方法有助于在不牺牲性能的情况下高效部署 SLM。这项调查特别强调大语言模型和 SLM 之间跨边缘和云环境的交互。通过共同分析推理和训练阶段的协作，我们的审查将算法设计和部署需求联系起来，为未来的边缘云 LLM 系统提供方法论见解和实际影响。此外，我们的讨论以 2023 年以来发表的最新文献为基础，确保覆盖范围和相关性。通过共同解决推理和训练维度，我们的调查填补了一个关键的方法论空白，并建立了一个在异构、资源受限的环境中设计大小模型合作的通用框架。

1.2 研究问题和调查结构

本调查系统回顾了大型 SLM 的边云协作推理和训练的发展、挑战和未来方向。我们围绕以下核心研究问题（RQ）组织讨论：

表 1. 本次调查与相关评论的比较

Reference	Scope	Focus Area	Distinguishing Features
Xu <i>et al.</i> [25]	AIGC service lifecycle	Mobile network infrastructure design	Proposes end-cloud-edge architecture; omits model-level 推理推理 collaboration.
Xu <i>et al.</i> [246]	LLM system deployment	推理 optimization (compression, pruning)	Emphasizes hardware/system acceleration; ignores LLM-SLM interaction logic.
Wang <i>et al.</i> [249, 250]	Mobile-cloud 任务卸载	Scheduling and resource allocation	Models 卸载 strategies via RL; does not address 协同推理-协同推理.
Xu <i>et al.</i> [248]	Decentralized continual learning	Distributed algorithmic adaptation	Surveys lifelong learning; lacks explicit LLM-SLM collaboration structure.
Niu <i>et al.</i> [163]	LLM-SLM collaborative training	System, algorithm, application layers	Reviews collaborative training; does not cover 推理 across modalities/tasks.
Zhang <i>et al.</i> [24, 187]	LLMs in constrained networks (6G)	Multi-agent and aerial-ground collaboration	Focuses on special network conditions; proposes communication-specific 推理-推理 strategies.
Chen <i>et al.</i> [162]	LLM-SLM collaboration mechanisms	Pipelining, routing, distillation, fusion	Summarizes interaction methods; lacks a unified algorithmic design space for 推理.
This Survey	Heterogeneous LLM-SLM collaboration	推理 and training algorithms	First to cover end-cloud 协同推理 (task assignment/division/mixture) and training (parameter fusion, knowledge transfer).

- RQ1 什么是大模型、小模型的边云协同推理范式？它的基本概念和系统架构是什么？我们专注于基本范式、协作角色和系统级设计。
- RQ2 边云推理的主要范式和协作模式是什么？我们涵盖任务调度、任务和令牌级别的混合合作以及推测解码。检查协作如何减少延迟、适应不确定性并提高效率。
- RQ3 为什么以及如何研究边云环境中大小模型之间的协同训练？我们探讨了异构下训练协作的必要性，总结了蒸馏、模块化调整和跨设备适应的参数对齐等范式。
- RQ4 为什么在边缘云协作的背景下审查基准、隐私保护方法和垂直应用程序很重要？我们解决公平的评估标准、训练和推理中的隐私挑战以及现实世界领域的实际要求。

如图 2 所示，我们的调查结构如下：

- 1.3 节介绍了边缘云与大型模型和 SLM 协作的基础知识，涵盖系统架构、边缘设备约束以及大型模型开发的趋势（解决 RQ1）。
- 第 2 节研究任务分配和推理策略，重点是动态调度和草稿细化验证框架，说明边缘和云模型如何协作且高效地执行推理（解决 RQ2）。
- 第 3 部分调查了云边缘训练架构和部署策略，包括量化、修剪、参数高效微调和双向知识传输，以支持高效的 SLM 部署而不牺牲性能（解决 RQ3）。
- 第 4 节 - 第 5 节总结了基准、评估指标和特定领域的部署，以促进模型比较和实际实施，并强调普遍性、隐私、可持续性和多代理协作等开放挑战（解决 RQ4）。
- 第六部分总结了主要见解和未来的研究方向。

1.3 相关概念和基础

1.3.1 大语言模型的定义和特点。大语言模型通常指的是具有数十亿到数万亿参数的基于变压器的架构。这些模型使用自回归学习（例如 GPT [141, 240]）或屏蔽语言建模（例如 Qwen [235]、DeepSeek [289]）等策略在大规模语料库上进行预训练。在架构上，LLM 堆叠了数十到数百个转换器块，每个块都包含多头注意力、前馈层、残差连接和归一化。随着规模的扩大，大语言模型表现出新兴的能力，例如符号推理、指令遵循和多模式理解，这些能力不随参数数量线性扩展。在边缘云协作中，由于计算和内存需求密集，大语言模型通常由云托管。在提供强大的泛化能力和跨任务的零/少镜头传输的同时，它们也带来了巨大的通信开销，因为每个推理通常需要多次云交互，从而增加了延迟和带宽负载。此外，它们的训练和微调涉及较高的 I/O 成本和较差的设备适应性，限制了它们在实时或隐私敏感的边缘场景中的使用。

1.3.2 SLM 的定义和特征。SLM 通常包含数百万到数亿个参数，专为资源受限的环境而构建，同时保留核心语言建模能力。它们通过更浅的变压器堆栈、更小的隐藏尺寸和更少的注意力头来简化架构，从而大大减少内存和功耗，从而实现在移动设备、微控制器和边缘节点上的高效部署。SLM 强调响应能力和本地可用性，而不是广泛的推理。尽管他们缺乏大语言模型的应急能力，但他们在智能输入、离线助手和嵌入式系统等特定环境任务中表现良好。通过知识蒸馏、LoRA 微调和指令调整，SLM 可以在窄域中逼近 LLM 输出，同时保持低延迟和数据局部性。在协作设置中，它们充当第一响应代理或草稿生成器，仅在需要时将复杂的推理卸载给云大语言模型，从而优化通信成本和模型效率。

1.3.3 硬件架构和应用场景的互补。云边缘 LLM-SLM 协作的基础源于硬件驱动的能力划分：云服务器利用多 GPU 集群（例如 NVIDIA H100）和高带宽互连（NVLink/RoCE）来运行万亿参数模型（例如 LLaMA-3 405B）以进行复杂推理和全局数据处理 [193]，而资源受限的边缘设备则涵盖智能手机（6-16GB RAM）、XR 耳机和嵌入式系统（例如 Jetson Orin），部署十亿参数的 SLM（例如 TinyBERT [157]）来执行延迟关键型任务（<10ms 响应）和本地数据优化 [192]。这种架构上的互补性实现了分层任务分配：SLM 执行实时感知（关键词检测、语音转文本）、隐私敏感预处理（医疗数据匿名化）和意图过滤（客户服务准确率 90%），将复杂的生成/推理工作卸载给 LLM。

表2 云边协同推理主要范式比较

Category	Definition & Characteristics	Advantages	Limitations
Task assignment § 2.1	Routes requests to SLM or LLM based on confidence, resource, or task type.	Simple and fast; minimal communication overhead.	Hard switching may misroute uncertain inputs; lacks joint reasoning.
Task division § 2.2	Splits tasks into modules (e.g., 提前退出, routing) processed by SLM and LLM.	Supports modular, adaptive推理 with fine-grained control.	Requires explicit segmentation; incurs coordination overhead.
Mixture: Task-level § 2.3	Combines assignment and division across stages or roles via communication.	Flexible decomposition; leverages complementary strengths.	Dependent on partitioning quality and coordination efficacy.
Mixture: 词元-level § 2.4	Collaborates at 词元 generation (e.g., 推测解码 - 推测解码).	Low-latency with accurate output; efficient cloud fallback.	Sensitive to draft quality; complex fusion and validation.

知识蒸馏（TinyBERT 实现了 BERT 性能的 96% [157]）和参数高效调整（LoRA 将医疗 QA 准确性提高了 20%）等技术协同作用进一步缩小了能力差距，联合学习确保了 SLM 将匿名特征传输到云端 LLM 进行多模态融合时的隐私，从而使车载语音系统（200ms 延迟）和医疗诊断等应用的效率提高了 40%。

2 协同推理概述

边缘部署的 SLM 和基于云的 LLM 之间的协作推理旨在在带宽和响应能力限制下优化延迟和服务效率 [288]。如表 2 所示，最近的工作探索了三种互补的协作范例。值得注意的是，这里提出的分类特别关注异构模型之间的推理时间协作。尽管某些机制（例如专家混合 (MoE)）适用于推理和训练阶段，但本次调查将其范围限制在面向推理的场景。也就是说，我们总结并比较了为推理工作负载设计或主要在推理工作负载下评估的协作策略。我们从以下几个角度对现有作品进行分类和回顾：

- 任务分配，将查询路由到最合适的模型（例如，通过基于代理或 MoE 策略）；
- 任务划分，跨模型或系统组件分解执行（例如卸载、请求路由或提前退出机制）；
- 混合策略，使用推测解码和多阶段验证等技术在任务级或令牌级粒度上集成分配和划分。

2.1 任务分配：成本质量权衡的动态模型选择

任务分配决定请求是完全由边缘侧 SLM 还是基于云的 LLM 处理，这与涉及模型间交互的协作解码不同。为了最大限度地减少服务质量 (QoS) 约束下的延迟和能耗，先前的方法采用轻量级评分器、校准奖励估计器或基于老虎机的控制器来在生成之前选择最佳执行路径。一些方法进一步结合用户偏好向量或学习的模型能力表示




图 3. 边缘云系统中任务分配的比较: (a) 代理将用户指令分解为为专门代理执行的多阶段计划; (b) 通过细粒度选通基于 MoE 的顶级 k 云 LLM 专家的选择和融合。

自适应运行时路由。FS-GEN [84] 引入协作频率来量化生成任务中大小模型之间的权衡: 通过对齐输入空间并定义统一的输出融合目标, FS-GEN 测量云 LLM 干预频率主导序列的频率。从广义上讲, 任务分配策略分为三种架构范式: 资源和不确定性感知分配、基于代理的调度和专家混合 (MoE) 框架 (见图 3), 每种架构范式都反映了不同的协调粒度和模型选择理念。

2.1.1 资源和不确定性感知任务分配。为了利用异构模型, 同时尊重边缘-云容量限制 (见表3), 最近的工作探索了处理运行时不确定性、系统异构性和模型容量的多种任务分配机制: FS-GEN [34] 采用双系统架构, 其中快速但不确定的 SLM 充当系统1, 可靠的 LLM 充当系统2, 在出现歧义时调用。方等人。[10] 提出了一种反馈驱动的框架, 该框架根据运行时不确定性、模型置信度和系统状态动态调整路由决策, 避免静态阈值。EdgeLLM [66] 使用值密度优先算法按成本效益对任务进行排名, 通过自适应阈值支持抢占和批量执行。杨等人。[15] 引入细粒度的模块级分区, 将重型组件 (例如注意力、线性层) 卸载到云端, 同时保留边缘的轻量级操作。U-VPA [202] 在师生框架内采用不确定性引导采样, 有选择地上传领域信息样本以增强非平稳分布下的泛化能力。混合成本函数 [123] 识别边缘-云转换的分支点, 并在本地容错地重新执行失败的分支。叶等人。[204] 通过自动调整动态选择用于边缘部署的中间 INT8 表示。KD SL [85] 利用 LLM 通过 UCT 引导的搜索生成逻辑规则。这些规则在边缘进行验证和部署, 支持符号推理来完善云预测。

2.1.2 通过 MoE 和代理架构进行模块化协作。

基于教育部的的方法。专家混合 (MoE) 架构可在边缘云设置中实现可扩展、自适应推理。轻量级设备上 SLM 通过门控或路由网络路由查询, 以激活一组稀疏的云 LLM 专家 (见图 3), 其响应被融合以实现软分配和多样性。MoE² [18] 和 EdgeMoE [50] 使用统计先验或学习策略来指导专家路由, 以减少内存和 I/O 开销。LiteMoE [251] 通过识别和合并关键专家而无需重新培训, 进一步降低了成本。

表 3. 资源和不确定性感知任务分配策略

Reference	Key Idea	Advantage	Limitation
PerLLM [115]	Personalized scheduling with constraint satisfaction	Jointly optimizes deployment and resource usage	Complex constraint modeling
EdgeLLM [66]	Value-density-first scheduling with preemption and batching	Cost-effective, real-time task prioritization	Preemption can destabilize under dynamic loads
FS-GEN [34]	Dual-system 推理 with uncertainty-triggered LLM fallback	Latency-efficient by conditional large-model invocation	Accuracy depends on uncertainty-estimation precision
Yang <i>et al.</i> [15]	Operator-level scheduling based on compute intensity	Fine-grained control of module placement	Requires precise operator profiling
Stammiller <i>et al.</i> [123]	Hybrid cost-aware branching with fault-tolerant rollback	Reduces re-execution cost during cloud failures	Overhead in maintaining state consistency
U-VPA [202]	Uncertainty-guided sampling in a teacher-student setup	Bandwidth-efficient selection of informative samples	Needs robust domain-shift detection
Li <i>et al.</i> [125, 204]	INT8 模型切分 with automatic tuning	Efficient, low-latency dynamic deployment	Precision loss under aggressive 量化
KDSL [85]	LLM-based rule generation with feedback verification	Closed-loop correction with minimal cloud calls	Complexity in evaluating rule quality

将选择扩展到结构化，DoT [49] 使用任务分解模块和依赖图调度程序将复杂查询划分为子任务，从而实现自适应粒度和关键路径优先级。田等人。[229]提出了用于多轮对话的角色感知 MoE 路由，将片段分配给专业专家并融合输出以实现上下文丰富的生成。CoEL [272]增加了跨边缘设备的资源自适应协调，支持不同预算下的弹性部署和高效扩展。

基于代理的方法。这些方法使用模块化执行管道，其中规划代理解释指令、制定结构化计划并将子任务委托给专门代理[283]（例如助手、工具、驱动程序），以实现上下文感知、目标驱动的协调[275]。A RAG [274] 将四个代理、用户理解、自然语言推理（NLI）、上下文摘要和项目排名集成到 RAG 管道中。AgentVerse [95]部署基于边缘的协调器，根据任务意图组建云专家团队，支持水平聚合（例如投票）和垂直通信以进行复杂推理。萨尔夫等人。[198]提出了一个专门的多代理框架，其中一个中央模块协调上下文感知查询生成和多源检索。在物理接地场景中，WebAgent [230] 将 LLM 与具体的 VirtualHome 代理融合，以进行目标导向的探索和物理推理。ChatEval [228] 引入了一种辩论式框架，其中大语言模型法官可以协作评估生成质量。EcoAgent [254]实现了一个带有云规划器和两个边缘代理的闭环系统，一个用于执行，一个用于结果验证，在失败时触发重新规划。最后，MADRL 框架 [257] 支持集中式云训练和分散式边缘执行，减少多智能体强化学习 [255] 中的训练开销和推理延迟。

表 4. 协作推理范式的比较：路由、卸载、提前退出和通信优化

Paradigm	Core Innovation	Typical Scenario	Limitations
Routing and Forwarding § 2.2.1	Combines confidence, semantic planning, and contextual bandits for query routing.	Budget- or latency-constrained query routing.	Depends on accurate confidence estimates; fallback may add overhead or misroute.
计算卸载 § 2.2.2	Supports dynamic scheduling and 词元 - /layer-wise partitioning of models.	Latency-sensitive tasks under fluctuating resource availability.	Performance degrades in highly dynamic or non-stationary environments.
提前退出 § 2.2.3	Enables 词元 - or layer-level early termination via dropout and pipeline reuse.	Low-latency generation or streaming applications.	Accuracy can drop at exit points; modeling 词元 -dependent dynamics is challenging.
Communication Optimization § 2.2.4	Uses entropy compression, bandit routing, and adaptive switching to reduce transfer.	Resource-constrained settings with frequent edge-cloud interactions.	Balancing compression and semantic fidelity remains difficult; sensitive to distribution shifts.

2.2 任务划分：大小模型之间的协作子任务分解

任务划分将分层或模块化任务分解为语义或功能部分，使 LLM 和 SLM 能够联合执行互补的子任务。这种合作提高了边缘约束下的并行性和响应能力。与分类[287]不同，我们确定了边云协同推理、路由、卸载和提前退出中任务划分的三种根本不同的范式，如图4所示。每种范式都具有独特的优势，适合不同的应用场景，如表4所示。

2.2.1 路由和转发机制。基于路由的方法在推理时动态选择模型，以平衡延迟、成本和准确性：

信任和语义感知路由。这些方法使用运行时置信度估计和语义规划来进行自适应模型选择。FrugalGP T [167] 通过即时压缩和级联路由降低 API 成本。Tabi [168] 使用校准的置信度分数在轻量级模型和强大的大语言模型之间进行选择。德科宁克等人。[268]在统一框架下集成推理前和推理后质量估计，提高路由准确性和回退成功率。卡格等人。[53, 205]引入备份块预加载，以实现跨异构设备的稳健故障转移。RouteLLM [106] 分层组织模型并应用动态编程来最小化分层性能差异。

奖励和成本感知强盗路由。这些方法使用在线学习根据奖励信号和成本性能权衡来优化路由。Hybrid LLM [97]定义了质量差距并使用轻量级编码器来预测路由概率。ZOOTER [166]利用查询级奖励来选择专家。RouterDC [94] 使用双重对比损失来使查询与高性能模型保持一致。LLM Bandit [269] 引入了用于偏好条件路由的“模型身份向量”，而 MixLLM [169] 和 CITER [183] 使用上下文 bandit 来估计成本和质量。RouteT2I [165] 使用多维质量指标在边缘模型和云模型之间选择文本到图像任务。




图 4. 三种执行阶段任务划分策略的图示：(a) 请求路由，根据语义和成本将查询分派给最佳 LLM 专家；(b) 任务卸载，跨边缘和云分割计算图以实现成本感知的负载平衡；(c) 提前退出、多退出网络，提前终止简单输入以减少延迟和能量。

2.2.2 计算卸载和系统级优化。卸载根据运行时条件在设备和云之间划分推理任务：卸载不是从一开始就静态分配任务（如在路由中），而是在执行过程中做出动态的分阶段决策，根据系统容量评估当前工作负载，以最大限度地提高性能并经济高效地利用资源。我们将卸载分为两种互补的类型：

结构模型划分。该策略根据计算成本和深度，通过在选定的层或令牌阶段跨设备和边缘/云对模型进行结构性分区来分解推理[292]。ADAS [55]利用物联网（IoT）网络，提出了一种基于 DDPG 的增强型任务卸载算法，其中采用扩散模型来生成噪声并确定每个任务的最佳执行位置（即云、边缘或本地）。刘等人。[51]将较低层分配给本地设备，并将更高层的推理卸载到边缘服务器。CE-CoLLM [13] 使用令牌级别的置信度来决定本地处理哪些令牌。李等人。[125]自动选择INT8量化的中间层作为分区点。

运行时自适应调度。这组方法通过适应实时指标（例如延迟、置信度和资源可用性）动态调度卸载决策，并跨本地设备、控制单元和辅助车辆分配任务。郝等人。[12, 124] 使用设备指标和置信度分数进行细粒度控制。他等人。[52]引入基于潜在状态的无奖励政策。增强型混合推理[65]在带宽限制下结合了用户感知的实用模型。AVA [132] 结合了联邦和多智能体强化学习以实现多层分发。虽然这些方法擅长自适应、条件感知调度，但它们通常难以在高度动态或异构环境中推广。

2.2.3 提前退出。提前退出是一种混合推理范例，其中执行可以根据系统负载或模型置信度在中间层终止，从而通过动态退出决策减少计算。LITE [259] 引入了一种以置信为导向的提前退出策略，可以在不牺牲生成质量的情况下停止推理。LayersKip [130] 在 Transformer 层上应用逐渐增加的层丢失和提前退出损失，以支持可靠的提前终止。EE-LLM [261] 专为 3D 并行化 LLM 设计，通过键值重新计算和管道并行性 [252] 集成令牌级退出，使其与大规模训练和推理兼容。EESD [62] 使用基本模型的初始 N 层并附加单层 Transformer 来有效生成高质量的草案令牌。FREE [258] 通过将浅层处理单元与预先计算的残差同步来引入时间相干并行性，以最小的深度加速令牌生成。总的来说，这些方法减少了延迟和成本，但仍然难以在退出点上保持一致的准确性，并在依赖于令牌的动态下协调退出。

高效通信对于边缘云系统中的协作推理至关重要，通过联合任务划分和通信感知调度实现细粒度推理。胡等人。[267]提出了一种混合架构，动态委托轻量级边缘模型和强大的云 LLM 之间的推理，实现 91% 的诊断准确率，同时能耗降低 28.6%。LLMCascades [111] 使用多阶段框架，其中边缘预测要么被接受，要么通过投票和验证升级到云模型，以最小的冗余增强可信度。EdgeShard [117] 通过仅转发推理关键令牌特征来减少不必要的云查询，而基于熵的压缩 [17] 进一步最小化传输成本而不损失准确性。为了优化吞吐量，PipeEdge [116] 使用管道并行性和自动调度跨设备对 LLM 进行分区，在保留模型容量的同时减少延迟。PerLLM [115] 将协调框架视为一个受约束的多臂老虎机问题，采用置信上限算法来自适应地选择最具成本效益的执行路径。混合[271]可以在多轮交互中实现轮次模型切换，利用模型异构性来提高响应质量，同时保持成本效率。尽管取得了这些进步，最大限度地减少动态环境中的开销并保持分区推理之间的语义一致性仍然是一个开放的挑战。

2.2.4 通信优化。

2.3 混合：LLM-SLM协同推理中的任务级编排和委托

混合范式混合了任务分配和执行划分，允许 SLM 和 LLM 通过分阶段责任共享来协作处理请求。如图 5 所示，我们区分了两种粒度：1) 任务级混合，2) 令牌级混合，其中生成在模型之间逐步共享[129,196,203]。

2.3.1 任务级分解、调度和编排。任务级混合使用语义线索来识别子任务边界，并根据计算要求将它们分配给边缘或云模型，从而产生可解释的模块化工作流程。例如，MinionS [138] 通过云聚合进行边缘侧分解，而 HybridSD [7] 将高级结构推理卸载到云并细化设备上的感知细节。IntellectReq [75] 在云中生成抽象意图以实现轻量级边缘执行。BAIM [64] 通过门控网络集成多个边缘模型输出以实现多模式协作，而 OT-GAH [118] 使用在线树修剪和分配启发式方法来最大化批量吞吐量。为了简化思想链推理，HAWKEYE [284] 在 LLM 中应用长度惩罚强化学习，并将详细的扩展卸载到 SLM。

2.3.2 历史增强协作推理。用户对云 API 的查询通常会反映发送到本地模型的查询，从而激发了利用历史用户与云交互来改进设备上推理的方法。现有的方法包括检索增强生成、基于缓存的调度和协作学习。例如，SlimPLM [174] 使用启发式置信度分数，仅当本地




图 5. 边缘-云模型协作的混合策略: (a) 任务级, 边缘服务器根据上下文和历史决定本地响应、查询云或转发到 LLM; (b) 令牌级边缘 SLM 在本地生成简单的令牌, 并通过隐藏状态共享将较难的令牌卸载到云 LLM 以进行细粒度推理。

响应不可靠。VELO [45] 在边缘服务器上缓存先前的请求嵌入, 并根据向量相似性来调度执行路径。丁等人。[44] 存储最近邻检索的交互历史, 使用子集选择来限制存储开销。Hybrid-RACA [114] 通过传输压缩内存单元将云检索器与轻量级边缘预测器结合起来, 以增强本地推理而无需连续的云访问。徐等人。[83,185,186] 引入了迭代直接偏好优化 (DPO) 机制, 其中大型模型不断引导小型设备上模型的更新。

2.3.3 具有自我评估和反馈的检索增强生成。如图 6 所示, 这些方法利用外部知识和反思推理来增强复杂任务的生成。秦等人。[188, 282] 分析了微调、RAG、数据规模、模型大小和任务难度之间的权衡, 证明 RAG 在资源限制下可以优于微调, 并且压缩的大语言模型从有限的个性化数据中受益更多。自知识检索[170]优先考虑内部知识, 仅在需要时通过即时学习或置信启发法调用外部检索。Self-RAG [171] 引入了反射标记, 这是一种特殊的控制信号, 可以让模型明确地评估检索到的段落。CRAG [172] 采用轻量级评估器来评估检索质量并根据需要触发二次检索或网络扩展。江等人。[200] 通过允许模型合并或重新校准检索到的内容来扩展内省信号。RA-ISF [173] 通过三阶段框架、自我评估、检索和查询分解将失败的查询分解为子问题, 并将子答案集成到最终响应中。SlimRAG [273] 在云上构建轻量级实体到片段索引, 用于显着实体检测, 降低图形复杂性和通信。SpeculativeRAG [211] 对文档进行聚类以并行草稿生成。

在实践中, Glocker [80] 在自主家居对象管理中应用了时间戳增强型 RAG, 使机器人能够在执行高级指令的同时跟踪过去的动作。朱等人。[190] 引入稀疏上下文选择, 通过控制令牌并行化文档编码和仅解码最相关的缓存内容。SparseRAG [231] 集成了文档评估和响应生成, 以最大限度地减少上下文加载, 加速推理并提高短格式和长格式任务的输出质量。

2.4 混合: 边缘云 LLM-SLM 协作中的代币级推测和验证

大多数大语言模型以自回归方式生成标记, 为下一个预测顺序生成每个标记。虽然这会产生高质量的输出, 但会延迟, 从而限制了资源受限的实时部署




图 6. RAG 中的混合 SLM-LLM 协作：SLM 通过近似最近邻搜索对查询进行编码并检索文档，LLM 使用查询和检索到的上下文生成响应。

设备。为了解决这个问题，最近的工作[244]提出了一种“轻量级起草+精确验证”范例：边缘部署的SLM快速生成高置信度的草稿，基于云的LLM验证语义一致性，纠正不确定的标记，并用额外的细节丰富内容[276]。如图7所示，我们调查了边缘-云协作中的推测性解码架构和技术，涵盖草稿-细化框架、草稿-完成策略、骨架-完成机制和令牌级验证[14]。

2.4.1 边缘草稿和云验证。该工作线分为两类：1) 具有算法增强功能的普通推测解码框架，2) 在不同部署约束下提高并行性并减少延迟的系统级设计。

普通推测解码和算法增强。早期的作品如[32,40,208]介绍了基本的推测解码范式。回退机制[207]让轻量级模型将不确定的标记推迟到更大的模型，而回滚策略则纠正不准确。在此基础上，RSD [37] 和 SpecExec [42] 结合了受控偏差来优先考虑高回报输出。AutoMix [92] 将符号推理与强化学习相结合，以减轻幻觉 [213] 和推理错误，使用内核密度估计来关闭设备上验证和云路由之间的反馈循环。傅等人。 [215]通过学习的验证分布将草稿模型和目标模型交替作为提议者和验证者来提高效率。

并行和低延迟推测推理框架。交互式应用程序（例如问答、语音助手、实时翻译）需要较低的首次令牌时间 (TTFT) 和逐令牌时间 (TBT)。DiSCo [41] 使用起草模型的 logits 估计每个投机令牌的接受概率。为了避免草稿模型等待验证的相互停滞，SpecDec [100, 109] 使用软区分执行并行令牌验证。PEARL [191] 使用自适应草稿长度和早期验证来加速解码，SEED [210] 使用循环 FCFS 队列管理草稿。

多层和轻量级验证管道。为了减少云负载，[135,195,219,223]提出了多层管道：轻量级验证器在最终云验证之前过滤令牌块[217]。Falcon [194] 通过耦合顺序扫描增强了块内令牌依赖性，提高了推测准确性，同时保持了适合轻量级多层验证的紧凑两层变压器草案模型。Spector [128] 使用更简单的模型添加了一个额外的草案阶段来预过滤低置信度假设。[291]通过提前退出来使用层并行性来进行中期验证令牌起草。客户在最终验证之前利用空闲时间预先起草令牌，从而提高边缘云并行性。与 Unitree Go 2 机器人上的云解码相比，这实现了 21% 的加速。




图 7. (a) Vanilla: 云验证边缘生成的草稿并拒绝或重新生成无效令牌; (b) 语义骨架: 云通过提示生成高级语义骨架, 边缘用相同或细化的提示完成该骨架; (c) 自推测: 模型分为浅层子网和深层子网, 使用适配器进行轻量级设备上验证; (d) 令牌树: 令牌树按概率扩展, 云验证每个请求的最佳分支。

草案质量增强和硬件感知调度。模糊推测解码 (FSD) [27] 放宽了严格的匹配约束, 允许较小的不匹配来提高速度[221]。赵等人。[126, 136] 提出短语级重用, 缓存经过验证的短语以快速生成。DistillSpec [137] 使用自采样数据离线将目标模型提炼为草稿模型。DuoDecoding [28] 将绘图分配给 CPU, 将验证分配给 GPU, 根据系统负载动态调整绘图长度 [218]。SPIN [290] 使用基于学习的 SSM 选择, 无需先验请求, 并通过推测和验证的 GPU 流水线加速执行。BanditSpec [214] 将生成文本时的自适应超参数选择问题表述为多臂 Bandit 问题, 并设计了两种基于 bandit 的超参数选择算法。

2.4.2 没有辅助草案模型的自推测解码。一些研究 [61, 216] 指出, 添加单独的草稿模型会增加通信、存储和培训成本 [253]。Kangaroo [38] 重用目标 LLM 的浅层子网络和 LM 头进行自起草, 显着减少了开销。S WIFT [61] 利用上下文感知层跳跃进行动态计算, ASD [216] 将推测采样扩展到扩散模型

表 5 云到边和边到云骨架协作范式比较

Paradigm	Ref.	Key Ideas	Advantages	Limitations
e d g e : c l o u d : c l o u d	PICE [43]	Progressive 推理 : cloud LLM drafts, edge SLM refines	Reduces latency and sup- ports incremental, real- time reasoning	Requires fine-grained synchronization between LLM and SLM
	CoGenesis [33]	Sketch planning by LLM with local completion; distribution-only collabo- ration via logits	Enables privacy- preserving 推理 and adapts to bandwidth constraints	Coarse plans may limit ex- pressiveness; logit proto- cols are model-specific
	NEST [201]	Cloud performs full retrieval, edge conducts 词元 -level neighbor search for caching	Reduces corpus storage and improves retrieval la- tency	Requires careful tuning of retrieval-词元 matching; introduces multi-stage complexity
d d p m : c l o u d : e d g e	SlimPLM [174]	Triggers LLM only when edge model uncertainty is high	Minimizes cloud calls and provides fast edge responses	Depends on accurate un- certainty detection; may miss subtle errors
	Hao <i>et al.</i> [14]	词元 correction: LLM re- fines output by editing a few edge 词元	Efficient corrections with minimal cloud usage	Requires reliable error lo- calization; not suited for structural rewrites
	Probe Sampling [209]	Measures draft-target sim- ilarity to decide cloud fall- back	Lowers cloud overhead while maintaining output fidelity	Relies on precise simi- larity estimation; risk of under-correction

利用 DDPM 可交换性进行并行推理。这些方法无需额外的模型训练即可保持速度增益。

2.4.3 语义和骨架完成。草稿-细化范式将生成分为两个阶段：边缘草稿和云端细化（参见表 5）。

云到边缘的骨架。此类方法采用自上而下的策略，其中云LLM首先生成高级语义“骨架”，边缘部署的SLM根据本地上下文或约束补充或调整内容。PICE [43] 生成一个用于并发边缘细化的任务草图，从而减少延迟。CoGenesis [33] 提供 1) 基于草图的局部完成规划和 2) 基于 logit 的隐私保护推理。NEST [201] 在云中使用混合检索，并通过轻量级缓存在边缘使用令牌级邻居搜索。

边缘到云绘图。这种范例首先在边缘快速、低成本地生成草稿，然后从功能更强大的云模型中进行细化。SlimPLM [174] 基于本地知识充足性触发大语言模型参与。郝等人。[14]执行令牌级别的更正，有选择地替换不明确的令牌。探测采样[209]根据草稿目标相似性过滤提示，最大限度地减少云的使用。虽然协作粒度各不相同，从文档块检索到令牌级校正，但这些方法体现了两种互补的协调范例：用于语义分解的云到边缘草图和用于轻量级响应式绘图的边缘到云细化。

表 6. 边缘云 LLM-SLM 系统中协作训练范例的比较

Category	Definition & Characteristics	Advantages	Limitations
Distillation-Based Collaboration	Uses logits, features, or hidden states for LLM-to-SLM supervision with task- and domain-adaptive schemes	Flexible; enables effective model compression and personalization	Sensitive to domain shift and teacher-student mismatch; data quality-dependent; uni-directional by default
Multi-SLM Parameter Fusion	Integrates heterogeneous SLMs via stitching, subnet assembly and capacity-guided transfer	Enhances edge personalization; enables cross-domain parameter reuse; supports one-pass deployment	Structural mismatch sensitivity; requires functional/meta-guidance; faces stability challenges
Adapter-Based Modular Training	Inserts LoRA-like adapters for parameter-efficient fine-tuning and federated updates	Scalable across tasks and devices; reduces communication costs; preserves base model integrity	Depends on shared adapter architectures; limited in cross-modal or non-aligned scenarios
SLM-Driven LLM Supervision	Employs SLM CoT to refine LLM outputs in noisy/low-resource contexts	Improves interpretability; enhances reliability on simple or repetitive tasks	Constrained by SLM capacity; risk of reinforcing local biases
Cloud-Guided Capability Injection	LLMs generate task-specific modules or behavioral updates for SLMs via meta-learning or distillation	Enables few-shot adaptation; supports evolving edge demands; modular and task-aware	Requires costly cloud computation; may induce concept drift; on-device validation is challenging

2.4.4 令牌树验证。在推测性解码中，最佳验证时机至关重要：早期验证可能会浪费计算，而延迟检查则可能会出现不可逆错误（见图 7）。为了缓解这种情况，令牌树结构允许每个节点分支到多个候选路径，从而实现更广泛的输出探索并减少单路径错误造成的浪费。沿着这条线，LLMCad [26] 和遍历验证 [133] 引入了一种非自回归令牌树验证器，能够在单次迭代中同时验证和纠正所有分支。在此基础上，Ada Serve [39] 为每个请求构建候选令牌树，并动态选择最佳令牌分支，以在预定义的服务级别目标 (SLO) [29, 131] 下最大化系统吞吐量。OPT-Tree [60]通过提出动态树构建方法来解决固定结构令牌树的低效率问题。它在每个解码步骤贪婪地构建期望最优候选树，并通过概率建模修剪分支，从而在节点预算下最大化有效令牌。遍历验证[133]通过引入自下而上的序列级验证进一步增强了树的利用率。该方法评估完整的令牌路径而不是单个令牌，从而降低了过早丢弃有用子序列的风险。Sequoia [127] 在此基础上将令牌树构建表述为动态编程问题。它避免了草稿模型重采样，并集成了硬件感知优化，以自适应地为目标平台选择树深度和大小。

3 协作学习架构概述

协作培训促进边缘 SLM 和云 LLM 在异构条件下持续进行知识交换。与注重延迟的推理合作不同，训练强调结构兼容性、非独立同分布适应和隐私保护传输。传统的蒸馏和迁移学习假设一致




图 8. 高效云边协作训练的模型压缩技术: (a) 权重和激活的量化; (b) 参数修剪 (结构化或非结构化稀疏性); (c) 师生转移的知识提炼; (d) 权重矩阵的低阶近似。

架构或任务, 限制了通用性。在实践中, 结构差距和数据异质性会导致偏差和虚假相关性, 从而损害聚合和泛化。刘等人。[90]在隐私、暴露和成本约束下正式化大小模型协作, 将其分解为三个阶段: 1) LLM到SLM转移, 2) SLM到LLM反馈, 3) 闭环适应。为了统一这一格局, 我们提出了跨五种范式的协作训练分类法: 基于蒸馏的协作、基于适配器的模块化训练、双向学习、SLM 驱动的监督和云引导的能力注入。如表 6 所示, 我们的分类突出了每个范式的功能作用和渐进的相互依赖性, 从单向转移到模块化调整、迭代反馈和反向监督。该分类法以知识流、耦合强度、结构假设和部署约束为基础, 为在边缘云环境中选择合适的策略提供了原则基础, 并激发了更强大、更通用的训练设计。

3.1 高效端云协同的剪枝和量化策略

在端云协同训练框架中, 剪枝和量化是构建轻量级模型的关键技术, 可以协调边缘设备的有限资源与云模型的准确性要求。李等人。[120]引入了一种稀疏感知通道修剪方法, 该方法评估特征分布偏差以删除全局不重要的通道; 其软掩模机制允许选择性重新激活。EfficientLLM [121] 在预训练期间应用渐进式结构修剪来消除冗余子结构。补充修剪, Jiang等人。[122]提出了一种分割变压器设计, 其中轻量级边缘编码器生成用于云解码的量化中间嵌入。MergeNet [67] 通过 LLM 和 SLM 参数的低秩分解解决结构不兼容问题, 然后进行基于注意力的融合, 从而在不改变边缘架构的情况下实现表达性知识转移。如图 8 所示, 这些方法在训练、推理和调度维度上共同优化剪枝和量化。对于任务粒度混合物

边云推理中, OT-GAH 算法 [118] 利用在线树修剪和广义分配启发式方法, 在不同的延迟和准确性约束下实现接近最优的吞吐量。

3.2 蒸馏和低阶近似

边缘云蒸馏技术分为三大类: 1) 任务和领域自适应蒸馏, 2) 与代理学习的架构解耦, 以及3) 双向、反馈驱动的蒸馏。

任务和领域自适应蒸馏。ATKD 沿着任务和多样性导向的轴重新定义了蒸馏[112], 引入不确定性系数来量化令牌级别的学习难度, 并揭示了 LLM 输出的高确定性抑制了多样性。SLMREC [91] 和 GKT [16] 等方法对齐轻量级设备上 SLM 和云 LLM 之间的中间隐藏状态, 以实现潜在空间传输。领域鲁棒技术 [76, 81] 使用潜在映射、掩蔽和混合来构造伪样本空间, 以在没有共享数据的情况下对齐学生表示。DDK [101]通过域引导采样和因子平滑机制进一步提高跨域鲁棒性, 以促进跨不同域的高效从云到边缘的蒸馏。

。

架构解耦和反馈引导的蒸馏。为了解耦边缘和云之间的部署, DC-CCL [9] 将基础模型垂直划分为云和边缘组件, 通过蒸馏训练轻量级代理, 以最少的通信来模拟云行为。斯塔罗杜布切夫等人。[108]仅当学生输出未通过质量检查时才自适应地调用教师纠正。科林等人。[93]将弱监督和高能力教师整合到闭环框架中, 而共同监督学习[102]通过后验一致性动态分配教师并过滤噪声信号。像 SALT [107] 和 SKD [212] 这样的反向监督方法让边缘 SLM 在训练早期教导 LLM, 逐渐反转角色, 让 LLM 专注于复杂样本。多模式、反馈增强的管道、CD-CCA [48] 和 LLM-QAT [103], 上传实用程序选择的样本以进行云优化, 并将量化更新返回到边缘, 从而实现高效、可压缩和自适应模型增强。总的来说, 这些方法展示了边缘云协作训练中从静态分区到动态、双向和多模式知识转移的进展。

利用低秩近似进行边缘侧 SLM 部署。。除了知识蒸馏之外, 低秩近似已成为一种轻量级且有效的方法, 用于在资源受限的边缘环境中优化 LLM 部署。QLLMS [294] 通过低秩属性驱动的恢复方法从部分样本重建 AQS 矩阵, 解决了边缘性能的不可预测性。DP-LoRA [293]通过低秩权重更新减少了分布式训练中的传输开销。此外, [295]使用分数规划和迭代级惩罚 (IRP) 增强了稳定性感知微调, 以共同优化资源分配和用户边缘关联。

3.3 参数兼容性和模型收敛性

传统的统一模型传输方法面临着参数不匹配和个性化边缘要求的问题。为了解决协作学习中的碎片化领域知识, 最近的研究提出了有效的参数协调机制: Graft [277]引入了一种兼容性感知缝合策略, 使用局部功能归因和全局信息论信号来仅集成兼容的参数。CKI [68]评估源模型的信息容量, 并通过两阶段传输和拼接过程将兼容参数融合到目标中。Forward-OFA [69]使用实时边缘需求通过行为到结构映射来组装子网络, 解决梯度冲突并允许无需反向传播的一次性适应。DIET [70] 维护跨设备的统一主干, 而云根据每个设备的使用历史生成个性化的“饮食”(子网)。FedMKT [46] 探索了云 LLM 和客户端 SLM 之间的双向知识交换, 提高了非 IID 数据下的适应性。ModelGPT [74] 利用 LLM 从用户提供的样本或任务描述自动生成定制的小模型。




图 9. 双向知识迁移的协作训练: (a) SLM 通过特定领域的预训练、指令调整和提示优化来获取任务知识; (b) 冻结的客户端 SLM 增强了本地适配器, 在集中协调下进行协作训练。

3.4 基于适配器的模块化设计

在协作边缘云系统中, 集成 SLM 和 LLM 之间的知识和权重参数仍然是一个核心挑战。为了解决这个问题, 适配器方法 (例如 LoRA) 可以跨异构边缘云系统进行可扩展、参数高效的调整: PEFT [79] 使用轻量级 LoRA 模块作为通信桥梁: 客户端在联合训练期间仅更新适配器权重, 而服务器通过监督微调 and K L 散度正则化执行双向知识提取。卢等人。[280] 在 Transformer 层之间插入瓶颈适配器, 将领域知识编码到预先训练的模型中。PLURALISM [88] 通过 LoRA 将社区 LLM 集成到基础模型中, 使边缘 SLM 能够在本地进行微调, 云 LLM 能够管理集成。HETLoRA [96] 结合了高阶和低阶 LoRA 模块; 客户端按功能对模块进行排名, 服务器应用排名感知修剪和稀疏加权聚合。CDC-MMPG [36] 引入了一种快速域适配器, 它使用历史多模态数据来训练全局模型并为实时设备输入生成个性化参数。总的来说, 这些方法标志着向灵活、模块化和数据感知调整机制的转变, 这些机制可以跨端云协作框架无缝集成知识。

3.5 异构模型的双向协作学习

大多数分布转移方法依赖于通过在线训练或梯度更新进行的设备上个性化, 这会产生高延迟和开销。为了解决这个问题, 最近的方法有利于跨异构边缘云模型的协作优化, 强调迭代、双向知识转移而不是静态、单向蒸馏 (见图 9): DUET [104] 分离静态层和动态层, 使用通用元网络和分层超网络来生成用于个性化边缘推理的自适应参数。胡等人。[270] 开发一种知识转移促进技术, 让不同的大语言模型有效地共享和整合互补知识。CROSSLM [87] 建立了一个管道, 其中边缘模型在本地进行训练, 云使用边缘反馈生成和过滤伪数据, 从而实现相互增强。SLM [89] 在边缘应用逆强化学习来生成结构化的、与任务一致的样本, 而云 LLM 则执行并行解码蒸馏以协调全局和局部目标。

3.5.1 从云 LLM 到设备上 SLM 的动态知识传输。该研究线将小型模型视为可插入的知识模块，以补充或增强推理过程中的 LLM 性能。知识卡[176]使用预训练的SLM来生成“知识卡”，这是在推理过程中动态查询的参数化知识库。BLADE [181] 采用插件式架构，其中特定领域的 SLM 捕获专家知识，并通过贝叶斯优化将其与通用 LLM 融合，以提高推理质量。渐进蒸馏[99]通过让云大语言模型生成任务标签和基本原理来训练轻量级边缘模型，联合优化标签和基本原理损失以提高准确性和可解释性，从而针对未标记数据。HEF 框架 [180] 集成了一个小型移情模型来检测情绪和触发因素，指导 LLM 生成进行更细致的对话。FedCFA [73] 通过构建全局特征数据集并应用因果感知反事实替换，使 SLM 与云语义保持一致，解决联邦设置中的非独立同分布泛化问题。AcKnowledge [281]利用用户问题驱动的元学习来获取外部知识，并在检测到扭曲时根据用户反馈不断完善SLM。

3.5.2 通过云指导将自适应能力注入小型模型。这一类别反转了典型的蒸馏流程，使用 SLM 作为“老师”或行为先验来指导 LLM 培训和微调。ECLM [256]将云模型分解为可组合模块，为不同设备组装特定于任务的子模型，并定期将新的边缘知识集成回云中。米切尔等人。[105] 将微调引起的行为变化编码为紧凑的“logit delta”，轻量级 SLM 对其进行计算并传输到 LLM 以模拟这些适应，而无需完全重新训练。唐等人。[179, 206] 提出了一种实体关系提取系统，其中小型 PLM 捕获头级知识并生成中间预测，作为 LLM 的思想链指导。Purify-LLM [177] 使用可信的 SLM 和 CP- δ 算法过滤 LLM 的噪声数据，仅集成对齐的知识。这些方法强调了 SLM 在约束和指导 LLM 学习方面的作用，创建了一个沿着显式路径优化模型行为的正反馈循环。

4 基准、数据集和评估协议

由于缺乏边缘-云协作的标准化基准，评估协作式 LLM-SLM 系统比集中式模型更复杂。传统的 NLP 基准假设 IID 数据和集中执行，这与 SLM 管理个性化、非 IID 工作负载的实际部署不同。因此，新的基准必须支持用户或设备级分区以反映部署异构性。

4.1 边云联合协作数据集

现实、异构且可重复的基准对于评估边缘云 LLM-SLM 系统中的协作训练和推理至关重要（参见表 7）。LEAF 框架 [145] 提供模块化工具和真实世界的用户分区数据集，以评估统计异质性、资源限制和个性化下的性能。对于大规模视觉任务，Zhu 等人。[146]引入非IID分区的iNaturalist-User-120k（120K图像，1.2K物种，9.3K用户）和Landmarks-User-160k（164K图像，2K类别，1.3K上传者）。在对话建模中，PersonalDialog [147] 提供来自 850 万说话者的 5600 万条话语，并带有人口统计属性注释，而 PERSON A-CHAT [148] 提供基于角色的一致性基准。LiveChat [149] 提供 133 万多方中文对话和 351 个角色，能够在时间动态下实现响应生成和接收者识别。FedScale [150] 涵盖了跨模式的 18 项现实世界任务，规模从数百到数百万客户，其 FAR 平台支持异步训练、延迟模拟以及准确性、成本和隐私指标。FedNLP [151] 使用 Dirichlet 分割来模拟非 IID 分布，对联合 NLP 任务（例如 20Newsgroup、MRQA）进行基准测试，促进协作 LLM-SLM 系统的可重复评估和实际优化。

表 7. 边云协作的代表性数据集

Dataset	Task	Volume & Classes	Partitioning	Metrics & Features
LEAF [145]	Multi-task federated learning	Sent140: 660k tweets; FEMNIST: 805k images	User-level splits reflecting real-world heterogeneity	Supports personalization and transfer learning
iNaturalist-User-120k [146]	Image classification	120,300 images from 9,275 users; 1,203 species	Uploader-ID splits (user-level)	Large label space with strong user-level statistical skew
Landmarks-User-160k [146]	Landmark recognition	164,172 images from 1,262 photographers; 2,028 landmarks	Region-aware S2-cell splits via GPS metadata	Captures spatial distribution heterogeneity
PersonalDialog [147]	Personalized dialogue	56.3 M utterances from 8.5 M speakers	User-ID splits with demographic annotations	Supports sociolinguistic and attribute personalization
PERSONA-CHAT [148]	Persona-grounded chit-chat	164,356 utterances across 10,981 dialogues	Crowdworker pairs on 1,155 personas	Next-utterance prediction and personal consistency
LiveChat [149]	Multi-party live dialogue	1.33 M utterances from 351 streamers	ASR-aligned utterances with recipient matching	Single-turn dialogue with personas; addressee recognition
FedScale [150]	Multi-domain federated learning	20 datasets (CV, NLP, audio) with millions of clients	Non-IID splits by user ID or trace logs	Benchmarks statistical; System heterogeneous, dynamics
FedNLP [151]	Federated NLP (TC, NER, QA, Seq2Seq)	20News: 11.3k, 20 classes; OntoNotes: 50k, 37 tags	Dirichlet non-IID splits and cross-silo partitions	Metrics: accuracy, F1, ROUGE; federated evaluation

4.2 双模型边云学习基准

边缘-云协作学习需要双重评估：在跨设备的非 IID 数据下，云 LLM 的全局泛化和边缘 SLM 的本地适应。最近的基准测试通过用户级拆分创建非独立同分布测试环境。LEAF 将 CIFAR-10 和 Shakespeare 扩展为具有设备 ID 分区的联合版本 [145]。Persona-Chat [148] 和 LiveChat [149] 利用对话角色进行个性化生成。FedMulti-modal [152] 集成了八种模态的十个数据集，模拟缺失的模态和标签噪声。FederatedScopeGNN [160] 提供具有节点、边缘和图级别拆分的异构图基准（例如 FedDBLP）。pFL-Bench [153] 统一了 10+ 数据集的分区策略，并引入了设备异构性和稀疏性配置以实现真实性。

分层评估指标至关重要：图像分类采用加权全局精度（按设备数据量）、局部 SLM 精度和蒸馏损失来评估知识转移 [158]。对于 NLG，全局 BLEU/ROUGE 分数补充了用户级别的困惑。在推荐中，由用户数据加权的全局 AUC 和本地 CTR 校正反映了个性化[154]，OCPC 评估端到端流量分配效率[155]。

开源平台支持可重复的边缘云实验：FedML [159] 提供具有模块化通信训练解耦的设备上、单机和分布式模式；Flower [161] 可跨语言和后端扩展到数百万个虚拟客户端；Google 的 TensorFlow Federated [158] 在数亿台设备上运行。对于 LLM 特定的操作，LLMOps 框架 [156, 164] 引入了定制的监控和安全协议。SpecBench [244] 评估推测解码的延迟、准确性和计算成本。MessageRewriteVal [227] 使用高质量、人工注释的场景标准化移动文本重写，以评估模型基于自然语言指令重写消息的能力。这些基准和平台共同为在现实边缘云条件下对协作式 LLM-SLM 系统进行公平、严格的评估奠定了基础。

5 项公开挑战

5.1 隐私保护和协作机制

传统的推理效率优化往往忽视协作训练和更新中的隐私和安全风险[113]。因此，在保持数据局部性的同时实现高效的边云合作已成为一个关键的研究方向，安全多方计算加密梯度更新以防止聚合过程中敏感信息泄漏。

培训级保护。刘等人。[57]通过轻量级适配器将边缘端即时适应与基于云的优化集成起来，通过将敏感数据保留在本地来实现隐私保护协作，同时利用云资源提高效率。DCPR [63] 采用分层扩散范式进行个性化推荐，其中一般模式在云端学习，区域偏好在边缘进行调整，细粒度个性化在设备上。罗等人。[278]利用联合学习来训练分散客户端的模型，通过仅传输加密更新来确保隐私。在这些进步的基础上，未来的工作将越来越集中于不确定性引导的监督，以选择性云参与、倾斜和非独立同分布下的公平聚合。客户分布，以及跨异构任务、模式和模型规模的通用知识转移。此外，反事实表示学习预计将在聚合前消除云端更新偏差方面发挥关键作用，从而增强协作训练的实用性和公平性。

推理级保护。RemoteRAG [247] 在嵌入空间中引入了语义差异隐私度量和动态安全检索协议，该协议仅在相似性超过阈值时返回文档索引。SuperICL [58]使用插件式的小模型通过即时增强注入局部知识，在不暴露原始数据的情况下指导大语言模型的推理。潘等人。[35]提出了一种混合框架，其中云通过适配器和压缩构建代理模型，边缘对敏感内容应用符号屏蔽，通过 cGAN 生成替代数据以平衡实用性和隐私。POST [222] 通过将草案生成卸载到公共 GPT 模型并优化加密操作来加速隐私保护推测解码。陈等人。[197]编排一个基于 Kubernetes 的混合系统，该系统在私有云中保留敏感数据和向量存储（例如 Chroma），同时在严格的保密约束下将 LLM 推理弹性卸载到公共云。这些努力为隐私保护协作提供了初步方法，但也揭示了开放的挑战。未来的工作应该在不同的模型层次结构中扩展安全、高效的推测性解码，平衡多模型设置中的草稿质量和验证成本，确保在嘈杂的反馈和不稳定的连接中的鲁棒性，并通过更大的协作系统中的自反射 SLM 实现紧急功能。

表8. 工业云边缘LLM-SLM协作框架及应用场景

Category	Domain	Collaboration Strategy	Advantages & Limitations
d u o C - e g d E i a r r i s u d n	Walle [264]	End-to-end deployment pipeline handling development, runtime, and scaling.	Manages 300+ tasks and 10B+ daily calls; constrained by tight infrastructure coupling.
	Luoxi [265]	Slow-fast learning: cloud LLM generates aux. reps; edge SLM fast 推理 with feedback.	Enhances personalization via feedback loop; requires robust bidirectional communication.
	InfGUIAgent [266]	Two-stage hierarchical reasoning with on-device fine-tuning for multi-modal GUI interaction.	Enables on-device GUI reasoning; may face edge memory and compute limitations.
s n o i a c i p A i a c t i v	Autonomous driving [55, 56]	Edge SLM handles perception; cloud LLM performs high-level planning and reasoning.	Balances fast perception with complex strategy; requires efficient cloud triggering.
	Livestream product recognition [184]	Edge extracts keyframe features; cloud LLM conducts multi-modal classification.	Reduces bandwidth via selective uploads; risks missing critical content in keyframes.
	Cultural heritage restoration [77]	Edge proposes fragment matches; cloud LLM ranks and aligns results.	Supports time-sensitive, high-accuracy restoration; depends on fragment proposal quality.
	Product modeling[78]	Edge injects geometric priors; cloud completes texture synthesis.	Improves partial-view generation; limited by cross-device alignment noise.
	Virtual assistants [240, 241]	Edge SLM manages routine interactions; cloud LLM handles complex or fallback queries.	Ensures responsiveness; cloud fallback may disrupt conversational continuity.
	Personalized recommendation [30, 63, 221]	Cloud LLM generates candidate items; edge re-ranks using real-time user context.	Adapts swiftly to user intent; candidate diversity hinges on LLM quality.
	Mobile task automation [224]	Cloud LLM parses app semantics; edge executes tasks via dynamic analysis.	Enables cross-app automation without manual setup; depends on accurate semantic parsing.
	Healthcare [225]	Biomedical LLM fine-tuned from general LLM for on-premise or hybrid deployment.	Offers domain-specific open-source model; needs careful tuning for sensitive settings.
	Web interaction [230]	Cloud LLM decomposes tasks and generates executable scripts.	Automates multi-step web tasks; relies on precise decomposition.

5.2 边云大小模型在垂直领域的应用

边缘云 LLM-SLM 协作在不同的应用领域展示了强大的潜力（见表 8）。在自动驾驶中，ADAS [55] 在边缘使用轻量级多模态模型 (CogVLM2) 来执行延迟关键型任务（对象检测、避障），而云 LLM (ChatGPT-4o) 则处理高级路线规划。EC-Drive [56] 通过事件驱动设计扩展了这一点：边缘 LLM 管理日常驾驶，在分布变化（例如，新障碍）时触发云 LLM，以进行常识推理和跨模式理解。

直播对低延迟、高并发和昂贵的多模态推理的实时产品识别提出了挑战。最近的框架通过使用单模态边缘模型来选择性地上传云多模态处理的关键帧来解决这个问题[184]。例如，LLMCO4MR [77] 将手稿恢复视为一项组合任务，使用设备上的神经解算器进行片段选择，并使用云 LLM 进行置信度评分和对齐。BoFiCap [286] 将图像字幕解耦为设备上的边界检测和云中的非自回归填充。VITA-1.5 [285] 采用三阶段训练管道（视觉语言预训练、音频对齐、语音解码）来避免模态冲突，而 MPOD123 [78] 在边缘注入几何先验，并将复杂的视觉生成卸载到云端。

cenarios [263]、LSC4Rec [30] 等推荐系统使用云 LLM 生成不同的候选列表，并使用实时适应用户偏好的轻量级边缘排名模型。AutoDroid [224] 通过将大语言模型常识推理与应用程序界面的动态分析相结合，实现移动工作流程的自动化。在医疗保健领域，BioMistral [225] 通过持续对生物医学文本进行预训练来专门学习一般大语言模型，以支持特定领域的任务。对于基于 Web 的交互，WebAgent [230] 通过将用户指令分解为结构化子任务、总结冗长的文档以及生成可执行的 Python 脚本来执行复杂的操作，解决了开放域可变性和 HTML 归纳偏差的缺乏。这些垂直应用程序共同说明了分层边缘云 LLM-SLM 架构在现实场景中的变革性影响。

6 结论

这项调查首次全面回顾了大型和小型语言模型 (SLM) 之间的边缘云协作，解决了推理时协作和训练时协调问题。我们提出了推理范式、任务分配、任务划分和混合方法的统一分类法，并进一步细化为任务和令牌级别的粒度。在训练方面，我们确定了双向知识转移、量化、修剪和低秩适应等关键推动因素，这些因素支持高效部署而不影响性能。通过基于最新进展的分析，我们将算法技术与系统级需求联系起来，为构建可扩展、低延迟、资源感知的 LLM-SLM 系统提供方法见解和实践指导。这种统一的视角为未来异构环境中的研究和部署奠定了坚实的基础。

前景。在边缘-云协作推理中，许多系统依靠不确定性估计来支持动态决策，例如提前退出、回退或模型切换，通常是通过比较边缘侧 SLM 和云 LLM 之间的不确定性。然而，基于采样一致性或令牌级概率的主流方法面临着固有的局限性。归一化的 softmax 概率掩盖了 logits 中编码的原始证据强度，通常无法区分模型是否对输入有信心、不确定或不熟悉。这种错位在开放式语言生成中尤其成问题，其中可能存在多个有效延续。我们主张未来转向基于证据的不确定性估计，利用非标准化逻辑来保留模型积累的训练经验。通过将不确定性分解为认知和任意成分（例如通过基于狄利克雷的公式），边缘模型可以更准确地表征其自身的可靠性。这种证据感知策略为信任校准提供了更细粒度的基础，

协作式 LLM-SLM 部署中的响应升级和卸载，从而实现更稳健且语义一致的推理。

基于证据驱动的不确定性估计，未来的协作框架将从固定规则转向自适应、智能政策。强化和元学习可以利用任务需求、资源限制和实时反馈来优化协作。合作将从简单的任务拆分深化到联合优化、共享表示，实现更精细的协调。在多模态和实体智能等复杂领域，轻量级边缘模型将处理实时传感，而云法学硕士则执行高级推理，平衡延迟和决策复杂性。在确保强有力的协作、降低通信成本和实现个性化方面仍然存在挑战。未来的系统必须平衡性能、灵活性和隐私，以实现真正有效的边缘云 LLM-SLM 协作。

参考

- [1] 邱宇, 梁俊斌, Victor CM Leung, 等。在边缘智能云中提供在线安全感知和可靠性保证的人工智能服务链。IEEE 传输。暴民。计算机, 2023。[2] Othmane Friha, Mohamed Amine Ferrag, Burak Kantarci 等人。基于LLM的边缘智能: 对架构、应用程序、安全性和可信度的全面调查。IEEE Open J. Commun. Soc., 2024。[3] 王一鸣, 林宇, 曾晓东, 等。Privatelora 用于有效保护隐私的 llm。arXiv 预印本 arXiv:2311.14030, 2023。[4] 曲冠桥, 陈启元, 魏伟, 等。大语言模型的移动边缘智能: 当代调查。IEEE 通信。幸存者。导师., 2025。[5] 马木磊, 宫辰宇, 曾列康, 等。用于协同AI计算的LLM多层多节点调度。在过程中。IEEE INFOCOM, 第 1-10 页, 2025 年。[6] 于仲凯、梁胜文、马天云等。Cambricon-llm: 一种基于小芯片的混合架构, 用于 70b LLM 的设备上推理。在过程中。第 57 届 IEEE/ACM 国际会议症状。微架构, MICRO, 第1474-1488页, 2024年。[7] Chenqian Yan, Song wei Liu, Hongjian Liu, et al. Hybrid sd: 稳定扩散模型的边云协作推理。arXiv 预印本 arXiv:2408.06646, 2024。[8] 张旭超, 夏梦琳, Camille Couturier, 等。用于实时合成辅助的混合检索增强生成。arXiv 预印本 arXiv:2308.04215, 2023。[9] 丁宇成, 牛超跃, 吴凡, 等。Dc-ccl: 大型视觉模型的设备云协作控制学习。arXiv 预印本 arXiv:2303.10361, 2023。[10] Jing Cheng Fang, Ying He, F Richard Yu, et al.云边缘网络中的大语言模型 (llms) 推理卸载和资源分配: 一种主动推理方法。在过程中。第 98 届 IEEE 车辆。技术。会议, VTC2023-秋季, 第 1-5 页。IEEE, 2023。[11] Jihwan Bang, Juntae Lee, Kyuhong Shim 等人。Crayon: 通过即时适配器混合和边缘服务器混合推理定制设备上 llm。在过程中。62周年。见面。副教授。计算。语言学家。(ACL), 卷。1, ACL, 第 3720–3731 页, 2024 年。[12] Ruslan Svirshchevski, Avner May, Zhuoming Chen 等人。Specexec: 大规模并行推测解码, 用于消费设备上的交互式 llm 推理。arXiv 预印本 arXiv:2406.02532, 2024。[13] 金红鹏和吴艳照。Ce-collm: 通过云边缘协作实现高效且自适应的大语言模型。arXiv 预印本 arXiv:2411.02829, 2024。[14] 郝子旭, 蒋惠强, 蒋世奇, 等。用于边缘云协作推理的混合 slm 和 llm。在过程中。车间边缘移动已找到。模型, EdgeFM, 第 36-41 页, 2024 年。[15] Fan Yang, Zehao Wang, Haoyu Zhang, et al. 跨云设备系统高效部署大语言模型。在 IEEE 国际。片上系统会议, SOCC, 第 1-6 页, 2024 年。[16] Yao Yao, Zuchao Li 和 Hai Zhu. Gkt: 一种新颖的基于指导的知识转移框架, 用于高效的云边缘协作 llm 部署。arXiv 预印本 arXiv:2405.19635, 2024。[17] 沉一飞, 邵嘉伟, 张新杰, 等。大语言模型支持自主边缘人工智能, 实现互联智能。IEEE 通信。Mag., 62(10):140–146, 2024。[18] 金吕尔, 张彦宁, 李彦涵, 等。Moe²: 优化边缘大语言模型的协作推理。arXiv 预印本 arXiv:2501.09410, 2025。[19] 陈伟, 李志远, 郭震, 等。Octo-planner: 用于规划器操作代理的设备上语言模型。arXiv 预印本 arXiv:2406.18082, 2024。[20] 朱训宇, 李健, 刘勇, 等。大语言模型的模型压缩调查。跨。副教授。计算。语言学, 12: 1556–1577, 2024。

[21] 李金东, 李腾龙, 沉国斌, 等. 突破内存带宽和容量利用率的限制, 实现嵌入式 fpga 上的高效 llm 解码. 在德斯. 自动. 测试欧元. 会议, 日期, 第 1-7 页. IEEE, 2025. [22] 贾福成, 吴泽文, 江世奇, 等. 通过 DRAM 和闪存之间的主动权重交换来扩展设备上的 llms. arXiv 预印本 arXiv:2504.08378, 2025. [23] 刘一恒, 何浩, 韩天乐, 等. 了解 llms: 从训练到推理的全面概述. 神经计算, 620: 129190, 2025. [24] 张书航, 刘庆宇, 陈科, 等. 空中边缘的大型模型: 边缘云模型演变和通信范例. IEE E J. Sel. Areas Commun., 43(1):21–35, 2025. [25] Minrui Xu, Hongyang Du, Dusit Niyato, et al. 在移动网络中释放边缘云生成人工智能的力量: aigc 服务调查. IEEE 通信. 幸存者. 导师., 26(2):1127–1170, 2024. [26] 徐大良, 尹王松, 金鑫, 等. Llmcad: 快速且可扩展的设备上大语言模型推理. arXiv 预印本 arXiv:2309.04255, 2023. [27] Maximilian Holsman, Yukun Huang 和 Bhuwan Dhingra. 模糊推测解码可实现可调节精度与运行时间的权衡. arXiv 预印本 arXiv:2502.20704, 2025. [28] 吕凯, 郭洪林, 郭启鹏和邱西鹏. Duodecoding: 具有动态多序列起草的硬件感知异构推测解码. arXiv 预印本 arXiv:2503.00784, 2025. [29] 杨鹏辉, 杜存晓, 张峰卓, 等. Longspec: 具有高效起草和验证的长上下文推测解码. arXiv 预印本 arXiv:2502.17421, 2025. [30] Zheqi Lv, Tianyu Zhan, Wenjie Wang, et al. 大语言模型和小推荐模型的协作进行端云推荐. 在过程中. ACM SIGKDD 会议知道. 迪可夫. Data Min., KDD, 第 962–973 页, 2025 年. [31] Jihwan Bang, Juntae Lee, Kyuhong Shim 等人. Crayon: 通过即时适配器混合和边缘服务器混合推理定制设备上 LLM. 在过程中. 62周年. 见面. 副教授. 计算. 语言学家. (ACL), 卷. 1, ACL, 第 3720–3731 页, 2024 年. [32] Sehoon Kim, Karttikeya Mangalam, Suhong Moon 等人. 使用大大小小的解码器进行推测解码. 在过程中. 国际. 会议. 神经信息. 过程. Syst., NeurIPS, 2023. [33] 张凯彦, 王建宇, 华雷莫, 等. Cogenesis: 一个协作大型和小型语言模型的框架, 用于安全的上下文感知指令跟踪. 在过程中. 62周年. 见面. 副教授. 计算. 语言学家. (ACL), 卷. 1, ACL, 第 4295–4312 页, 2024 年. [34] Kaiyan Zhang, Jianyu Wang, Ning Ding, et al. 快与慢生成: 大小语言模型协同解码的实证研究. arXiv 预印本 arXiv:2406.12295, 2024. [35] 潘阳河, 苏周, 王云涛, 等. 云边协同大模型服务: 挑战与解决方案. IE EE 网络, 2024. [36] 季伟, 李丽, 吕哲琪, 等. 通过云设备协作进行无反向传播的多模式设备上模型自适应. ACM 翻译. 多米. 计算. 交流. 应用, 21(2):69:1–69:17, 2025. [37] 廖宝浩, 徐宇辉, 董汉泽, 等. 用于高效 llm 推理的奖励引导推测解码. arXiv 预印本 arXiv:2501.19324, 2025. [38] 刘方成, 唐业辉, 刘振华, 等. Kangaroo: 无损自推测解码, 通过双提前退出加速 llms. 在过程中. 国际. 会议. 神经信息. 过程. Syst., NeurIPS, 2024. [39] 李子坤, 陈卓夫, Remi Delacourt, 等. Adaserve: Slo 定制的 llm 服务, 具有细粒度推测解码功能. arXiv 预印本 arXiv:2501.12162, 2025. [40] Yujin Kim, Euiin Yi, Minu Kim, et al. 在法学硕士的帮助下指导小语言模型的推理. arXiv 预印本 arXiv:2504.09923, 2025. [41] Ting Sun, Penghan Wang 和 Fan Lai. Disco: 基于 llm 的设备-服务器协作文本流服务. arXiv 预印本 arXiv:2502.11417, 2025. [42] Ruslan Svirskchevski, Avner May, Zhuoming Chen 等人. Specexec: 大规模并行推测解码, 用于消费设备上的交互式 llm 推理. 在过程中. 国际. 会议. 神经信息. 过程. 系统, NeurIPS, 2024. [43] 詹惠友, 张轩, 谭海生, 等. Pice: 一种语义驱动的渐进推理系统, 用于云边缘网络中的 llm 服务. a rXiv 预印本 arXiv:2501.09367, 2025. [44] 丁宇成, 牛超跃, 吴凡, 等. 通过基于云的历史 llm 交互增强设备上 llm 推理. 在过程中. ACM SIGKDD 会议知道. 迪可夫. 数据挖掘, KDD, 第 597–608 页, 2024 年. [45] 志耀, 唐志清, 楼炯, 等. Velo: 矢量数据库辅助的云边协同 llm qos 优化框架. 在 IEEE 国际. 会议. 网络服务, ICWS, 第 865–876 页, 2024 年. [46] 范涛, 马国强, 康彦, 等. Fedmkt: 大型和小型语言模型的联合相互知识转移. 在过程中. 国际. 会议. 计算. 语言学家, COLING, 第 243–255 页. [47] 李传涛, 顾布鲁斯, 赵志刚, 等. 用于设备上 llms 高效微调优化的联合迁移学习. 大数据最小值肛门..

[49] 邵晨阳, 胡新元, 林玉堂, 等. 思路分工: 利用混合语言模型协同作用实现高效的设备上代理. 在过程中. ACM Web Conf., WWW, 第 1822–1833 页, 2025. [50] Rongjie Yi, LiweiGuo, Shiyun Wei, et al. Edgemoe: 基于 moe 的大语言模型的快速设备上推理. arXiv 预印本 arXiv:2308.14352, 2023. [51] 刘畅和赵军. 移动边缘计算中稳定的 LLM 训练的资源分配. 在过程中. ACM 国际. 症状. 移动自组织网络. 计算机, MOBIHOC, 第 81–90 页, 2024 年. [52] Ying He, Jing Cheng Fang, F. Richard Yu, 等. 云边缘计算中的大语言模型 (llms) 推理卸载和资源分配: 一种主动推理方法. IEEE 传输. 暴民. 计算机, 23(12):11253–11264, 2024. [53] 胡欣怡, 陈子涵, 郭坤, 等. Adaptlink: 用于分布式 MLM 推理的异构感知自适应框架. 在过程中. AAAI 2025 研讨会 Artif. 英特尔. 无线通讯. 网络, AI4WCN, 2025. [54] Bhaskarjit Sarmah, Dhagash Mehta, Benika Hall 等人. Hybridrag: 集成知识图和向量检索增强生成, 以实现高效的信息提取. 在过程中. 第五届 ACM 国际赛. 会议. 人工智能金融, ICAIF, 第 608–616 页, 2024 年. [55] 胡亚奇, 叶东东, 康嘉文, 等. 物联网中基于多模式 LLM 的高级驾驶员辅助系统的云边缘协作架构. IEEE Internet Things J., 12(10):13208–13221, 2025. [56] Jiao Chen, Suyan Dai, Fangfang Chen, et al. 使用大语言模型进行自动驾驶的边云协作运动规划. 在过程中. IEEE ICCT, ICCT, 第 185–190 页, 2024 年. [57] Ya Liu, Kai Yang, Yu Zhu, 等. 云边缘 LLM 代理的灰盒提示优化和微调, 2024 年. [58] Canwen Xu, Yichong Xu, Shuohang Wang, et al. 小模型是大语言模型的有价值的插件. arXiv 预印本 arXiv:2305.08848, 2023. [59] Chi-Heng Lin, Shikhar Tuli, James Seale Smith, et al. Slim: 带有假设缩减的推测解码. 在过程中. 2024 年会议北上午. 第一章副教授. 计算. 语言学家: 嗯. 郎. 技术. (第 1 卷: 长论文), NAACL, 第 1005–1017 页, 2024. [60] 王继凯, 苏毅, 李俊涛, 等. Opt-tree: 具有自适应草案树结构的推测解码. 跨. 副教授. 计算. 语言学, 13: 188–199, 2025. [61] 夏鹤鸣, 李永琪, 张军, 等. Swift: 用于 llm 推理加速的即时自推测解码. 在过程中. 第 13 届国际. 会议. 学习. 代表, ICLR, 2025. [62] Jiahao Liu, Qifan Wang, Jingang Wang, et al. 通过提前退出进行推测解码, 以利用汤普森采样控制机制实现更快的 llm 推理. 在调查结果协会中. 计算. 语言学家, ACL, 第 3027–3043 页. [63] 龙景, 叶冠华, 陈童, 等. 基于扩散的云边设备协同学习, 用于下一个 POI 推荐. 在过程中. ACM SIGKDD 会议知道. 迪可夫. Data Min., KDD, 第 2026–2036 页, 2024 年. [64] Yuqing Tian, Zhaoyang Zhang, Yuzhi Yang, et al. 边缘-云协作框架, 用于通过协同的大云模型和小边缘模型提供生成式人工智能服务. IEEE Netw., 38(5):37–46, 2024. [65] Teresa Peng, Liam Liu, Maya Gupta, et al. 增强的混合推理技术, 用于可扩展的设备上 llm 个性化和云集成. 上下文, 8 (17): 18–25, 2024. [66] 蔡凤龙, 袁东, 杨哲, 等. Edge-llm: 服务于边缘计算的大语言模型的协作框架. 在 IEEE 国际. 会议. 网络服务, ICWS, 第 799–809 页, 2024 年. [67] Kunxi Li, Tianyu Zhan, Kairui Fu, et al. Mergenet: 跨异构模型、任务和模式的知识迁移. 在过程中. AAAI 会议阿蒂夫. Intel, AAAI, 第 39 卷, 第 4824–4832 页, 2025. [68] Zheqi Lv, Keming Ye, Zishu Wei, et al. 通过兼容性感知知识集成来优化不兼容的参数. 在过程中. AAAI 会议阿蒂夫. Intel, AAAI, 第 19233–19241 页, 2025. [69] Kairui Fu, Zheqi Lv, Shengyu Zhang, et al. 一次性转发: 结构参数化适应, 以实现高效的云协调设备上推荐. 第 31 届 ACM SIGKDD 知识发现和数据挖掘会议论文集, KDD, 第 318–329 页, 2025 年. [70] Kairui Fu, Shengyu Zhang, Zheqi Lv, et al. 饮食: 针对不兼容的网络进行序贯推荐的定制瘦身. 在过程中. ACM SIGKDD 会议知道. 迪可夫. 数据挖掘, KDD, 第 816–826 页, 2024 年. [71] Minsu Kim, Pinyarash Pinyoanuntapong, Bong-Ho Kim 等人. 边缘与云: 我们如何平衡 5G 网络上的大语言模型的成本、延迟和质量? 在过程中. IEEE 无线通信. 网络. Conf., WCNC, 第 1–6 页, 2025 年. [72] Jing Liu, Yao Du, Kun Yang, 等. 分布式智能和模型优化的边云协同计算: 一项调查. arXiv 预印本 arXiv:2505.01821, 2025. [73] 蒋中华, 徐济民, 张胜宇, 等. Fedcfa: 通过反事实联邦学习缓解模型聚合中的辛普森悖论. 在过程中. AAAI 会议阿蒂夫. 情报, AAAI, 第 17662–17670 页

[76] 唐子豪, 吕哲琪, 张胜宇, 等。Aug-kd: 基于锚的混合生成, 用于域外知识蒸馏。在过程中。第 12 届国际。会议。学习。代表, ICLR, 2024。[77] 张宇清, 李航奇, 张胜宇, 等。Llmco4mr: LLMS 辅助神经组合优化从碎片修复古代手稿并以敦煌为例。在过程中。欧元。会议。计算。Vis., ECCV, 第 15133 卷, 第 253-269 页, 2024 年。[78] Jimin Xu, Tianbao Wang, Tao Jin, et al. Mpod123: 使用掩模增强的渐进式轮廓到细节优化从一张图像生成 3D 内容。在 IEEE/CVF 会议中。计算。维斯。模式识别, CVPR, 第 10682-10692 页, 2024 年。[79] 范涛, 康彦, 马国强, 等。Fedcollm: 适用于大型和小型语言模型的参数高效联合协同调优框架。arXiv 预印本 arXiv:2411.11707, 2024。[80] Marc Glocker, Peter Hönig, Matthias Hirschmanner 等人。用于家庭机器人中记忆增强任务规划的 LLM 授权实体代理。arXiv 预印本 arXiv:2504.21716, 2025。[81] Yuxian Gu, Li Dong, Furu Wei, et al. Minillm: 大语言模型的知识蒸馏。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024 年。[82] M. Mehdi Mojarraadi, Lingyi Yang, Robert McCraith 等。使用小型语言模型集合改进上下文学习。arXiv 预印本 arXiv:2410.21868, 2024。[83] 徐冉, 石文奇, 庄雨辰, 等。Collab-rag: 通过白盒和黑盒 LLM 协作促进复杂问题回答的检索增强生成。arXiv 预印本 arXiv:2504.04915, 2025。[84] 张凯彦, 王建宇, 丁宁, 等。快与慢生成: 大小语言模型协同解码的实证研究。arXiv 预印本 arXiv:2406.12295, 2024。[85] Bin Chen, Yu Zhu, Hongfei Ye, et al. 知识解耦协同学习: 一种基于 MLLM 的协作方法, 用于少镜头多模态对话意图识别。在过程中。ACM Web Conf., WWW, 第 3044-3048 页, 2025。[86] Yu-Neng Chuang, Leisheng Yu, Guanchu Wang, 等。自信还是寻求更强: 探索基于不确定性的设备上 llm 路由从基准测试到泛化。arXiv 预印本 arXiv:2502.04428, 2025。[87] 邓永恒, 乔子清, 任举, 等。通过跨孤岛知识转移来相互增强大小语言模型。arXiv 预印本 arXiv:2312.05842, 2023。[88] Shangbin Feng, Taylor Sorensen, Yuhua Liu, et al. 模块化多元化: 通过多机构协作进行多元化调整。在过程中。会议。帝国。方法。自然。郎。Process., EMNLP, 第 4151-4171 页, 2024 年。[89] Yu-Chen Lin, Sanat Sharma, Hari Manikandan 等人。通过颠倒强化学习在小语言模型中进行高效的多任务学习。arXiv 预印本 arXiv:2502.09854, 2025。[90] 刘阳, 严冰杰, 邹天元, 等。利用大型和小型模型的协作能力来完成领域任务。arXiv 预印本 arXiv:2504.17421, 2025。[91] 徐吴江, 吴启田, 梁祖杰, 等。Slmrec: 将大型语言模型提炼为小型语言模型以进行顺序推荐。在过程中。第 13 届国际。会议。学习。代表。 , ICLR, 2025 年。[92] Pranjal Aggarwal, Aman Madaan, Ankit Anand 等人。Automix: 自动混合语言模型。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2024。[93] Collin Burns, Pavel Izmailov, Jan Hendrik Kirchner 等人。从弱到强的泛化: 用弱监督引出强能力。在过程中。国际。会议。马赫。学习。 , ICML, 2024。[94] 陈书豪, 蒋维森, 林白炯, 等。Routerdc: 基于查询的路由器, 通过双重对比学习来组装大型语言模型。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2024。[95] 陈伟泽, 苏玉生, 左经纬, 等。Agentverse: 促进多智能体协作并探索紧急行为。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024。[96] Yae Jee Cho, Luyang Liu, Zheng Xu, et al. 用于设备上基础模型联合微调的异构 lora。在过程中。会议。帝国。方法。自然。郎。Process., EMNLP, 第 12903-12913 页, 2024。[97] Dujian Ding, Ankur Mallick, Chi Wang, 等。混合 llm: 经济高效且具有质量意识的查询路由。在过程中。第 12 届国际。会议。学习。代表, ICLR, 2024。[98] 陈东, 庄月婷, 张硕, 等。数据分流: 小型和大型模型的协作, 以降低成本并提高性能。在过程中。AAAI 会议阿蒂夫。Intelli., AAAI, 第 38 卷, 第 11249-11257 页, 2024 年。[99] Cheng-Yu Hsieh, Chun-Liang Li, Chih-Kuan Yeh 等人。一步步蒸馏! 使用较少的训练数据和较小的模型大小优于较大的语言模型。在调查结果协会中。计算。语言学家, ACL, 第 8003-8017 页, 2023 年。

[100] Yaniv Leviathan, Matan Kalman 和 Yossi Matias。通过推测解码从 Transformer 进行快速推理。在过程中。国际。会议。马赫。学习。 , ICML, 2023。

[101] 刘家恒, 张晨晨, 郭金阳, 等。Ddk: 提炼领域知识以获得高效的大语言模型。在过程中。国际。会议。神经信息。过程。系统, NeurIPS, 2024。

[102] 刘跃江和亚历山大·阿拉希。共同监督学习: 通过专家的分层混合来提高从弱到强的泛化能力。arXiv 预印本 arXiv:2402.15505, 2024。

[103] 刘泽春, Barlas Oguz, 赵长胜, 等。Llm-qat: 大语言模型的无数据量化感知训练。在调查结果协会中。计算。语言学家, ACL, 第 467-484 页, 2024。[104] Zheqi Lv, Wenqiao Zhu, Shengyu Zhu, et al. Duet: 一种免调优的端云协同参数生成框架, 用于高效的设备模型泛化。在过程中。ACM Web Conf., WWW, 第 3077-3085 页, 2023 年。[105] Eric Mitchell, Rafael Rafailov, Archit Sharma 等人。用于使用小语言模型微调大语言模型的模拟器。在过程中。第 12 届国际。会议。学习。代表。ICLR, 第 16 页, 2024 年。[106] Isaac Ong, Amjad Almahairi, Vincent Wu 等人。Routellm: 学习根据偏好数据路由 llms。在过程中。第 13 届国际。会议。学习。代表。ICLR, 第 16 页, 2025 年。[107] Ankit Singh Rawat, Veeranjaneyulu Sadhanala, Afshin Rostamizadeh 等人。一点帮助就能大有帮助: 利用小型 lms 进行高效的 llm 培训。arXiv 预印本 arXiv:2410.18779, 2024。[108] Nikita Starodubcev, Dmitry Baranchuk, Artem Fedorov 等人。您的学生比预期的要好: 文本条件扩散模型的自适应师生协作。在 IEEE/CVF 会议中。计算。模式识别, CVPR, 第 9275-9285 页, 2024。[109] Heming Xia, Tao Ge, Peiyi Wang, et al. 推测性解码: 利用推测性执行来加速 seq2seq 的生成。在过程中。会议。帝国。方法自然。郎。Process., EMNLP, 第 3909-3925 页, 2023。[110] 夏孟周, 高天宇, 曾志远, 等。Sheared llama: 通过结构化修剪加速语言模型预训练。在过程中。第 12 届国际。会议。学习。代表, ICLR, 2024。[111] 慕容越, 赵杰, 张敏, 等。大语言模型与思维表征的混合级联, 以实现经济高效的推理。在过程中。第 12 届国际。会议。学习。代表, ICLR, 2024。[112] 钟其黄, 丁亮, 沉力, 等。重新审视自回归语言模型的知识蒸馏。在过程中。62 周年。见面。副教授。计算。语言学家。(ACL), 卷。1, ACL, 第 10900-10913 页, 2024。[113] Daihang Chen, Yonghui Liu, Mingyi Zhou, et al. 移动大语言模型: 初始路线图。ACM 翻译。软件。工程师。Methodol., 34(5), 2025。[114] 夏梦琳, 张旭超, Camille Couturier, 等。Hybrid-raca: 用于实时文本预测的混合检索增强合成辅助。在过程中。会议。帝国。方法自然。郎。Process., EMNLP, 第 120-131 页, 2024。[115] Zheming Yang, Yuanhao Yang, Chang Zhao, et al. Perllm: 针对各种 llm 服务的边缘云协作的个性化推理调度。arXiv 预印本 arXiv:2405.14636, 2024。[116] Yang Hu, Connor Imes, Xuanang Zhao 等人。Pipedge: 异构边缘设备上大规模模型推理的管道并行性。在第 25 届 Euromicro Conf. 数字。系统。Des., DSD, 第 298-307 页, 2022。[117] 张明金, 沉晓明, 曹建农, 等。Edgeshard: 通过协作边缘计算进行高效的 llm 推理。IEEE Internet Things J., 12(10):13119-13131, 2025。[118] 张新元, 聂江田, 黄玉东, 等。超越云: 无线网络中生成大语言模型的边缘推理。IEEE 传输。无线通信, 24(1):643-658, 2025。[119] 胡雅琪, 叶东东, 康嘉文, 等。物联网中基于多模式 LLM 的高级驾驶员辅助系统的云边缘协作架构。IEEE Internet Things J., 12(10):13208-13221, 2025。[120] 李明然, 张学军, 郭家胜, 等。具有网络修剪的云边缘协作推理。电子学, 12(17):3598, 2023。[121] 邢兴润, 刘峥, 肖世涛, 等。Efficientllm: 针对与架构无关的边缘语言模型的可扩展的剪枝感知预训练。arXiv 预印本 arXiv:2502.06663, 2025。[122] 姜鹏浩, 可欣, 李春熙, 等。高效端云协同变压器模型。在 IEEE/CVF 会议中。计算。模式识别, CVPR, 第 2204-2210 页, 2023。[123] Matthias Stammer, Vladimir Sidorenko, Fabian Kreß 等人。用于云边缘系统中无缝神经网络推理的上下文感知层调度。在 IEEE 第 16 届国际会议中。症状。嵌入式多核/众核片上系统, MCSoc, 第 97-104 页, 2023 年。[124] 罗浩, 田辉, 张鹏, 等。配电网中基于分布式神经网络的云边协同智能推理在国际。会议。天地空地计算, SAGC, 第 129-136 页, 2021 年。[125] Guangli Li, Lei Liu, Xueying Wang, et al. 自动调整神经网络量化框架, 用于云和边缘之间的协作推理。在国际。会议。阿蒂夫。神经网络。马赫。Learn., ICANN, 第 11139 卷, 第 402-411 页, 2018 年。[126] Weilin Zhao, Yuxiang Huang, Xu Han 等人。Ouroboros: 逐句生成更长的草稿, 以实现更快的推测解码。在过程中。会议。帝国。方法自然。郎。Process., EMNLP, 第 13378-13393 页, 2024 年。[127] Zhuoming Chen, Avner May, Ruslan Svirschevski 等人。红杉: 可扩展且稳健的投机性

- [131] 苗旭鹏, Gabriele Oliaro, 张志豪, 等。Specinfer: 通过基于树的推测推理和验证来加速大语言模型。在过程中。第 29 届 ACM 国际赛会议。建筑师。支持计划。郎.歌剧。系统, 卷。3, ASPLOS, 第 932-949 页, 2024 年。[132] 吴华明, 顾安琪, 梁永辉。联合强化学习支持车辆边缘计算中大型模型的任务卸载。IEEE 传输。呃。科技, 74(2):1979–1991, 2025。[133] 翁业鹏, 胡巧, 陈旭杰, 等。推测树解码的遍历验证。arXiv 预印本 arXiv:2505.12398, 2025。[134] Zhuoming Chen, Avner May, Ruslan Svirshchevski, et al. Sequoia: 可扩展且强大的推测解码。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2024。[135] Bradley McDanel、Sai Xian Zhang、Yunhai Hu 等人。Pipespec: 打破分层 llm 解码中的阶段依赖性。arXiv 预印本 arXiv:2505.01572, 2025。[136] Jinyu Liu 和 Ce Zhang。汉堡包: 通过令牌粉碎加速 llm 推理。arXiv 预印本 arXiv:2505.20438, 2025。[137] Yongchao Zhou, Kaifeng Lyu, Ankit Singh Rawat, et al. Distillspec: 通过知识蒸馏改进推测解码。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024 年。[138] Avanika Narayan, Dan Biderman, Sabri Eyuboglu 等人。Minions: 设备上和云语言模型之间具有成本效益的协作。arXiv 预印本 arXiv:2502.15964, 2025。[139] Gemini 团队、Rohan Anil、Sebastian Borgeaud 等人。Gemini: 一系列高性能的多式联运模型。arXiv 预印本 arXiv:2312.11805, 2025。[140] Marah Abdin, Jyoti Aneja, Hany Awadalla 等人。Phi-3 技术报告: 手机本地的高性能语言模型。arXiv 预印本 arXiv:2404.14219, 2024。[141] OpenAI, Aaron Hurst, Adam Lerer 等人。Gpt-4o 系统卡。arXiv 预印本 arXiv:2410.21276, 2024。[142] S Anthropic。模型卡附录: 克劳德 3.5 俳句和升级版克劳德 3.5 十四行诗。网址 <https://api.openai.com/v1/models/gpt-4o-mini>。[143] 保护条例。一般数据保护法规。Intouch, 25:1–5, 2018。[144] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin 等。Palm: 通过路径扩展语言建模。J. 机器学习。论文, 24:240:1–240:113, 2023。[145] Sebastian Carladas, Sai Meher Karthik Duddu, Peter Wu 等。Leaf: 联合设置的基准。arXiv 预印本 arXiv:1812.01097, 2019。[146] Tzu-Ming Harry Hsu, Hang Qi 和 Matthew Brown。联合视觉分类与真实世界的分布。在过程中。欧元。会议。计算。Vis., ECCV, 第 12 卷, 第 76-92 页, 2020 年。[147] Yinhe Cheng, Guanyi Chen, Minlie Huang, et al。具有多样化特征的个性化对话生成。arXiv 预印本 arXiv:1901.09672, 2019。[148] Saizheng Zhang, Emily Dinan, Jack Urbanek, et al。个性化对话代理: 我有一只狗, 你也有宠物吗? 在过程中。56 周年。见面。副教授。计算。语言学家, ACL, 第 2204-2213 页, 2018。[149] Jingsheng Gau, Yixin Lian, Ziyi Zhou, et al。Livechat: 根据直播自动构建的大规模个性化对话数据集。在过程中。61 周年。见面。副教授。计算。语言学家。(ACL), 卷。1, ACL, 第 15387–15405 页, 2023。[150] Fan Lai, Yinwei Dai, Sanjay Sri Vallabh Singapuram, et al。FedScale: 大规模联邦学习的基准模型和系统性能。在过程中。国际。会议。马赫。Learn., ICML, 第 162 卷, 第 11814–11827 页, 2022。[151] Bill Yuchen Lin, Chaoyang He, Zihang Ze, et al。FedNLP: 自然语言处理任务的联邦学习方法基准测试。在调查结果协会中。计算。语言学家, NAACL, 第 157-175 页, 2022。[152] Tiantian Feng, Digbalay Bose, Tuo Zhang, 等。Fedmultimodal: 多模式联合学习的基准。在过程中。ACM SIGKDD 会议知道。迪可夫。数据挖掘, KDD, 第 4035–4045 页, 2023 年。[153] Daoyuan Chen, Dawei Gau, Weirui Kuang, et al。pfl-bench: 个性化联邦学习的综合基准。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2022。[154] Yu Cheng Ding, Chaoyue Niu, Fan Wu, et al。通过推荐系统中的标签校正进行设备上模型微调。arXiv 预印本 arXiv:2211.01163, 2022。[155] Han Zhu, Junqi Jin, Chang Tan, et al。优化淘宝展示广告单次点击费用。在过程中。ACM SIGKDD 会议知道。迪可夫。数据挖掘, KDD, 第 2191–2200 页, 2017 年。[156] Eduardo Zimelewicz, Marcos Kalinowski, Daniel Méndez 等人。支持机器学习的系统模型部署和监控: 现状和问题。在第 16 届国际比赛中。会议。软件。Qual., SWQD, 第 505 卷, 第 112–131 页, 2024 年。[157] Xiaoqi Jiao, Yichun Yin, Lifeng Shang, 等。Tinybert: 提炼 BERT 以实现自然语言理解。在过程中。会议。帝国。方法 自然。郎。Process., EMNLP, 第 4163–4174 页, 2020 年。[158] Kallista A. Bonawitz, Hubert Eichner, Wolfgang Grieskamp 等人。迈向大规模联合学习: 系统设计。在过程中。第二次会议马赫。学习。系统, SysML, 2019。[159] 何朝阳, 李松泽, 苏金贤,

- [161] Daniel J. Beutel, Taner Topal, Akhil Mathur 等人。Flower: 一个友好的联邦学习研究框架。arXiv 预印本 arXiv:2007.14390, 2022. [162] 陈毅, 赵家豪, 韩浩浩。大小语言模型之间协作机制的调查。arXiv 预印本 arXiv:2505.07460, 2025. [163] Chaoyue Niu, Yu Cheng Ding, Junhui Lu, et al.设备上小模型和基于云的大模型的协作学习: 进展和未来方向。arXiv 预印本 arXiv:2504.15300, 2025. [164] Saurabh Pahune 和 Zahid Akhtar。从 mlops 过渡到 llmops: 应对大语言模型的独特挑战。信息, 16(2), 2025. [165] 辛泽伟, 李勤亚, 牛超跃, 等。具有令牌级多度量预测的文本到图像模型的边缘云路由。arXiv 预印本 arXiv:2411.13787, 2024. [166] Keming Lu, Hongyi Yuan, Runji Lin, et al.路由到专家: 高效的奖励引导的大语言模型集成。在过程中。2024 年会议北上。第一章副教授。计算。语言学家: 嗯。郎。技术。(第 1 卷: 长论文), NAACL, 第 1964-1974 页, 2024 年。[167] Lingjiao Chen, Matei Zaharia 和 James Zou。FrugalGPT: 如何使用大语言模型, 同时降低成本并提高性能。跨。马赫。学习。研究, 2024. [168] 王一丁, 陈凯, 谭海生, 等。Tabi: 大型语言模型的高效多级推理系统。在过程中。18 欧元。会议。计算。Syst., EuroSys, 第 233-248 页, 2023 年。[169] Xinyuan Wang, Yanchi Liu, Wei Cheng, et al。MixLLM: 混合大语言模型中的动态路由。在过程中。2025 年会议北上。第一章副教授。计算。语言学家: 嗯。郎。技术。(第 1 卷: 长论文), NAACL, 第 10912-10922 页, 2025. [170] 王一乐, 李鹏, 孙茂松, 等。大语言模型的自我知识引导检索增强。在过程中。会议。帝国。方法。自然。郎。Process., EACL, 第 10303-10315 页, 2023. [171] Akari Asai, Zeqiu Wu, Yizhong Wang, et al。Self-RAG: 通过自我反思学习检索、生成和批判。在过程中。第 12 届国际。会议。学习。代表。ICLR, 2024. [172] Shi-Qi Yan, Jia-Chen Gu, Yun Zhu, et al。纠正检索增强了生成。arXiv 预印本 arXiv:2401.15884, 2024. [173] Yanming Liu, Xinyue Peng, Xuhong Zhang, et al。Ra-isf: 通过迭代自我反馈从检索增强中学习回答和理解。在调查结果协会中。计算。语言学家, ACL, 第 4730-4749 页, 2024. [174] Jiejun Tan, Zhi Cheng Dou, Yutao Zhu, et al。小模型, 大见解: 利用精简代理模型来决定何时以及为 llms 检索什么。在过程中。62 周年。见面。副教授。计算。语言学家。(ACL), 卷。1, ACL, 第 4420-4436 页, 2024 年。[175] Timo Schick, Jane Dwivedi-Yu, Roberto Dessi 等人。Toolformer: 语言模型可以自学使用工具。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2023. [176] 冯尚斌, 施维佳, 白宇阳, 等。知识卡: 通过插件专用语言模型填补 llms 的知识空白。在过程中。第 11 国际。会议。学习。代表, ICLR, 2023. [177] Tianlin Li, Qian Liu, Tianyu Pang, et al。通过集成小语言模型来纯化大语言模型。arXiv 预印本 arXiv:2402.14845, 2024. [178] Dheeraj Mekala, Alex Nguyen 和 Jingbo Shang。较小的语言模型能够为较大的语言模型选择指令调整训练数据。在调查结果协会中。计算。语言学家, ACL, 第 10456-10470 页, 2024. [179] 唐雪梅和王军。小语言模型作为中文关系提取中大语言模型的有效指导。arXiv 预印本 arXiv:2402.14373, 2024. [180] 周阳, 任兆春, 王玉峰, 等。通过使用小规模移情模型增强 LLMs 来增强移情反应的生成。arXiv 预印本 arXiv:2402.11801, 2024. [181] 李海涛, 艾庆耀, 陈佳, 等。Blade: 使用小型特定领域模型增强黑盒大语言模型。在过程中。AAAI 会议阿蒂夫。Intelli., AAAI, 第 39 卷, 第 24422-24430 页, 2025. [182] 赵昆, 杨博浩, 唐陈, 等。SLIDE: 集成小型和大语言模型的框架, 用于开放域对话评估。在调查结果协会中。计算。语言学家, ACL, 第 15421-15435 页, 2024. [183] Wenhao Cheng, Yixiao Chen, Weitong Zhang, et al。Citer: 通过令牌级路由进行高效大语言模型解码的协作推理。arXiv 预印本 arXiv:2502.01976, 2025. [184] Yufei Zhu, Chaoyue Niu, Yikai Yan, et al。用于直播内容理解的设备-单模态云-多模态协作。在 IEEE 国际。会议。Data Min., ICDM, 第 1571-1576 页, 2023. [185] Jiaxing Li, Chi Xu, Lianchen Jia, et al。Eaco-rag: 使用边缘辅助和协作 rag 以及自适应知识更新, 实现分布式分层 llm 部署。arXiv 预印本 arXiv:2410.20299, 2025. [186] Masoomali Fatehkia, Ji Kim Lucas 和 Sanjay Chawla。T-rag: 来自 llm 战壕的教训。arXiv 预印本 arXiv:2402.07483, 2024. [187] 郑

[189]朱云, 顾嘉晨, Caitlin Sikora, 等。通过稀疏上下文选择加速检索增强生成的推理。在过程中。第13届国际。会议。学习。代表, ICLR, 2025。[190]秦瑞阳, 严哲宇, 曾德文, 等。在基于边缘的内存计算架构上稳健地实现检索增强生成。在过程中。第43届IEEE/ACM国际会议会议。计算机辅助设计, ICCAD, 2025。[191] Tianyu Liu, Yun Li, Qitan Lv, et al. Pearl: 具有自适应草稿长度的并行推测解码。在过程中。第13届国际。会议。学习。代表。 , ICLR, 2025。[192] Seong Hoon Seo, Junghoon Kim, Donghyun Lee 等人。Facil: 灵活的 DRAM 地址映射, 用于 soc-pim 协作设备上 LLM 推理。在 IEEE 国际。症状。高性能。计算。Archit., HPCA, 第 1720–1733 页, 2025。[193] Weiyi Sun, Mingyu Gau, Zhaoshi Li, et al. Lincoln: 在具有 lddr 接口、支持计算的闪存的消费设备上进行实时 50~100b LLM 推理。在 IEEE 国际。症状。高性能。计算。Archit., HPCA, 第 1734–1750 页。IEEE, 2025。[194] 高翔翔, 谢伟胜, 向一伟, 等。Falcon: 通过增强的半自回归绘图和定制设计的解码树, 更快、并行地推理大语言模型。在过程中。AAAI 会议阿蒂夫。Intel., AAAI, 第 23933–23941 页, 2025。[195] Shensian Syu 和 Hung-yi Lee。使用动态窗口的分层推测解码。在过程中。2025 年会议北上。第一章副教授。计算。语言学家: 嗯。郎。技术。(第 1 卷: 长论文), NAACL, 2025。[196] Minsu Kim, Alexander DeRieux 和 Walid Saad。一种通过无线网络进行个性化、节能的分裂学习的讨价还价游戏。在过程中。IEEE 无线通信。网络。Conf., WCNC, 第 1-6 页, 2023 年。[197] Chia-Chuan Chuang 和 Kai-Ching Chen。混合云上的检索增强生成: 知识库系统的新架构。在第 16 届 IIAI 国际会议上。国会议员。副词。应用。通知。 , IIAI-AAI, 第 68-71 页, 2024 年。[198] Aniruddha Salve, Saba Attar, Mahesh Deshmukh 等人。一种协作多代理方法, 可跨不同数据进行检索增强生成。arXiv 预印本 arXiv:2412.05838, 2024。[199] Pei Chen, Shuai Zhang, and Boran Han。CoMM: 协作多智能体、多推理路径提示解决复杂问题。在过程中。2024 年会议北上。第一章副教授。计算。语言学家: 嗯。郎。技术。(第 1 卷: 长论文), NAACL, 第 1720–1738 页, 2024 年。[200] Ziyang Jiang, Xueguang Ma 和 Wenhui Chen。Longrag: 通过长上下文 LLMS 增强检索增强生成。arXiv 预印本 arXiv:2406.15319, 2024。[201] Minghan Li, Xilun Chen, Ari Holtzman, et al.用于 llm 生成和归因的最近邻推测解码。过程。国际。会议。神经信息。过程。Syst., NeurIPS, 37:80987–81015, 2024。[202] Yulu Gan, Mingjie Pan, Rongyu Zhu, et al.云设备协作适应现实世界中不断变化的环境。在 IEEE/CVF 会议中。计算。维斯。模式识别, CVPR, 第 12157–12166 页, 2023。[203] Yuxuan Chen, Rongpeng Li, Xiaoxue Yu, et al。边缘计算中无线 llm 推理的自适应层分割: 一种基于模型的强化学习方法。arXiv 预印本 arXiv:2406.02616, 2024。[204] 叶盛源, 杜江苏, 曾列康, 等。Galaxy: 用于原位变压器推理的资源高效协作边缘人工智能系统。在过程中。IEEE INFOCOM, 第 1001–1010 页, 2024。[205] Anil Kag, Igor Fedorov, Aditya Gangrade 等人。通过选择性查询进行高效边缘推断。在过程中。第11国际。会议。学习。代表。 , ICLR, 2023。[206] Zhanhui Zhou, Zhixuan Liu, Jie Liu, et al。从弱到强的搜索: 通过搜索小语言模型来对齐大语言模型。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2025。[207] Zihua Wang, Ruijie Li, Haozhe Du, et al。Flash: 用于多模态任务的潜在感知半自回归推测解码。arXiv 预印本 arXiv:2505.12728, 2025。[208] Mukul Gagrani, Raghav Goel, Wonseok Jeon 等人。关于多模态大语言模型的推测解码。在过程中。IEEE/CVF 会议计算。维斯。模式识别。研讨会, CVPRW, 第 8285–8289 页, 2024 年。[209] Yiran Zhao, Wenyue Cheng, Tianle Cai, et al。通过探针采样加速贪婪坐标梯度和一般提示优化。在过程中。国际。会议。神经信息。过程。Syst., NeurIPS, 2025。[210] 王正林, 吴嘉龙, 赖一龙, 等。种子: 通过预定的推测解码加速推理树的构建。在过程中。国际。会议。计算。语言学家, COLING, 第 4920–4937 页, 2025。[211] Zilong Wang, Zifeng Wang, Long Le, et al。推测性抹布: 通过起草增强检索增强生成。在过程中。第13届国际。会议。学习。代表, ICLR, 2025。[212] Wenda Xu, Rujun Han, Zifeng Wang, et al。推测性知识蒸馏: 通过交错采样弥合师生差距。在过程中。第13届国际。会议。学习。代表。 , ICLR, 2025。[213] Valentin De Bortoli, Alexandre Galashov, Arthur Gretton 等

[216]胡恒源, Aniket Das, Dorsa Sadigh, 等。扩散模型可以秘密交换: 通过自动推测并行化 ddpm。在过程中。国际。会议。马赫。学习。 , ICML, 2025。 [217] Ziteng Sun, Ananda Theertha Suresh, Jae Hun Ro, et al. Spectr: 通过最佳传输进行快速推测解码。在过程中。国际。会议。神经信息。过程。系统, NeurIPS, 2023。 [218] 杜存晓, 蒋静, 徐元辰, 等。Glide with a Cape: 一种加速推测解码的低麻烦方法。在过程中。国际。会议。马赫。学习。 , ICML, 2024。 [219] Haifeng Qi, Sujan Kumar Gonugondla, Sungsoo Ha, et al. Bass: 批量注意力优化推测采样。在调查结果协会中。计算。语言学家, ACL, 第 8214–8224 页, 2024。 [220] Heming Xia, Yongqi Li, Jun Chang, et al. Swift: 用于 llm 推理加速的即时自推测解码。在过程中。第 13 届国际。会议。学习。代表, ICLR, 2025。 [221] Xinyu Lin, Chaoqun Yang, Wenjie Wang, et al. 基于大语言模型的生成推荐的有效推理。在过程中。第 13 届国际。会议。学习。代表, ICLR, 2025。 [222] 李正毅, 关悦, 杨康, 等。高效的私有 gpt 永远不会进行自回归解码。在过程中。国际。会议。马赫。学习。 , ICML, 2025。 [223] Ziyao Wang, Muneeza Azmat, Ang Li, et al. 推测, 然后协作: 在解码过程中融合语言模型的知识。在过程中。国际。会议。马赫。学习。 , ICML, 2025。 [224] 文浩, 李元春, 刘国宏, 等。Autodroid: Android 中由 Llm 驱动的任务自动化。在过程中。30 周年。国际。会议。移动计算。Netw., MobiCom, 第 543–557 页, 2024 年。 [225] Yanis Labrak, Adrien Bazoge, Emmanuel Morin 等人。Biomistral: 用于医学领域的开源预训练大型语言模型的集合。在调查结果协会中。计算。语言学家, ACL, 第 5848–5864 页, 2024 年。 [226] 向建南, 陶天华, 顾一, 等。语言模型符合世界模型: 具体体验增强了语言模型。过程。国际。会议。神经信息。过程。Syst., NeurIPS, 36:75392–75412, 2023。 [227] Yun Zhu, Yinxiao Liu, Felix Stahlberg, et al. 用于文本重写的设备上代理。在过程中。2024 年会议北上。第一章副教授。计算。语言学家: 嗯。郎。技术。 (第 1 卷: 长论文), NAACL, 第 2535–2552 页, 2024 年。 [228] Chi-Min Chan, Weize Chen, Yusheng Su, et al. Chateval: 通过多主体辩论建立更好的基于大语言模型的评估者。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024。 [229] 田元和, 夏飞, 宋岩。基于大语言模型的专家混合对话总结。在过程中。62 周年。见面。副教授。计算。语言学家。 (ACL), 卷。1, ACL, 第 7143–7155 页, 2024 年。 [230] Izzeddin Gur, Hiroki Furuta, Austin V Huang 等人。具有规划、长期上下文理解和程序综合功能的现实世界网络代理。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024。 [231] Yun Z hu, Jia-Chen Gu, Caitlin Sikora, et al. 通过稀疏上下文选择加速检索增强生成的推理。在过程中。第 13 届国际。会议。学习。代表。 , ICLR, 2025。 [232] Volodymyr Kuleshov. Minillm: 消费者 GPU 上的大语言模型。 <https://github.com/kuleshov/minillm>, 2023。 [233] Yuxian Gu, Li Dong, Furu Wei, et al. Minillm: 大型语言模型的知识蒸馏。在过程中。第 12 届国际。会议。学习。代表。 , ICLR, 2024。 [234] Xiaoqi Jiao, Yichun Yin, Lifeng Shang, et al. TinyBERT: 提炼 BERT 以实现自然语言理解。在过程中。会议。帝国。方法自然。郎。Process., EMNLP, 第 4163–4174 页, 2020。 [235] Qwen, An Yang, Baosong Yang, et al. Qwen2.5 技术报告。arXiv 预印本 arXiv:2412.15115, 2025。 [236] Sachin Mehta, Mohammad Hossein Sekhavat, Qingqing Cao 等人。Openelm: 一个高效的语言模型家族, 具有开放的训练和推理框架。arXiv 预印本 arXiv:2404.14619, 2024。 [237] 杜正晓, 钱玉杰, 刘晓, 等。GLM: 具有自回归空白填充的通用语言模型预训练。在过程中。60 周年。见面。副教授。计算。语言学家。 (ACL), 卷。1, ACL, 第 320–335 页, 2022 年。 [238] Ross Taylor, Marcin Kardas, Guillem Cucurull 等人。卡拉狄加: 大型科学语言模型。arXiv 预印本 arXiv: 2211.09085, 2022。 [239] Gemma Team, Morgane Riviere, Shreya Pathak 等人。Gemma 2: 以实际规模改进开放语言模型, 2024 年。 [240] OpenAI, Josh Achiam, Steven Adler 等人。Gpt-4 技术报告。arXiv 预印本 arXiv:2303.08774, 2024。 [241] GLM 团队。Chatglm: 大语言模型系列, 从 glm-130b 到 glm-4 所有工具。arXiv 预印本 arXiv:2406.12793, 2024。 [242] 阿里巴巴达摩院。达摩院十大技术趋势, 2022。 [243] 高通。人工智能的未来是混合型的; 第一部分: 通过设备端人工智能和混合人工智能解锁生成式人工智能的未来。 <https://www.qualcomm.com/content/dam/qcomm-martech/dm-assets/documents/Whitewater-The-future-of-AI-is-hybrid-Part-1-Unlocking-the-generative-AI-future-with-on-device-and-hybrid-AI.pdf>, 2024。 [244] Heming Xia, Zhe Yang, Qingxiu Dong 等人。释放效率

scale-hybrid-AI.pdf, 2024. [246] 徐文超, 陈金字, 郑培荣, 等. 部署基础模型驱动的代理服务: 一项调查. IEEE 通信. 幸存者. 导师, 第 1-1 页, 2025 年. [247] 程一航, 张兰, 王俊阳, 等. Remoterag: 一种保护隐私的 llm 云抹布服务. arXiv 预印本 arXiv:2412.12775, 2024. [248] Minrui Xu, Hongyang Du, Dusit Niyato, et al. 在移动网络中释放边缘云生成人工智能的力量: aigc 服务调查. IEEE 通信. 幸存者. 导师., 26(2):1127–1170, 2024. [249] 顾惠贤, 赵立强, 朱涵, 等. 人工智能增强的云端协同网络: 综述、应用和未来方向. IEEE 通信. 幸存者. 导师., 26(2):1322–1385, 2024. [250] 王建宇, 潘建利, Flavio Esposito, 等人. 边缘云卸载算法: 问题、方法和观点. ACM 计算. Surv., 52(1):2:1–2:23, 2019. [251] 庄艳, 郑振哲, 吴凡, 等. Litemoe: 通过代理子模型调整自定义设备上 llm 服务. 在过程中. 第 22 届 ACM 会议嵌入式网络传感器系统, SenSys, 第 521–534 页, 2024 年. [252] Haseena Rahmath P, Vishal Srivastava, Kuldeep Chaurasia 等人. 提前退出深度神经网络 - 全面调查. ACM 计算. Surv., 57(3):75:1–75:37, 2025. [253] 欧杰, 陈月明, 田教授. 通过自适应 n-gram 并行解码无损加速大语言模型. 在过程中. 2024 年会议北上. 第一章副教授. 计算. 语言学家: 嗯. 郎. 技术. (第 1 卷: 长论文), NAACL, 第 10-22 页, 2024 年. [254] Biao Yi, Xavier Hu, Yurun Chen, et al. Ecoagent: 一种用于移动自动化的高效边缘云协作多代理框架. arXiv 预印本 arXiv:2505.05440, 2025. [255] Junhao Feng, Boyang Huang, Xiaodong Zhou, et al. 基于大规模多智能体学习的云边协同分布式光伏数据压缩和电力系统多模态网络信息聚合 IEEE 传输. 消耗. 电子, 71(1):30–40, 2025. [256] 庄艳, 郑振哲, 邵云峰, 等. Eclm: 高效的边云协同学习, 持续环境适应. arXiv 预印本 arXiv:2311.11083, 2023. [257] 高洪军, 王仁军, 何帅家, 等. 使用多智能体深度强化学习进行配电网重构的云边协作解决方案. IEEE 传输. 电力系统, 39(2):3867–3879, 2024. [258] Sangmin Bae, Jongwoo Ko, Hwanjun Song, et al. 快速且强大的早期退出框架, 用于具有同步并行解码的自回归语言模型. 在过程中. 会议. 帝国. 方法 自然. 郎. Process., EMNLP, 第 5910–5924 页, 2023 年. [259] Neeraj Varshney, Agneet Chatterjee, Mihir Parmar 等人. 通过使用 “lite” 进行指令调整来启用中间层解码, 研究 llama 推理的加速. 在过程中. 2024 年会议北上. 第一章副教授. 计算. 语言学家: 嗯. 郎. 技术. (第 1 卷: 长论文), NAACL, 第 3656–3677 页, 2024 年. [260] Daniel Rotem, Michael Hassid, Jonathan Mamou 等人. 找到最佳位置: 低资源环境下自适应推理的分析和改进. 在过程中. 61 周年. 见面. 副教授. 计算. 语言学家. (ACL), 卷. 1, ACL, 第 14836–14851 页, 2023. [261] Yanxi Chen, Xuchen Pan, Yaliang Li, et al. Ee-llm: 具有 3d 并行性的早期退出大语言模型的大规模训练和推理. 在过程中. 国际. 会议. 马赫. 学习., ICML, 2024. [262] 姚江超, 张胜宇, 姚洋, 等. 边缘云极化与协作: 人工智能综合调查. IEEE 传输. 在知识上. 和数据工程, 35(7):6866–6886, 2023. [263] 钱旭峰, 徐悦, 吕福宇, 等. 推荐系统中的智能请求策略设计. 在过程中. ACM SIGKDD 会议知道. 迪可夫. 数据挖掘, KDD, 第 3772–3782 页, 2022 年. [264] Chengfei Lv, Chaoyue Niu, Renjie Gu, et al. Walle: 用于端云协作机器学习的端到端、通用、大规模生产系统. 在第 16 届 USENIX Symp 中. 歌剧. 系统. 德斯. 实施, OSDI, 第 249–265 页, 2022 年. [265] 罗西团队. 洛溪模型. https://github.com/luoxi-model/luoxi_models, 2024 年. 访问时间: 2025 年 6 月 28 日. [266] 刘宇航, 李鹏翔, 魏子树, 等. Infiguiagent: 具有原生推理和反射功能的多模式通用 GUI 代理. arXiv 预印本 arXiv:2501.04575, 2025. [267] 廖虎. 用于智能移动应用程序的混合边缘人工智能框架: 利用大型语言模型实现设备上的上下文帮助和代码感知自动化. J. 工业工程杂志. 应用. 科学, 3(3):10–22, 2025. [268] Jasper Dekoninck, Maximilian Baader 和 Martin Vechev. LLMS 的统一路由和级联方法. arXiv 预印本 arXiv:2410.10347, 2024. [269] 杨丽. Llm bandit: 通过偏好条件动态路由生成具有成本效益的 llm. arXiv 预印本 arXiv:2502.02743, 2025. [270] 胡金武, 王玉峰, 张树海, 等. 大语言模型专家的动态集成推理. arXiv 预印本 arXiv:2412.07448, 2024. [271] Xiaoding Lu, Zongyi Liu, Adrian Liusic, et al. 混合就是全部

[273] 张家乐, 陈家祥, 李祝聪, 等。Slimrag: 通过实体感知上下文选择进行无图检索。arXiv 预印本 arXiv:2506.17288, 2025。[274] Reza Yousefi Maragheh, Pratheek Vadla, Priyank Gupta 等人。Arag: 代理检索增强了个性化推荐的生成。arXiv 预印本 arXiv:2506.21931, 2025。[275] 郭龙坤, 林嘉伟, 徐宣明, 等。边缘云环境中具有子模块优化的成本驱动任务卸载的算法和复杂性。arXiv 预印本 arXiv:2411.15687, 2024。[276] Weizhong, Manasa Bharadwaj, Yixiao Wang, et al. 交叉注意力推测解码。arXiv 预印本 arXiv:2505.24544, 2025。[277] 戴阳, 安建翔, 林天伟, 等。Graft: 通过 mllms 的有效参数协同集成领域知识。arXiv 预印本 arXiv:2506.23940, 2025。[278] Huaiying Luo 和 Cheng Ji。基于联邦学习的数据协作方法, 利用大语言模型增强边缘云人工智能系统安全性。arXiv 预印本 arXiv:2506.18087, 2025。[279] Ling Li, Lidong Zhu 和 Weibang Li。云-边-端协作联合学习: 增强非独立同分布环境中的模型准确性和隐私性。传感器, 24(24), 2024。[280] Qihao Lu, Dejing Dou, 和 Thien Huu Nguyen。来自多个来源的参数高效的领域知识集成, 用于生物医学预训练语言模型。Marie-Francine Moens, Xuanjing Huang, Lucia Specia 和 Scott Wen-tau Yih, 编辑, Proc. 会议。帝国。方法自然。郎。Process., EMNLP, 第 3855–3865 页, 2021 年。[281] Sourav Das, Sanjay Chatterji 和 Imon Mukherjee。Acknowledge: 无需预训练即可通过小语言模型获得知识表示。在过程中。第一届知识研讨会。郎。模型, Know LLM, 第 83-95 页, 2024 年。[282] Chitranshu Harbola 和 Anupam Purwar。Knowslm: 用于评估知识增强和人性化对话的小语言模型的框架。arXiv 预印本 arXiv:2504.04569, 2025。[283] 王坤, 张桂斌, 周振红, 等。llm (-agent) 全栈安全性的全面调查: 数据、培训和部署。arXiv 预印本 arXiv:2504.15585, 2025。[284] 余建树, 李卓豪, 黄哲民, 等。鹰眼: 模型协作高效推理。arXiv 预印本 arXiv:2504.00424, 2025。[285] Chaoyou Fu, Haojia Lin, Xiong Wang, 等。Vita-1.5: 迈向 gpt-4o 级别的实时视觉和语音交互。arXiv 预印本 arXiv:2501.01957, 2025。[286] 马正, 王长鑫, 黄博, 等。边界和填充: 快速灵活的图像字幕框架。在纳特。郎。过程。下巴。计算机, NLPCC, 第 469-481 页, 2023 年。[287] Evan King, Haoyang Yu, Sahil Vartak 等。深思熟虑的事情: 用小语言模型构建以人为中心的智能设备。arXiv 预印本 arXiv:2405.03821, 2024。[288] 陈志军, 李景正, 陈鹏鹏, 等。利用多个大型语言模型: 关于 llm 集成的调查。arXiv 预印本 arXiv:2502.18036, 2025。[289] DeepSeek-AI, Aixin Liu, Bei Feng, et al. Deepseek-v3 技术报告。arXiv 预印本 arXiv:2412.19437, 2025。[290] Fahao Chen, Peng Li, Tom H. Luan, et al. Spin: 利用异构推测模型加速大型语言模型推理。在过程中。IEEE INFOCOM, 第 1-10 页, 2025 年。[291] Yeshwanth Venkatesha, Souvik Kundu 和 Priyadarshini Panda。快速且经济高效的推测性边缘云解码, 并提前退出, 2025 年。[292] Jingling Yuan, Yao Shang, Yuhui Deng, et al. UPOA: 一种基于用户偏好的延迟和能源感知智能卸载方法, 适用于云边缘系统。IEEE 传输。云计算, 11(2):2188–2203, 2023。[293] 刘晓阳, 朱荣义, 查道辰, 等。使用联邦学习对大语言模型进行差分私有低秩适应。ACM 翻译。马纳格。信息。系统, 16(2):1–24, 2025。[294] 苗虎, 何琪, 吴迪。QLLMS: 用于部分通知边缘服务系统的量化自适应 LLM 调度。在过程中。IEEE INFOCOM, 第 1-10 页。IEEE, 2025。[295] 刘昌和赵军。提高边缘辅助移动系统的 LLM 培训的稳定性和资源效率。IEEE 传输。暴民。计算机, 第 1-18 页, 2025 年。