

同步定位与测绘的过去、现在和未来 ：迈向鲁棒感知时代

塞萨尔·卡德纳、卢卡·卡龙、亨利·卡里略、亚西尔·拉蒂夫、大卫·斯卡拉穆扎、何塞·内拉、伊恩·里德和约翰·J·伦纳德

Abstract—同步定位和建图 (SLAM) 包括同时构建环境模型 (*map*)，以及估计在其中移动的机器人的状态。SLAM 社区在过去 30 年中取得了惊人的进步，实现了大规模的现实应用，并见证了该技术向工业的稳步过渡。我们调查了 SLAM 的现状并考虑了未来的方向。我们首先介绍现在的 SLAM *de-facto* 标准公式。然后，我们回顾相关工作，涵盖广泛的主题，包括长期映射的鲁棒性和可扩展性、映射的度量和语义表示、理论性能保证、主动 SLAM 和探索以及其他新领域。本文同时作为 SLAM 用户的立场文件和教程。通过以批判的眼光审视已发表的研究，我们描绘了仍值得仔细科学研究的开放挑战和新研究问题。该论文还包含作者对机器人会议期间经常引发讨论的两个问题的看法：

Do robots need SLAM? 和 *Is SLAM solved?*

Index Terms—因子图、定位、建图、最大后验估计、感知、机器人、传感、同步定位和建图 (SLAM)。

稿件接收日期：2016年7月29日；2016年10月31日修订；接受日期：2016年10月31日。当前版本日期：2016年12月2日。在评估审稿人的意见后，副主编 J. M. Porta 和编辑 C. Torras 推荐发表该论文。这项工作得到了以下部分的支持：Grant MINECO-FEDER DPI2015-68905-P、Grant Grupo DGA T04-FSE；ARC 拨款 DP130104413、拨款 CE140100016 和拨款 FL130100102；NCCR 机器人；授予 PUJ 6601；EU-FP7-ICT-项目 TRADR 609763、授予 EU-H2020-688652 和授予 SERI-15.0284。本文的部分内容是在 2015 年 7 月于意大利罗马举行的机器人学：科学与系统会议的“移动传感器问题：设定 SLAM 的未来目标和进度指标”研讨会上提出的。本文的其他材料，包括扩展的参考文献列表 (bibtex) 和 SLAM 在线数据集的指针表，可以在 <https://slam-future.github.io/> 上找到。

C. Cadena 就职于 ETH Zürich, Zürich 8092, Switzerland 的自治系统实验室 (电子邮件: cesarc@ethz.ch)。

L. Carlone 就职于麻省理工学院信息与决策系统实验室, Cambridge, MA 02139 USA (电子邮件: lcarlone@mit.edu)。

H. Carrillo 就职于哥伦比亚波哥大 Sergio Arboleda 大学 Escuela de Ciencias Exactas e Ingenierías 和哥伦比亚波哥大 Javeriana 大学 (电子邮件: herny.carrillo@usa.edu.co)。

Y. Latif 和 I. Reid 就职于阿德莱德大学计算机科学学院 (Adelaide, SA 5005, Australia) 和澳大利亚机器人视觉中心 (Brisbane, QLD 4000, Australia) (电子邮件: yasir.latif@adelaide.edu.au; ian.reid@adelaide.edu.au)。

D. Scaramuzza 就职于苏黎世大学机器人与感知小组, Zürich 8006, 瑞士 (电子邮件: sdavide@ifi.uzh.ch)。

J. Neira 就职于萨拉戈萨大学信息与工程部门, 萨拉戈萨 50029, 西班牙 (电子邮件: jneira@unizar.es)。

J. J. Leonard 就职于麻省理工学院海洋机器人小组, 地址: Cambridge, MA 02139 USA (电子邮件: jleonard@mit.edu)。

本文中一幅或多幅图的彩色版本可在线获取: <http://ieeexplore.ieee.org>

数字对象标识符 10.1109/TRO.2016.2624754

一、简介

SLAM 包括同时估计配备机载传感器的机器人的状态以及构建传感器感知的环境模型 (*map*)。在简单的情况下，机器人状态由其位姿 (位置和方向) 描述，尽管状态中可能包含其他量，例如机器人速度、传感器偏差和校准参数。另一方面，地图是描述机器人操作环境的感兴趣方面 (例如地标、障碍物的位置) 的表示。

使用环境地图的需要是双重的。首先，地图常常需要支持其他任务；例如，地图可以为路径规划提供信息或为操作员提供直观的可视化。其次，该地图可以限制估计机器人状态时所犯的误差。如果没有地图，航位推测法很快就会随着时间的推移而发生漂移。另一方面，使用地图，例如一组可区分的地标，机器人可以通过重新访问已知区域 (所谓的 *loop closure*) 来“重置”其定位误差。因此，SLAM 可以在所有无法获得先验地图且需要构建先验地图的场景中找到应用。

在一些机器人应用中，一组地标的位置是已知的 *a priori*。例如，可以为在工厂车间运行的机器人提供手动构建的环境中的人工信标地图。另一个例子是机器人可以访问 GPS 的情况 (GPS 卫星可以被视为已知位置的移动信标)。在这种情况下，如果可以相对于已知地标可靠地进行定位，则可能不需要 SLAM。

SLAM 问题的流行与移动机器人室内应用的出现有关。室内操作排除使用 GPS 限制定位误差；此外，SLAM 为用户构建的地图提供了一种有吸引力的替代方案，表明在没有临时定位基础设施的情况下机器人操作也是可能的。

Durrant-Whyte 和 Bailey 在两项调查中对 SLAM 问题的前 20 年进行了彻底的历史回顾 [8]、[70]。这些主要涵盖我们所说的 *classical age* (1986–2004)；经典时代引入了 SLAM 的主要概率公式，包括基于扩展卡尔曼滤波器 (EKF)、Rao-Blackwellized 粒子滤波器和最大似然估计的方法；此外，它还描述了与效率和强大的数据关联相关的基本挑战。另外两篇优秀的参考文献描述了古典时代的三种主要 SLAM 公式：

表 I 调查和教程

Year	Topic	Reference
2006	Probabilistic approaches and data association	Durrant-Whyte and Bailey [8], [70]
2008	Filtering approaches	Aulinas <i>et al.</i> [7]
2011	SLAM back end	Grisetti <i>et al.</i> [98]
2011	Observability, consistency and convergence	Dissanayake <i>et al.</i> [65]
2012	Visual odometry	Scaramuzza and Fraundorfer [86], [218]
2016	Multi robot SLAM	Saeedi <i>et al.</i> [216]
2016	Visual place recognition	Lowry <i>et al.</i> [160]
2016	SLAM in the Handbook of Robotics	Stachniss <i>et al.</i> [234, Ch. 46]
2016	Theoretical aspects	Huang and Dissanayake [110]

Thrun、Burgard 和 Fox 的书 [240] 以及 Stachniss *et al.* 的章节 [234, Ch. 46]。接下来的时期就是我们所说的 *algorithmic-analysis age* (2004-2015), [65] 中的 Dissanayake *et al.* 部分涵盖了这一时期。算法分析阶段研究了 SLAM 的基本特性, 包括可观察性、收敛性和一致性。在此期间, 人们还了解了稀疏性对于高效 SLAM 求解器的关键作用, 并且开发了主要的开源 SLAM 库。

我们在表一中回顾了迄今为止主要的 SLAM 调查, 发现大多数最近的调查仅涵盖 SLAM 的特定方面或子领域。如果考虑一下 SLAM 涉及的多个方面, SLAM 在过去 30 年的流行就不足为奇了。在较低层次 (第二节中称为 *front end*), SLAM 自然地与其他研究领域交叉, 例如计算机视觉和信号处理; 在更高的层次上 (我们后来称为 *back end*), SLAM 是几何学、图论、优化和概率估计的有吸引力的组合。最后, SLAM 专家必须处理从传感器校准到系统集成等实际问题。

本文对 SLAM 的现状进行了广泛的概述, 并提供了部分社区对 SLAM 研究的开放问题和未来方向的想法。我们的主要关注点是度量和语义 SLAM, 我们建议读者参考 Lowry *et al.* [160] 最近的调查, 该调查对基于视觉的位置识别和拓扑 SLAM 进行了全面的回顾。

在深入研究本文之前, 我们首先讨论机器人会议期间经常引起讨论的两个问题: 自主机器人是否需要 SLAM? SLAM 是作为一项学术研究工作来解决的吗? 我们将在手稿的末尾重新讨论这些问题。

回答“自主机器人真的需要 SLAM 吗?” 这个问题需要了解 SLAM 的独特之处。SLAM 旨在利用自我运动测量和闭环来构建全球一致的环境表示。这里的关键词是“循环闭合”: 如果我们牺牲循环闭合, SLAM 就会简化为里程计。在早期应用中, 里程计是通过集成车轮编码器获得的。从车轮里程计获得的姿态估计很快就会漂移, 使得估计在几米后无法使用[128, Ch.1]。6];这是 SLAM 发展背后的主要推动力之一: 外部地标的观察有助于减少轨迹漂移并可能纠正它[185]。然而, 更多




图 1. 左: 根据里程计构建的地图。该地图与从起始位置 A 到最终位置 B 的长走廊同伦。现实中接近的点 (例如 B 和 C) 在里程地图中可能任意远。右: 从 SLAM 构建地图。通过利用闭环, SLAM 估计环境的实际拓扑, 并“发现”地图中的捷径。

最近的里程计算法基于视觉和惯性信息, 并且具有非常小的漂移 (轨迹长度的 $< 0.5\%$ [83])。因此, 这个问题就变得合理了: 我们真的需要 SLAM 吗? 我们的答案是三重的。

首先, 我们观察到过去十年进行的 SLAM 研究本身已经产生了目前代表最先进的视觉惯性里程计算法, 例如[163]、[175]; 从这个意义上说, 视觉惯性导航 (VIN) *is* SLAM: VIN 可以被认为是 *reduced* SLAM 系统, 其中闭环 (或位置识别) 模块被禁用。更一般地说, SLAM 直接导致了比其他文献 (例如航空航天工程中的惯性导航) 更具挑战性的设置 (即没有 GPS、低质量传感器) 下的传感器融合研究。

第二个答案涉及环境的真实拓扑。执行里程计并忽略闭环的机器人将世界解释为“无限走廊” (见图 1-左), 机器人在其中不断探索新区域。环路闭合事件通知机器人这条“走廊”不断与自身相交 (见图 1-右)。闭环的优势现在变得显而易见: 通过找到闭环, 机器人了解环境的真实拓扑, 并能够找到位置之间的捷径 (例如地图中的 B 点和 C 点)。因此, 如果获得正确的环境拓扑是 SLAM 的优点之一, 为什么不简单地放弃度量信息而只进行位置识别呢? 答案很简单: 度量信息使地点识别变得更简单、更稳健; 度量重建告知机器人有关环路闭合的机会, 并允许丢弃虚假的环路闭合[150]。因此, 虽然 SLAM 原则上可能是多余的 (预言地点识别模块足以进行拓扑映射), 但 SLAM 提供了针对错误数据关联和感知混叠的自然防御, 在这种情况下, 与环境中不同位置相对应的相似外观场景会欺骗地点识别。从这个意义上说, SLAM 地图提供了一种预测和验证未来测量的方法: 我们相信这种机制是稳健运行的关键。

第三个答案是, 许多应用都需要 SLAM, 这些应用无论是隐式还是显式, *do* 都需要全局一致的地图。例如, 在许多军事和民用应用中, 机器人的目标是探索环境并向人类操作员报告地图, 以确保获得对环境的完全覆盖。另一个例子是机器人必须执行结构检查 (建筑物、桥梁等); 同样在这种情况下, 全局一致的三维 (3-D) 重建是成功手术的必要条件。

“SLAM解决了吗？”这个问题在机器人社区中经常被问到，参见[88]。这个问题很难回答，因为SLAM已经成为一个如此广泛的话题，以至于这个问题仅适用于给定的机器人/环境/性能组合。特别是，一旦指定了以下几个方面，就可以评估SLAM问题的成熟度：

- 1) *Robot*: 运动类型（例如动力学、最大速度）、可用传感器（例如分辨率、采样率）、可用计算资源。
- 2) *Environment*: 平面或3-D、自然或人造地标的存在、动态元素的数量、对称性的数量以及感知混叠的风险。请注意，其中许多方面实际上取决于传感器-环境对：例如，对于二维激光扫描仪来说，两个房间可能看起来相同（感知混叠），而相机可以通过外观线索来辨别它们。
- 3) *Performance Requirements*: 机器人状态估计的期望精度、精度和环境表示类型（例如，基于地标的或密集的）、成功率（满足精度界限的测试的百分比）、估计延迟、最大操作时间、映射区域的最大尺寸。

例如，使用配备轮式编码器和激光扫描仪的机器人绘制二维室内环境图，具有足够的精度（< 10cm）和足够的鲁棒性（例如，低故障率），可以认为已经在很大程度上得到了解决（执行SLAM的工业系统的一个例子是 *Kuka Navigation Solution* [145]）。同样，基于视觉的SLAM与缓慢移动的机器人（例如，火星漫游者 [166]、家用机器人 [2]）和视觉惯性里程计 [95] 可以被认为是成熟的研究领域。

另一方面，其他机器人/环境/性能组合仍然值得进行大量的基础研究。当机器人的运动或环境太具有挑战性时（例如快速的机器人动力学、高度动态的环境），当前的SLAM算法很容易失败；同样，SLAM算法通常无法满足严格的性能要求，例如快速闭环控制的高速率估计。这项调查将对这些未决问题等进行全面概述。

在本文中，我们认为我们正在进入SLAM的第三个时代，即 *robust-perception age*，其特点是以下关键要求：

- 1) *Robust Performance*: SLAM系统可以在广泛的环境下长时间低故障率运行；该系统包括故障安全机制并具有自调整功能¹，因为它可以根据情况调整系统参数的选择。
- 2) *High-Level Understanding*: SLAM系统超越了基本的几何重建，以获得对环境的高级理解（例如，高级几何、语义、物理、可用性）。
- 3) *Resource Awareness*: SLAM系统根据可用的传感和计算资源进行定制，并且

¹The SLAM community has been largely affected by the “curse of manual tuning”, in that satisfactory operation is enabled by expert tuning of the system parameters (e.g., stopping conditions, thresholds for outlier rejection).




图2. 典型SLAM系统中的前端和后端。后端可以向前端提供反馈以进行环路闭合检测和验证。

vides 意味着根据可用资源调整计算负载。

- 4) *Task-Driven Perception*: SLAM系统能够选择相关的感知信息并过滤掉不相关的传感器数据，以支持机器人必须执行的任务；此外，SLAM系统会生成自适应地图表示，其复杂性可能会根据手头的任务而有所不同。

A. Paper organization

本文首先介绍SLAM的标准制定和架构（参见第二部分）。第三节讨论了终身SLAM的鲁棒性。第四节讨论可扩展性。第五节讨论如何表示环境的几何形状。第六节将环境表示问题扩展到语义信息的建模。第七节概述了SLAM理论方面的当前成就。第八节扩大了讨论并回顾了主动SLAM问题，其中决策用于提高SLAM结果的质量。第九节概述了SLAM的最新趋势，包括非常规传感器和深度学习的使用。第X节提供了最后的评论。在整篇论文中，我们提供了许多机器人社区之外相关工作的指导。尽管SLAM具有独特的特征，但它与计算机视觉、计算机图形学和控制理论中解决的问题有关，这些领域之间的交叉融合是实现快速进步的必要条件。

对于非专业读者，我们建议在深入研究本立场文件之前阅读Durrant-Whyte和Bailey的SLAM教程[8]、[70]。经验丰富的研究人员可以直接跳到感兴趣的部分，在那里他们将找到对最新技术和开放问题的独立概述。

二.现代SLAM系统剖析

SLAM系统的架构包括两个主要组件：*front end*和*back end*。前端将传感器数据抽象为适合估计的模型，而后端则对前端产生的抽象数据进行推理。图2总结了该架构。我们从后端开始回顾这两个组件。

A. Maximum a Posteriori (MAP) Estimation and the SLAM Back End

当前SLAM的 *de-facto* 标准表述起源于Lu和Milios [16] 1)的开创性论文，随后是Gutmann和Konolige [102] 的工作。从那时起，许多方法都提高了效率和鲁棒性

问题背后的优化[64]、[82]、[101]、[125]、[192]、[241]。所有这些方法都将 SLAM 表述为最大后验估计问题，并且经常使用 *factor graphs* [143] 的形式来推理变量之间的相互依赖性。

假设我们要估计一个未知变量 $\mathcal{X}$ ；如前所述，在 SLAM 中，变量 $\mathcal{X}$ 通常包括机器人的轨迹（作为一组离散的姿态）和环境中的地标位置。我们给出一组测量值 $Z = \{z_k : k = 1, \dots, m\}$ ，这样每个测量值都可以表示为 $\mathcal{X}$ 的函数，即 $z_k = h_k(\mathcal{X}_k) + \epsilon_k$ ，其中 $\mathcal{X}_k \subseteq \mathcal{X}$ 是变量的子集， $h_k(\cdot)$ 是已知函数（*measurement* 或 *observation* 模型），而 ϵ_k 是随机测量噪声。

在 MAP 估计中，我们通过计算变量 $\mathcal{X}^*$ 的分配来估计 $\mathcal{X}$ ，该变量获得后验 $p(\mathcal{X}|Z)$ 的最大值（给定测量值的 *belief* 超过 $\mathcal{X}$ ）

$$\mathcal{X}^* \doteq \underset{\mathcal{X}}{\operatorname{argmax}} p(\mathcal{X}|Z) = \underset{\mathcal{X}}{\operatorname{argmax}} p(Z|\mathcal{X})p(\mathcal{X}) \quad (1)$$

其中等式由贝叶斯定理得出。在 (1) 中， $p(Z|\mathcal{X})$ 是给定分配 $\mathcal{X}$ 的测量 Z 的可能性， $p(\mathcal{X})$ 是 $\mathcal{X}$ 的先验概率。先验概率包括关于 $\mathcal{X}$ 的任何先验知识；如果没有先验知识， $p(\mathcal{X})$ 就会变成一个常数（均匀分布），这是无关紧要的，可以从优化中删除。在这种情况下，MAP 估计减少为 *max-imum likelihood estimation*。请注意，与卡尔曼滤波不同，MAP 估计不需要运动模型和观测模型之间的明确区别：这两个模型都被视为因子，并且无缝地合并到估计过程中。此外，值得注意的是，卡尔曼滤波和 MAP 估计在线性高斯情况下返回相同的估计，但一般情况并非如此。

假设测量值 Z 是独立的（即相应的噪声不相关），问题 (1) 分解为

$$\begin{aligned} \mathcal{X}^* &= \underset{\mathcal{X}}{\operatorname{argmax}} p(\mathcal{X}) \prod_{k=1}^m p(z_k|\mathcal{X}) \\ &= \underset{\mathcal{X}}{\operatorname{argmax}} p(\mathcal{X}) \prod_{k=1}^m p(z_k|\mathcal{X}_k) \end{aligned} \quad (2)$$

其中，在右侧，我们注意到 z_k 仅取决于 $\mathcal{X}_k$ 中的变量子集。

问题 (2) 可以用因子图的推理来解释[143]。变量对应于因子图中的节点。项 $p(z_k|\mathcal{X}_k)$ 和先验 $p(\mathcal{X})$ 称为 *factors*，它们对节点子集的概率约束进行编码。因子图是对第 k 个因子（及其测量值 z_k ）与相应变量 $\mathcal{X}_k$ 之间的依赖性进行编码的图形模型。因子图解释的第一个优点是它可以对问题进行深入的可视化。图 3 显示了简单 SLAM 问题背后的因子图示例。图中显示了变量，即机器人位姿、地标位置和相机标定参数，以及这些变量之间施加约束的因素。第二个优点是通用性：因子图可以模拟复杂的推理问题




图 3. SLAM as a factor graph: 蓝色圆圈表示连续时间步长 $(x_1, x_2, \dots)$ 的机器人姿势，绿色圆圈表示地标位置 $(l_1, l_2, \dots)$ ，红色圆圈表示与内在校准参数相关的变量 (K) 。因子显示为黑色方块：标签“u”标记与里程计约束相对应的因子，“v”标记与相机观测相对应的因子，“c”表示闭环，“p”表示先验因子。

具有异质的变量和因素以及任意的相互联系。此外，因子图的连通性反过来又会影响由此产生的 SLAM 问题的稀疏性，如下所述。

为了以更明确的形式写出(2)，假设测量噪声 ϵ_k 是零均值高斯噪声，其信息矩阵 Ω_k (是协方差矩阵)的逆。那么，(2) 中的测量似然变为

$$p(z_k|\mathcal{X}_k) \propto \exp\left(-\frac{1}{2}\|h_k(\mathcal{X}_k) - z_k\|_{\Omega_k}^2\right) \quad (3)$$

我们使用符号 $\|e\|_{\Omega}^2 = e^T \Omega e$ 。类似地，假设对于某个给定函数 $h_0(\cdot)$ 、先验均值 z_0 和信息矩阵 Ω_0 ，先验可以写为： $p(\mathcal{X}) \propto \exp(-\frac{1}{2}\|h_0(\mathcal{X}) - z_0\|_{\Omega_0}^2)$ 。由于最大化后验与最小化 *negative log-posterior* 相同，因此 (2) 中的 MAP 估计变为

$$\begin{aligned} \mathcal{X}^* &= \underset{\mathcal{X}}{\operatorname{argmin}} -\log\left(p(\mathcal{X}) \prod_{k=1}^m p(z_k|\mathcal{X}_k)\right) \\ &= \underset{\mathcal{X}}{\operatorname{argmin}} \sum_{k=0}^m \|h_k(\mathcal{X}_k) - z_k\|_{\Omega_k}^2 \end{aligned} \quad (4)$$

这是一个非线性最小二乘问题，就像在机器人技术中大多数数感兴趣的问题中一样， $h_k(\cdot)$ 是一个非线性函数。请注意，公式 (4) 是根据正态分布噪声的假设得出的。噪声分布的其他假设会导致不同的成本函数；例如，如果噪声遵循拉普拉斯分布，则 (4) 中的平方 ℓ_2 -范数将替换为 ℓ_1 -范数。为了提高对异常值的恢复能力，通常用稳健的损失函数（例如 Huber 或 Tukey 损失）替代 (4) 中的平方 ℓ_2 -范数 [113]。

计算机视觉专家可能会注意到问题 (4) 和 Structure from Motion [244] 中的 *bundle adjustment* (BA) 之间的相似之处；(4) 和 BA 确实都源于最大后验公式。然而，有两个关键特征使 SLAM 独一无二。首先，(4) 中的因素并不像 BA 中那样仅限于对射影几何进行建模，而是包括各种传感器模型，例如惯性传感器、车轮编码器、GPS 等等。例如，在基于激光的测绘中，这些因素通常会限制不同视点之间的相对姿态，而在视觉 SLAM 的直接方法中，这些因素会惩罚不同视点之间像素强度的差异。

场景同一部分的视图。与 BA 相关的第二个区别是, 在 SLAM 场景中, 通常需要解决问题 (4) *incrementally*: 当机器人移动时, 在每个时间步都会提供新的测量结果。

最小化问题 (4) 通常通过连续线性化来解决, 例如高斯-牛顿或莱文伯格-马夸特方法 (第七节回顾了基于凸松弛和拉格朗日对偶性的替代方法)。连续的线性化方法从给定的初始猜测 $\hat{x}$ 开始迭代进行, 并以二次成本逼近 $\hat{x}$ 处的成本函数, 可以通过求解一组线性方程 (所谓的 *normal equations*) 以封闭形式进行优化。这些方法可以无缝地推广到属于平滑流形的变量 (例如旋转), 这在机器人学中很有趣[1], [83]。

现代 SLAM 求解器背后的关键见解是, 正规方程中出现的矩阵是稀疏的, 其稀疏结构由底层因子图的拓扑决定。这使得可以使用快速线性求解器[125]、[126]、[146]、[204]。此外, 它允许设计 *incremental* (或 *on-line*) 求解器, 当获取新的观测值时更新 x 的估计[125], [126], [204]。当前的 SLAM 库 (例如 GTSAM [62]、g2o [146]、Ceres [214]、iSAM [126] 和 SLAM++ [204]) 能够在几秒钟内解决具有数万个变量的问题。实践教程 [62]、[98] 提供了对两个最流行的 SLAM 库的精彩介绍; 每个库还包含一组展示真实 SLAM 问题的示例。

迄今为止描述的 SLAM 公式通常称为 *maximum a posteriori* 估计、*factor graph optimization*、*graph-SLAM*、*full smoothing* 或 *smoothing and mapping* (SAM)。该框架的一个流行变体是 *pose graph optimization*, 其中要估计的变量是沿机器人轨迹采样的姿势, 每个因素对一对姿势施加约束。

MAP 估计已被证明比基于非线性过滤的 SLAM 原始方法更准确、更高效。我们建议读者参考调查[8]、[70]来了解过滤方法的概述, 并参考[236]来了解过滤和平滑之间的比较。我们注意到, 一些基于 EKF 的 SLAM 系统也已被证明能够达到最先进的性能。基于 EKF 的 SLAM 系统的优秀示例包括 Mourikis 和 Roumeliotis [175] 的多态约束卡尔曼滤波器, 以及 Kottas *et al.* [139] 和 Hesch *et al.* [106] 的 VIN 系统。毫不奇怪, 当 EKF 的线性化点准确时 (如在视觉惯性导航问题中发生的情况)、使用滑动窗口滤波器以及当 EKF 中潜在的不一致来源得到处理时, 滤波和 MAP 估计之间的性能失配会变得更小 [106]、[109]、[139]。

如下一节所述, MAP 估计通常是在传感器数据的预处理版本上执行的。在这方面, 它通常被称为 SLAM *back end*。

B. Sensor-Dependent SLAM Front End

在实际的机器人应用中, 可能很难直接将传感器测量结果写为以下函数的解析函数:

状态, 根据 MAP 估计的要求。例如, 如果原始传感器数据是图像, 则可能很难将每个像素的强度表示为 SLAM 状态的函数; 更简单的传感器 (例如单光束激光器) 也会出现同样的困难。在这两种情况下, 问题都与我们无法设计一个足够普遍但易于处理的环境表示有关。即使存在这样的一般表示, 也很难编写将测量结果与这种表示的参数连接起来的分析函数。

因此, 在 SLAM 后端之前, 通常有一个模块 *front end*, 用于从传感器数据中提取相关特征。例如, 在基于视觉的 SLAM 中, 前端提取环境中少数可区分点的像素位置; 现在可以轻松地在后端对这些点的像素观察进行建模。前端还负责将每个测量值与环境中的特定地标 (例如 3D 点) 相关联: 这就是所谓的 *data association*。更抽象地, 数据关联模块将每个测量值 z_k 与未知变量的子集 $\mathcal{X}_k$ 相关联, 使得 $z_k = h_k(\mathcal{X}_k) + \epsilon_k$ 。最后, 前端还可能为非线性优化 (4) 中的变量提供初始猜测。例如, 在基于特征的单目 SLAM 中, 前端通常通过从多个视图对地标的位置进行三角测量来处理地标初始化。

图2给出了典型SLAM系统的图示。前端的数据关联模块包括短期数据关联块和长期数据关联块。短期数据关联负责关联连续传感器测量中的相应特征; 例如, 短期数据关联将跟踪连续帧中的 2 个像素测量描绘同一 3D 点的事实。另一方面, 长期数据关联 (或闭环) 负责将新测量值与旧地标相关联。我们注意到后端通常会向前端反馈信息, 例如支持回环检测和验证。

前端发生的预处理取决于传感器, 因为 *feature* 的概念根据我们考虑的输入数据流而变化。

三. 长期自主性 I: 稳健性

SLAM 系统在许多方面可能都很脆弱: 故障可能是算法²或与硬件相关。前一类包括由现有 SLAM 算法的限制引起的故障模式 (例如, 难以处理极其动态或恶劣的环境)。后者包括由于传感器或执行器退化而导致的故障。明确解决这些故障模式对于长期运行至关重要, 因为人们不能再对环境结构 (例如, 大部分是静态的) 做出简化假设或完全依赖机载传感器。在本节中, 我们回顾算法鲁棒性的主要挑战。然后我们讨论开放问题, 包括针对硬件相关故障的鲁棒性。

²我们忽略了 (大量) 与软件相关的故障。非专业读者必须意识到, 集成和测试是 SLAM 和机器人技术的关键方面。

算法失败的主要来源之一是数据关联。如第二部分所述，数据关联将每个测量与测量所指的状态部分相匹配。例如，在基于特征的视觉 SLAM 中，它将每个视觉特征与特定的地标相关联。感知混叠是一种不同的感官输入导致相同的传感器特征的现象，使得这个问题变得特别困难。在存在感知混叠的情况下，数据关联会建立错误的测量状态匹配（异常值或误报），从而导致后端做出错误的估计。另一方面，当数据关联决定错误地拒绝传感器测量作为虚假（假阴性）时，用于估计的测量会减少，但代价是估计准确性。

由于环境中存在未建模的动态（包括短期和季节性变化），情况变得更糟，这可能会欺骗短期和长期数据关联。当前 SLAM 方法中一个相当常见的假设是，当机器人在其中移动时，世界保持不变（换句话说，地标是静态的）。只要不存在 *short-term dynamics*（例如，四处移动的人和物体），此 *static world assumption* 就适用于小规模场景中的单次映射运行。当在更长的时间尺度和更大的环境中绘制地图时，变化是不可避免的。

鲁棒性的另一个方面是在水下等恶劣环境中进行 SLAM [74]、[131]。这种情况下的挑战是有限的能见度、不断变化的条件以及无法使用传统传感器（例如激光测距仪）。

A. Brief Survey

与不正确的数据关联相关的鲁棒性问题可以在 SLAM 系统的前端和/或后端得到解决。传统上，前端被委托建立正确的数据关联。短期数据关联是更容易解决的问题：如果传感器的采样率相对较快，与机器人的动力学相比，跟踪与相同 3D 地标相对应的特征就很容易。例如，如果我们想要跟踪连续图像上的 3D 点，并假设帧速率足够高，基于描述符匹配或光流 [218] 的标准方法可以确保可靠的跟踪。直观上，在高帧速率下，传感器（相机、激光）的视点不会发生显著变化，因此时间 $t + 1$ 的特征（及其外观）仍然接近于时间 t 观察到的特征。³ 前端的数据关联更具挑战性，涉及闭环 *detection* 和 *validation*。对于前端的闭环检测，检测当前测量（例如图像）中的特征并尝试将它们与所有先前检测到的特征进行匹配的强力方法很快就变得不切实际。词袋模型 [226] 通过量化特征空间并允许更有效的搜索来避免这种麻烦。词袋可以排列成分层词汇树 [189]，从而能够在大型词汇表中进行有效查找。

³In hindsight, the fact that short-term data association is much easier and more reliable than the long-term one is what makes (visual, inertial) odometry simpler than SLAM.

规模数据集。基于词袋的技术（例如 [54]）已经在单会话循环闭合检测任务上表现出了可靠的性能。然而，这些方法无法处理严重的照明变化，因为视觉单词不再能够匹配。这导致开发出新的方法，通过匹配序列 [173]、将不同的视觉外观收集到统一的表示中 [49] 或使用空间和外观信息 [107] 来明确地解释这种变化。关于视觉地点识别的详细调查可以在 Lowry *et al.* [160] 中找到。基于特征的方法也被用来检测基于激光的 SLAM 前端的闭环；例如，Tipaldi *et al.* [242] 提出了用于二维激光扫描的 FLIRT 功能。

相反，环路闭合验证包括额外的几何验证步骤，以确定环路闭合的质量。在基于视觉的应用中，RANSAC 通常用于几何验证和异常值拒绝，请参阅 [218] 及其中的参考文献。在基于激光的方法中，可以通过检查当前激光扫描与现有地图的匹配程度（即扫描匹配产生的残余误差有多少）来验证环路闭合。

尽管在增强前端的回环检测方面取得了进展，但在存在感知混叠的情况下，错误的回环被馈送到后端是不可避免的。错误的闭环可能会严重影响 MAP 估计的质量 [238]。为了解决这个问题，最近的一系列研究 [34]、[150]、[191]、[238] 提出了使 SLAM 后端能够抵抗虚假测量的技术。这些方法通过查看优化过程中约束引起的残余误差来推理闭环约束的有效性。相反，其他方法尝试检测异常值 *a priori*，即在进行任何优化之前，通过识别里程计不支持的不正确的闭环来检测 [215]。

在动态环境中，挑战是双重的。首先，SLAM 系统必须检测、丢弃或跟踪变化。虽然主流方法试图丢弃场景的动态部分 [180]，但一些作品将动态元素作为模型的一部分 [12]、[253]。第二个挑战是 SLAM 系统必须对永久或半永久变化进行建模，并了解如何以及何时相应地更新地图。当前处理动力学的 SLAM 系统要么维护同一位置的多个（与时间相关的）地图 [61]，要么具有由某些时变参数参数化的单个表示形式 [140]。

B. Open Problems

在本节中，我们回顾长期 SLAM 中出现的开放性问题 and 新的研究问题。

1) *Failsafe SLAM and Recovery*: 尽管 SLAM 后端取得了进展，但当前的 SLAM 求解器在存在异常值时仍然很脆弱。这主要是因为几乎所有鲁棒 SLAM 技术都是基于非凸成本的迭代优化。这有两个结果：首先，异常值拒绝结果取决于优化过程中初始猜测的质量；其次，该系统本质上是脆弱的：包含单个异常值会降低估计的质量，进而降低以后识别异常值的能力。这些类型的故障会导致错误的

线性化点, 从该点开始恢复并非微不足道, 尤其是在增量设置中。理想的 SLAM 解决方案应该是 *fail-safe* 和 *failure-aware*, 即系统需要意识到即将发生的故障 (例如, 由于异常值或退化) 并提供可以重新建立正确操作的恢复机制。现有的 SLAM 方法均不提供这些功能。实现这一目标的一种可能方法是前端和后端之间更紧密的集成, 但如何实现这一点仍然是一个悬而未决的问题。

2) *Robustness to HW Failure*: 虽然解决硬件故障可能超出了 SLAM 的范围, 但这些故障会影响 SLAM 系统, 而后者可以在检测和减轻传感器和运动故障方面发挥关键作用。如果传感器的精度由于故障、非标称条件或老化而降低, 则传感器测量的质量 (例如噪声、偏差) 与后端使用的噪声模型不匹配 [参见 cf, (3)], 导致估计结果不佳。这自然会提出不同的研究问题: 我们如何检测退化的传感器操作? 我们如何相应地调整传感器噪声统计数据 (协方差、偏差)? 更一般地说, 我们如何解决来自不同传感器的冲突信息? 这在安全关键型应用 (例如自动驾驶汽车) 中似乎至关重要, 在这些应用中, 传感器数据的误解可能会危及人类生命。

3) *Metric Relocalization*: 虽然与基于特征相反, 基于外观的方法能够闭合白天和夜晚序列之间或不同季节之间的循环, 但所产生的循环闭合本质上是拓扑性的。对于度量重定位 (即估计相对于先前构建的地图的相对姿态), 基于特征的方法仍然是常态; 然而, 当前的特征描述符缺乏足够的不变性来在这种情况下可靠地工作。SLAM 问题固有的空间信息 (例如轨迹匹配) 可以用来克服这些限制。此外, 使用一种传感器模式 (例如 3D 激光雷达) 进行映射并使用不同的传感器模式 (例如相机) 在同一地图中进行定位可能是一个有用的补充。Wolcott *et al.* [260] 的工作是朝这个方向迈出的第一步。

4) *Time Varying and Deformable Maps*: 主流的 SLAM 方法是在考虑到刚性和静态世界假设的情况下开发的; 然而, 由于动力学以及物体固有的可变形性, 现实世界是非刚性的。理想的 SLAM 解决方案应该能够推理环境中的动态 (包括非刚性)、长时间工作生成“全地形”地图, 并且能够实时执行此操作。在计算机视觉领域, 自 80 年代以来已经进行了多次尝试从非刚性物体恢复形状, 但适用性有限。非刚性 SfM 的最新结果 (例如 [92]、[97]) 限制较少, 但仅适用于小场景。在 SLAM 社区中, Newcombe *et al.* [182] 解决了小规模重建的非刚性情况。然而, 解决大比例尺非刚性地图问题在很大程度上仍未得到探索。

5) *Automatic Parameter Tuning*: SLAM 系统 (特别是数据关联模块) 需要大量的参数调整才能在给定场景下正常工作。这些参数包括控制特征匹配的阈值、RANSAC 参数以及决定何时向图中添加新因素或何时触发闭环算法的标准。

搜索匹配项。如果 SLAM 必须在任意场景下“开箱即用”, 则需要考虑自动调整相关参数的方法。

四. 长期自治 II: 可扩展性

虽然现代 SLAM 算法主要在室内建筑规模环境中得到成功演示, 但在许多应用努力中, 机器人必须在更大的区域内运行更长的时间。这些应用包括用于环境监测的海洋探索、不断变化的城市中的不间断清洁机器人或大规模精准农业。对于此类应用, 由于对新地点的不断探索和操作时间的增加, SLAM 底层的因子图的大小可以无限增长。实际上, 计算时间和内存占用受到机器人资源的限制。因此, 设计计算和内存复杂度保持有限的 SLAM 方法非常重要。

在最坏的情况下, 基于 *direct* 线性求解器的连续线性化方法意味着内存消耗随着变量数量呈二次方增长。当使用迭代线性求解器 (例如, 共轭梯度 [63]) 时, 内存消耗随着变量的数量线性增长。事实上, 当多次重新访问一个地方时, 由于节点和边不断添加到同一空间区域, 因子图优化变得不那么有效, 从而损害了图的稀疏结构, 因此情况变得更加复杂。

在本节中, 我们回顾了当前控制或至少减少问题规模增长的一些方法, 并讨论了开放的挑战。

A. Brief Survey

我们专注于降低因子图优化复杂性的两种方法: 1) *sparsification methods*, 它以信息损失换取内存和计算效率; 1) *out-of-core and multirobot methods*, 它将计算分配给许多机器人/处理器。

1) *Node and Edge Sparsification*: 这一系列方法通过减少图中的节点数量 *added* 或减少“信息量大”的节点和因子来解决可扩展性问题。Ila *et al.* [115] 使用信息论方法仅向图中添加非冗余节点和信息丰富的测量。Johannsson *et al.* [120], 如果可能的话, 通过在现有节点之间引入新的约束来避免向图中添加新节点, 这样变量的数量仅随着探索空间的大小而不是随着映射持续增长而增长。Kretzschmar *et al.* [141] 提出了一种基于信息的标准, 用于确定在位姿图优化中边缘化哪些节点。Carlevaris-Bianco 和 Eustice [29] 以及 Mazuran *et al.* [170] 分别介绍了 *generic linear constraint* (GLC) 因子和 *nonlinear graph sparsification* (NGS) 方法。这些方法对边缘化节点的马尔可夫毯进行操作, 并计算毯的稀疏近似。Huang *et al.* [108] 通过求解 ℓ_1 -正则化最小化问题来稀疏 Hessian 矩阵 (出现在正规方程中)。

另一项可以减少随时间估计的参数数量的工作是 *continuous-time*

trajectory estimation。此类的第一个 SLAM 方法是由 Bibby 和 Reid 提出的, 使用三次样条来表示机器人的连续轨迹[13]。在他们的方法中, 因子图中的节点代表样条线的控制点(结), 这些控制点以滑动窗口方式优化。后来, Furgale *et al.* [89] 提出使用基础函数, 特别是 B 样条, 在批量优化公式中近似机器人轨迹。滑动窗口 B 样条公式也用于带有卷帘快门相机的 SLAM, Patron-Perez *et al.* [196] 采用基于地标的表示, Kim *et al.* [133] 采用半密集直接表示。最近, Mueggler *et al.* [177] 将连续时间 SLAM 公式应用于基于事件的相机。Bosse *et al.* [22] 将连续 3D 扫描匹配公式从 [20] 扩展到大规模 SLAM 应用。后来, Anderson *et al.* [5] 和 Dubé *et al.* [68] 分别提出了通过使用小波或在轨迹上采样非均匀结来更有效的实现。Tong *et al.* [243] 将轨迹的参数化从基本曲线更改为高斯过程表示, 其中因子图中的节点是实际的机器人姿势, 任何其他姿势都可以通过计算给定时间的后验平均值来插值。需要昂贵的批量高斯-牛顿优化来解决第一个提案中的状态。Barfoot *et al.* [4] 然后提出了一个具有精确稀疏逆内核的高斯过程, 大大减少了批处理解决方案的计算时间。

2) *Out-of-Core (Parallel) SLAM*: SLAM 的并行 *out-of-core* 算法在多个处理器之间分割因子图优化的计算(和内存)负载。关键思想是将因子图划分为不同的子图, 并通过交替对每个子图进行局部优化和全局细化来优化整体图。相应的方法通常被称为 *submapping algorithms*, 这个想法可以追溯到处理大规模地图的最初尝试[19]。Ni *et al.* [187] 和 Zhao *et al.* [267] 提出了因子图优化的子映射方法, 以二叉树结构组织子图。Grisetti *et al.* [99] 提出了子图的层次结构: 每当获取观察结果时, 层次结构的最高级别都会被修改, 并且只有受到严重影响的区域才会在较低级别发生变化。一些方法近似解耦两个并行运行的线程中的定位和映射, 如 Klein 和 Murray [135]。其他方法诉诸于并行解决不同阶段: 受 [223] 的启发, Strasdat *et al.* [235] 采用两阶段方法, 首先优化局部姿态特征图, 然后优化姿态-姿态图; Williams *et al.* [259] 高频滤波器和低频平滑器中的分割因子图优化, 它们定期同步。

3) *Distributed Multirobot SLAM*: 绘制大规模环境地图的一种方法是部署多个执行 SLAM 的机器人, 并将场景划分为更小的区域, 每个区域由不同的机器人绘制地图。这种方法有两个主要变体: 一种是 *centralized*, 机器人构建子地图并将本地信息传输到执行推理的中央站[67], [210]; 另一种是 *decentralized*, 其中没有中央数据融合, 代理利用本地通信在公共地图上达成共识。Nerurkar *et al.* [181] 提出了一种基于

分布共轭梯度。Araguez *et al.* [6] 研究基于共识的地图合并方法。Knuth 和 Barooah [137] 使用分布式梯度下降估计 3-D 位姿。在 Lazaro *et al.* [151] 中, 机器人交换其因子图的一部分, 这些因子图以压缩测量的形式进行近似, 以最大限度地减少通信。Cunnigham *et al.* [55] 使用高斯消去法, 并开发了一种称为 DDF-SAM 的方法, 其中每个机器人在 *separators* (上交换高斯边际, 即多个机器人) 共享的变量。最近关于多机器人 SLAM 方法的调查可以在 [216] 中找到。

虽然高斯消除法已成为一种流行的方法, 但它有两个主要缺点。首先, 机器人之间交换的边际是密集的, 并且通信成本是分离器数量的二次方。这促使人们使用稀疏化技术来降低通信成本[197]。第二个原因是高斯消除是在问题的线性化版本上执行的, 因此 DDF-SAM [55] 等方法需要良好的线性化点和复杂的簿记以确保机器人之间线性化点的一致性。高斯消除的另一种方法是 Choudhary *et al.* [48] 的高斯-赛德尔方法, 这意味着通信负担与分隔符的数量呈线性关系。

B. Open Problems

尽管降低因子图优化复杂性的工作量很大, 但文献在与长期操作相关的其他方面仍存在很大差距。

1) *Map Representation*: 一个相当未探索的问题是如何在长期操作期间存储地图。即使内存不是一个严格的约束, 例如, 数据存储在云上, 点云或体积图(另见第五节)的原始表示在内存方面也是浪费的; 同样, 存储基于视觉的 SLAM 的特征描述符很快就会变得很麻烦。最近提出了一些初始解决方案, 用于针对压缩的已知地图进行定位[163], 以及用于内存高效的密集重建[136]。

2) *Learning, Forgetting, and Remembering*: 长期地图绘制的一个相关的悬而未决的问题是地图中包含的信息多久更新一次以及如何决定这些信息何时过时并可以被丢弃。如果有的话, 什么时候可以忘记? 在这种情况下, 什么是可以忘记的, 什么是必须维护的? 地图的某些部分可以“卸载”并在需要时调用吗? 虽然这显然取决于任务, 但文献中尚未对这些问题提出有根据的答案。

3) *Robust Distributed Mapping*: 虽然在单个机器人的情况下提出了异常值拒绝的方法, 但多机器人 SLAM 的文献几乎没有涉及异常值的问题。由于两个原因, 处理杂散测量尤其具有挑战性。首先, 机器人可能不共享共同的参考系, 这使得检测和拒绝错误的闭环变得更加困难。其次, 在分布式设置中, 机器人必须从非常局部和局部的信息中检测异常值。解决这个问题的早期尝试是[85], 其中机器人在融合信息之前使用会合策略主动验证位置假设。Indelman *et al.* [117] 提出

面对虚假测量建立通用参考系的概率方法。

4) *Resource-Constrained Platforms*: 另一个相对未探讨的问题是如何使现有的 SLAM 算法适应机器人平台具有 *severe* 计算约束的情况。当平台尺寸缩小时, 例如移动电话、微型飞行器或机器人昆虫, 这个问题就变得非常重要 [261]。许多 SLAM 算法的成本太高, 无法在这些平台上运行, 因此人们希望有一种算法可以调整“旋钮”, 从而可以在计算成本和准确性之间进行温和的权衡。多机器人环境中也出现了类似的问题: 当面临严格的带宽限制和通信中断时, 我们如何保证多机器人团队的可靠运行? Cieslewski *et al.* [50] 的“版本控制”方法是这个方向的第一个研究。

V. 表示 I: 度量地图模型

本节讨论如何在 SLAM 中对几何进行建模。更正式地说, *metric representation* (或度量映射) 是一种对环境几何形状进行编码的符号结构。我们声称, 了解如何为 SLAM 选择合适的度量表示 (以及扩展当前机器人技术中使用的表示集或表示) 将影响许多研究领域, 包括长期导航、与环境的物理交互以及人机交互。

在二维情况下, 几何建模显得简单得多, 只有两种主要范式: *landmark-based maps* 和 *occupancy grid maps*。前者将环境建模为一组稀疏的地标, 后者将环境离散化为单元格, 并为每个单元格分配占用概率。二维情况下这些表示的标准化问题已由 *IEEE RAS Map Data Representation Working Group* 解决, 该标准最近发布了机器人领域二维地图的标准 [114]; 该标准定义了平面环境的两种主要度量表示 (以及拓扑图), 以促进数据交换、基准测试和技术转让。

3-D 几何建模的问题更加微妙, 并且对如何在测绘过程中有效地建模 3-D 几何的理解还处于起步阶段。在本节中, 我们从机器人技术、计算机视觉、计算机辅助设计 (CAD) 和计算机图形学的广阔角度来回顾度量表示。我们的分类法从 [81]、[209]、[221] 中汲取灵感, 并包括对最近工作的指导。

A. Landmark-Based Sparse Representations

大多数 SLAM 方法将场景表示为一组 *sparse* 3-D 地标, 对应于环境中的判别特征 (例如, 线、角) [179]; 一个例子如图 4 (左) 所示。这些通常被称为 *landmark-based* 或 *feature-based* 表示, 自定位和地图绘制的早期工作以来, 在移动机器人领域以及在 *Structure from Motion* [3]、[244] 背景下的计算机视觉中广泛使用。这些表示背后的一个常见假设是地标是可区分的, 即传感器数据测量地标的某些几何方面, 但也提供了一个 *descriptor*, 它建立了 (可能不确定)




图 4. 左: ORB-SLAM [179] 生成的基于特征的房间地图。右图: DTAM [184] 生成的密集桌面地图。

每个测量值和相应地标之间的数据关联。之前的工作还研究了不同的 3-D 地标参数化, 包括全局和局部笛卡尔模型以及逆深度参数化 [174]。虽然大量工作集中在点特征的估计上, 但机器人文献包括对更复杂的几何地标的扩展, 包括直线、线段或弧线 [162]。

B. Low-Level Raw Dense Representations

与基于地标的表示相反, 密集表示试图提供 3D 几何的高分辨率模型; 这些模型更适合避障, 或者可视化和渲染, 见图 4 (右)。在密集模型中, *raw representations* 通过大量非结构化点 (即 *point clouds*) 或多边形 (即 *polygon soup* [222]) 来描述 3-D 几何形状。点云已广泛应用于机器人领域, 与立体相机和 RGB-D 相机以及 3D 激光扫描仪结合使用 [190]。这些表示最近在单目 SLAM 中得到了普及, 结合使用 *direct methods* [118]、[184]、[203], 它们直接根据所有图像像素的强度值估计机器人和 3D 模型的轨迹。稍微复杂的表示是 *surfel maps*, 它将几何图形编码为一组磁盘 [105]、[257]。虽然这些表示在视觉上令人愉悦, 但它们通常很麻烦, 因为它们需要存储大量数据。此外, 它们给出了几何结构的低级描述, 忽略了障碍物的拓扑结构等。

C. Boundary and Spatial-Partitioning Dense Representations

这些表示超越了低级基元 (例如点) 的非结构化集合, 并尝试显式表示表面 (或 *boundaries*) 和体积。这些表示更适合诸如运动或足迹规划、避障、操纵和其他基于物理的推理 (例如接触推理) 等任务。边界表示 (b-reps) 根据表面边界定义 3D 对象。特别是, 简单的边界表示是基于平面的模型, 已在 [45]、[124] 和 [162] 中用于映射。更一般的 b-rep 包括 *curve-based representations* (例如 NURBS 或 B 样条的张量积)、*surface mesh models* (多边形的连通集) 和 *implicit surface representations*。后者将固体表面指定为 $\mathbb{R}^3$ [17] 上定义的函数的零交叉点; 函数的示例包括 *radial-basis functions* [39]、*signed-distance function* [56] 和 *truncated*

signed-distance function (TSDF) [264]。TSDF 目前是机器人技术中基于视觉的 SLAM 的流行代表，在开创性的工作之后吸引了越来越多的关注 [183]。网格模型也已在 [258] 和 [257] 中使用。

空间分区表示将 3D 对象定义为连续的不相交图元的集合。最流行的空间分区表示是所谓的 *spatial-occupancy enumeration*，它将 3D 空间分解为相同的立方体 (voxels)，并排列在规则的 3D 网格中。更有效的分区方案包括 *octree*、*Polyg-、onal Map octree* 和 *Binary Space-Partitioning tree* [81, 秒。12.6]。在机器人技术中，八叉树表示已用于 3-D 映射 [76]，而常用的 *occupancy grid maps* [72] 可以被视为空间分区表示的概率变体。在没有悬挂障碍物的 3D 环境中，还使用了 2.5D 高程图 [24]。在转向更高级别的表示之前，让我们更好地了解稀疏（基于特征的）表示（和算法）与视觉 SLAM 中的密集表示相比如何。

Which one is best: Feature-based or direct methods? 基于特征的方法相当成熟，有着悠久的历史[60]。它们允许构建具有自动重定位和循环闭合功能的精确且强大的 SLAM 系统 [179]。然而，此类系统取决于环境中特征的可用性、对检测和匹配阈值的依赖，以及大多数特征检测器针对速度而不是精度进行优化的事实。另一方面，直接方法使用原始像素信息，而密集直接方法利用图像中的所有信息，即使是梯度很小的区域；因此，在纹理较差、散焦和运动模糊的场景中，它们可以优于基于特征的方法 [184]、[203]。然而，它们需要高计算能力（GPU）来实现实时性能。此外，如何联合估计密集结构和运动仍然是一个悬而未决的问题（目前它们只能依次估计）。为了避免基于特征的方法的警告，有两种选择。*Semidense* 方法通过仅利用具有强梯度（即边缘）的像素来克服密集方法的高计算要求 [73]，[84]；*semidirect* 方法同时利用稀疏特征（例如角或边缘）和直接方法 [84]，并且被证明是最有效的 [84]；此外，由于它们依赖于稀疏特征，因此它们允许对结构和运动进行联合估计。

D. High-Level Object-Based Representations

虽然点云和边界表示目前在密集地图领域占据主导地位，但我们预计，包括对象和实体形状在内的更高级别的表示将在 SLAM 的未来中发挥关键作用。将基于对象的推理纳入 SLAM 的早期技术包括 Salas-Moreno *et al.* [217] 的“SLAM++”、Civera *et al.* [51] 和 Dame *et al.* [57] 的工作。实体表示明确地编码了这样一个事实：真实对象是 3-D 而不是 1-D（即点）或 2-D（表面）。将物体建模为实体形状可以将物理概念（例如体积和质量）与每个物体相关联，这对于必须与世界互动的机器人来说绝对重要。幸运的是，现有的 CAD 和计算机图形学文献为实现这些目标铺平了道路。

事态发展。下面，我们列出了一些尚未在 SLAM 环境中使用的实体表示示例：

1) *Parameterized Primitive Instancing*: 依赖于物体（例如圆柱体、球体）的 *families* 的定义。对于每个族，定义一组参数（例如，半径、高度），唯一标识该族的成员（或 *instance*）。这种表示可能会引起 SLAM 的兴趣，因为它可以使用极其紧凑的模型，同时仍然捕获人造环境中的许多元素。

2) *Sweep Representations*: 将实体定义为 2-D 或 3-D 对象沿着空间轨迹的扫描。典型的扫描表示包括平移扫描（或 *extrusion*）和旋转扫描。例如，圆柱体可以表示为圆沿与圆平面正交的轴的平移扫描。二维横截面扫描在计算机视觉中被称为 *generalized cylinders* [14]，并且它们已被用于机器人抓取 [200]。这种表示似乎特别适合通过利用对称性对场景的被遮挡部分进行推理。

3) *Constructive Solid Geometry*: 通过基元之间的布尔运算定义复杂实体 [209]。对象存储为树，其中叶子是基元，边代表操作。这种表示可以模拟相当复杂的几何形状，并广泛应用于计算机图形学中。

我们在总结这篇评论时提到存在其他类型的表示，包括 CAD 中基于特征的模型 [220]、基于字典的表示 [266]、基于可供性的模型 [134]、生成和过程模型 [172] 以及场景图 [121]。特别是，基于字典的表示，将实体定义为字典中原子的组合，已经在机器人技术和计算机视觉中得到考虑，字典是从数据 [266] 中学习的，或者基于现有的对象模型存储库 [149]、[157]。

E. Open Problems

以下关于 SLAM 度量表示的问题值得进行大量的基础研究，但仍未得到充分探索。

1) *High-Level Expressive Representations in SLAM*: 虽然大多数机器人社区目前都专注于点云或 TSDF 来建模 3D 几何，但这些表示有两个主要缺点。首先，它们浪费内存。例如，两种表示都使用许多参数（即点、体素）来编码甚至一个简单的环境，例如空房间（这个问题可以通过所谓的体素散列 [188] 部分缓解）。其次，这些表示不能提供对 3D 几何的任何高级理解。例如，考虑机器人必须确定它是在房间还是走廊中移动的情况。点云不提供有关环境类型（即房间与走廊）的易于使用的信息。另一方面，更复杂的模型（例如，参数化基元实例）将提供识别两个场景的简单方法（例如，通过查看定义基元的参数）。因此，在 SLAM 中使用更高级别的表示会带来三个方面的影响：

承诺。首先,使用更紧凑的表示将为大规模测绘中的地图压缩提供自然的工具。其次,高级表示将提供对象几何的高级描述,这是促进数据关联、位置识别、语义理解和人机交互的理想功能;这些表示还将为 SLAM 提供强大的支持,能够推理遮挡、利用形状先验,并为物体物理属性(例如重量、动力学)的推理/映射过程提供信息。最后,使用丰富的 3D 表示将能够与现代建筑的施工和管理的现有标准进行交互,包括 CityGML [193] 和 IndoorGML [194]。目前,没有 SLAM 技术可以构建除点云、网格模型、面元模型和 TSDF 之外的更高级别的表示。最近在这个方向上的努力包括[18]、[52]、[231]。

2) *Optimal Representations*: 虽然有相对大量的关于 3D 几何的不同表示的文献,但很少有作品关注于理解哪些标准应该指导特定表示的选择。直观上,在简单的室内环境中,人们应该更喜欢参数化基元,因为很少有参数可以充分描述 3-D 几何形状;另一方面,在复杂的室外环境中,人们可能更喜欢网格模型。那么,我们应该如何比较不同的表示以及如何选择“最优”的表示呢? Requicha [209] 确定了实体表示的几个基本属性,可以比较不同的表示。在这些属性中,我们发现: *domain* (可以表示的真实对象的集合), *concise-ness* (用于存储和传输的表示的“大小”), *ease of creation* (在机器人技术中,这是构建表示所需的“推理”时间),以及 *efficacy in the context of the application* (这取决于使用表示的任务)。因此,“最佳”表示是能够执行给定任务,同时简洁且易于创建的表示。Soatto 和 Chiuso [229] 将最优表示定义为执行给定任务的最小足够统计量,及其对干扰因素的最大不变性。寻找一个通用但易于处理的框架来选择任务的最佳表示仍然是一个悬而未决的问题。

3) *Automatic Adaptive Representations*: 传统上,表示的选择被委托给设计系统的机器人专家,但这有两个主要缺点。首先,设计合适的表示是一项耗时的任务,需要专家的帮助。其次,它不允许任何灵活性:一旦系统被设计出来,选择的表示就不能改变;理想情况下,我们希望机器人根据任务和环境的复杂性使用或多或少复杂的表示。最佳表示的自动设计将对长期导航产生很大影响。

六. 表示二: 语义地图模型

语义映射包括将语义概念与机器人周围的几何实体相关联。最近,人们已经认识到纯几何地图的局限性,这在环境语义映射方面催生了一系列重要且持续的工作,以增强机器人的自主性

和鲁棒性,促进更复杂的任务(例如,驾驶时避免泥泞的道路),从路径规划转向任务规划,并实现先进的人机交互[10], [27], [217]。这些观察结果导致了不同的语义映射方法,这些方法在语义概念的数量和类型以及将它们与环境的不同部分相关联的方式方面有所不同。例如, Pronobis 和 Jensfel [206] 标记了不同的房间,而 Pillai 和 Leonard [201] 在地图中分割了几个已知的物体。除了少数方法之外,基本级别的语义解析被表述为分类问题,其中考虑了感知数据和语义概念之间的简单映射。

A. Semantic Versus topological SLAM

正如第一节中提到的,拓扑映射丢弃了度量信息,仅利用地点识别来构建一个图,其中节点表示可区分的“地点”,而边表示地点之间的可达性。我们注意到, *topological* 映射与 *semantic* 映射截然不同。前者需要识别以前见过的地点(无论该地点是厨房、走廊等),后者感兴趣的是根据语义标签对地点进行分类。Lowry *et al.* [160] 中提出了基于视觉的拓扑 SLAM 的调查,其一些挑战将在第三节中讨论。在本节的其余部分中,我们将重点讨论语义映射。

B. Semantic SLAM: Structure and Detail of Concepts

人类概念的无限数量和概念之间的关系开启了关于语义概念的层次和组织的更加哲学和任务驱动的决策。细节和组织取决于机器人执行任务的内容和地点的背景,并且它们会影响不同阶段问题的复杂性。语义表示是通过定义以下方面来构建的:

- 1) *Level/Detail of Semantic Concepts*: 对于给定的机器人任务,例如“从房间 A 到房间 B”,粗类别(房间、走廊、门)足以成功执行,而对于其他任务,例如“拿起茶杯”,需要更精细的类别(桌子、茶杯、玻璃)。
- 2) *Organization of Semantic Concepts*: 语义概念不是排他性的。更重要的是,单个实体可以拥有无限数量的属性或概念。椅子可以是“可动的”和“可坐的”;餐桌可以是“可移动的”和“不可坐的”。椅子和桌子虽然都是家具,但它们具有可移动的属性,但用途不同。扁平或分层的组织,无论是否共享某些属性,都必须被设计来处理这种概念的多样性。

C. Brief Survey

攻击语义映射以及将语义概念分配给数据有三种主要方法。

- 1) *SLAM Helps Semantics*: 第一批研究语义映射的机器人研究人员首先采用简单的方法,将经典 SLAM 系统构建的度量映射分割为语义概念。早期的一个工作是

Mozos *et al.* [176] 的模型，它使用二维激光扫描构建几何地图，然后通过关联马尔可夫网络以离线方式融合每个机器人姿势的分类语义位置。类似地，Lai *et al.* [148] 从 RGB-D 序列构建 3-D 地图来执行离线对象分类。Pronobis *et al.* [206] 后来提出了在线语义地图系统，他结合了三层推理（感觉、分类和位置），使用激光和摄像头传感器构建环境的语义地图。最近，Cadena *et al.* [27] 使用运动估计，并将粗略语义分割与不同的对象检测器互连，以超越各个系统。Pillai 和 Leonard [201] 使用单目 SLAM 系统来提高视频中对象识别任务的性能。

2) *Semantics Helps SLAM*: 第一个语义图问世后不久，另一个趋势就开始了，即利用已知的语义类或对象。这个想法是，如果我们能够识别地图中的对象或其他元素，那么我们就可以利用有关其几何形状的先验知识来改进该地图的估计。Castle *et al.* [45] 和 Civera *et al.* [51] 使用具有稀疏特征的单目 SLAM 进行了小规模的首次尝试，而 Dame *et al.* [57] 使用密集地图表示进行了小规模尝试。利用 RGB-D 传感器，Salas-Moreno *et al.* [217] 提出了一种基于环境中已知物体检测的 SLAM 系统。

3) *Joint SLAM and Semantics Inference*: 拥有计算机视觉和机器人技术专业知识的科研人员意识到，他们可以在联合公式中执行单目 SLAM 和地图分割。Flint *et al.* [80] 的在线系统提出了一个模型，利用曼哈顿世界假设来分割室内场景中主要平面的地图。Bao *et al.* [10] 提出了第一种使用场景中的几何和语义属性联合估计相机参数、场景点和对象标签的方法。在他们的工作中，作者展示了改进的对象识别性能和鲁棒性，但代价是每个图像对运行 20 分钟，并且有限的对象类别数量使得该方法对于在线机器人操作来说不切实际。在同一行中，Häne *et al.* [103] 解决了户外场景中更专业的类相关优化问题。尽管仍然处于离线状态，但 Kundu *et al.* [147] 通过语义分割和度量图的后期融合来降低问题的复杂性，Sengupta *et al.* [219] 早些时候使用立体相机提出了类似的想法。应该注意的是，[147] 和 [219] 只关注映射部分，他们没有细化后期阶段的早期计算姿势。最近，Vineet *et al.* [251] 提出了一个有前途的在线系统，使用立体相机和密集的地图表示。

D. Open Problems

在 SLAM 中包含语义信息的问题还处于起步阶段，与度量 SLAM 相反，它仍然缺乏一个有凝聚力的表述。图 5 显示了一个建筑工地的简单示例，我们可以在其中找到下面讨论的挑战。

1) *Consistent Semantic-Metric Fusion*: 尽管在时间融合方面已经取得了一些进展，例如，每帧语义证据[219]、[251]，但一致融合多个语义信息源的问题




图 5. 语义理解使人类能够预测不同时间尺度的环境变化。例如，在图中所示的建筑工地中，人类会考虑起重机的运动，并预计起重机卡车在不久的将来不会移动，同时我们可以预测现场的外观，这将使我们即使在施工结束后也能进行定位。这是可能的，因为我们对环境中实体的功能属性和相互关系进行推理。增强我们的机器人具有类似的功能是语义 SLAM 的一个悬而未决的问题。

不同时间点的指标信息仍然开放。将语义分类的置信度或不确定性纳入已知的度量表示的因子图公式中是建立联合语义度量推理框架的一种可能方法。

2) *Semantic Mapping is Much More Than a Categorization Problem*: 语义概念正在演变为更专业的信息，例如地图中实体的可供性和可操作性⁴以及环境中不同活动代理之间可能的交互。如何表示这些属性和相互关系是高级人机交互需要回答的问题。

3) *Ignorance, Awareness, and Adaptation*: 给定一些先验知识，机器人应该能够推理新概念及其语义表示，也就是说，它应该能够发现环境中的新对象或类，通过与其他机器人和人类的主动交互来学习新属性，并使表示适应环境随时间的缓慢和突然变化。例如，假设轮式机器人需要对地形是否可行驶进行分类，以通知其导航系统。如果机器人在道路上发现一些先前被分类为可驾驶的泥浆，则机器人应该根据穿越泥浆区域的难度等级来学习一个新的类别，或者如果感知到另一辆车陷入泥浆中，则调整其分类器。

4) *Semantic-Based Reasoning*⁵: 作为人类，语义表示允许我们压缩和加速对环境的推理，同时评估准确的度量表示需要一些努力。目前，机器人的情况并非如此。机器人可以处理（彩色）度量表示

⁴The term *affordances* refers to the set of possible actions on a given object/environment by a given agent [93], while the term *actionability* includes the expected utility of these actions.

⁵Reasoning in the sense of localization and mapping. This is only a subarea of the vast area of *Knowledge Representation and Reasoning* in the field of Artificial Intelligence that deals with solving complex problems, like having a dialogue in natural language or inferring a person's mood.

但他们并没有真正利用语义概念。我们的机器人目前无法使用环境中的语义概念（类别、关系和属性）有效且高效地定位和连续绘制地图。例如，当检测汽车时，机器人应该推断汽车下方是否存在平坦地面（即使被遮挡），并且当汽车移动时，地图更新应该仅使用新的传感器读数来细化幻觉地面。更重要的是，相同的更新应该通过一次高效的的操作来改变整个汽车的全局姿态，而不是更新每个单独的体素。

七. SLAM 的新理论工具

本节讨论为 SLAM 算法建立性能保证的最新进展，并阐明未解决的问题。理论分析之所以重要，主要有以下三个原因。首先，SLAM 算法和实现通常在少数问题实例中进行测试，很难理解相应的结果如何推广到新实例。其次，理论结果揭示了问题的内在属性，揭示了实证评估过程中可能违反直觉的方面。第三，对问题结构的真正理解可以突破算法的界限，从而扩展可以解决的现实世界 SLAM 实例集。

早期SLAM算法的理论分析都是基于EKF的使用；我们建议读者参考[65]、[255]来全面讨论 EKF SLAM 的一致性和可观察性。⁶这里我们重点关注因子图优化方法。除了实际优势（准确性、效率）之外，因子图优化还提供了一个更易于分析的优雅框架。

在没有先验的情况下，MAP 估计简化为最大似然估计。因此，在没有先验的情况下，SLAM 继承了最大似然估计器的所有属性：(4) 中的估计器是一致的、渐近高斯的、渐近有效的、并且对欧几里德空间中的变换不变[171, Th. 11-1,2]。其中一些属性在存在先验的情况下会丢失（例如，估计器不再是不变的[171, 第 193 页]）。

在这种情况下，我们更感兴趣的是 *algorithmic properties*：给定的算法是否收敛于 MAP 估计？我们如何改进或检查收敛性？存在虚假测量值时的故障点是什么？

A. Brief Survey

大多数SLAM算法基于迭代非线性优化[64]、[100]、[125]、[126]、[192]、[204]。SLAM是一个非凸问题，迭代优化只能保证局部收敛。当算法收敛到局部最小值时，⁷它通常返回一个完全正确的估计

⁶Interestingly, the lack of observability manifests itself very clearly in factor graph optimization, since the linear system to be solved in iterative methods becomes rank-deficient; this enables the design of techniques that can explicitly deal with problems that are not fully observable [265].

⁷We use the term “local minimum” to denote a minimum of the cost which does not attain the globally optimal objective.




图 6. 大多数 SLAM 算法的骨干是机器人轨迹的 MAP 估计，它是通过非凸优化计算的。该图显示了两个模拟基准问题（即球体 a 和环面）的轨迹估计，其中机器人在球体和环面的表面上行进。最上面一行报告了正确的轨迹估计，对应于优化问题的全局最优值。底行显示了由于收敛到局部最小值而导致的不正确的轨迹估计。最近的理论工具能够检测错误的收敛事件，并为故障检测和恢复技术开辟了途径。

错误且不适合导航（见图 6）。对于相对较小的噪声水平，最先进的迭代求解器无法收敛到全局最小成本[33]、[38]。

迭代方法的收敛失败引发了对 SLAM 问题更深入理解的努力。Huang *et al.* [111] 开创了这项工作，其最初的工作讨论了 SLAM 中非凸性的本质。Huang *et al.* [112] 讨论小姿态图优化问题中的最小值的数量。Knuth 和 Barooah [138] 研究了在没有闭环的情况下误差的增长。Carlone [30] 提供了高斯-牛顿法收敛盆地的估计。Carlone 和 Censi [33] 表明旋转估计可以以二维封闭形式求解，并表明相应的估计是唯一的。最近使用替代最大似然公式（例如，假设旋转上存在 Von Mises 噪声 [35]、[211]）已经实现了更强的结果。Carlone 和 Dellaert [32]、[37] 表明，在实践中经常遇到的某些条件（强对偶性）下，最大似然估计是唯一的，并且位姿图优化可以通过（凸）半定规划（SDP）全局解决。[110] 中给出了 SLAM 理论方面的最新概述。

如前所述，理论分析有时是设计更好算法的第一步。除了[32]、[37]的对偶SDP方法之外，其他作者提出了凸松弛以避免收敛到局部最小值。这些贡献包括 Liu *et al.* [159] 和 Rosen *et al.* [211] 的工作。提高收敛性的另一个成功策略是计算适合迭代非线性优化的 *initialization*。在这方面，首先求解旋转并使用所得估计来引导非线性迭代的想法已被证明在实践中非常有效[21]，[31]，[33]，[38]。Khosoussi *et al.* [130] 利用平移和旋转之间的（近似）可分离性来加速优化。

最近在 SLAM 中使用拉格朗日对偶性的理论结果也使得 *verification techniques* 的设计成为可能：给定 SLAM 估计，这些技术能够判断这种估计是否是最优的。能够确定给定 SLAM 解决方案的质量对于为安全关键型应用设计故障检测和恢复策略至关重要。关于 SLAM 验证技术的文献是最近出现的：当前的方法 [32]、[37] 能够通过求解稀疏线性系统来执行验证，并且只要强对偶性成立，就保证提供正确的答案（稍后会详细介绍这一点）。

我们注意到，在机器人技术背景下提出的这些结果为其社区的相关工作提供了有用的补充，包括多智能体系统中的定位[47]、[199]、[202]、[245]、[254]、计算机视觉中的运动结构[87]、[96]、[104]、[168]和冷冻电子显微镜[224]、[225]。

B. Open Problems

尽管过去几年取得了前所未有的进步，但一些理论问题仍然悬而未决。

1) *Generality, Guarantees, and Verification*: 第一个问题涉及现有结果的普遍性。大多数关于有保证的全局解决方案和验证技术的结果都是在位姿图优化的背景下提出的。这些结果可以推广到任意因子图吗？此外，大多数理论结果都假设测量噪声是各向同性的或至少是结构化的。我们可以将现有结果推广到任意噪声模型吗？

Weak or Strong duality? 作品[32]、[37]表明，当强对偶性成立时，SLAM可以全局解决；此外，它们提供的经验证据表明，在实际应用中遇到的大多数问题实例中都存在强对偶性。突出的问题在于建立强对偶性成立的 *a priori* 条件。我们想回答这个问题“给定一组传感器（以及相应的测量噪声统计数据）和一个因子图结构，强对偶性是否成立？”回答这个问题的能力将定义我们可以计算（或验证）SLAM 全局解决方案的应用领域。这项理论研究还将提供传感器设计和主动 SLAM 方面的基本见解（参见第 VIII 节）。

2) *Resilience to Outliers*: 第三个问题涉及存在虚假测量值时的估计。虽然最近的结果为位姿图优化提供了强有力的保证，但这种结果不适用于存在异常值的情况。尽管在鲁棒 SLAM（参见第 III 节）和非高斯噪声情况的新建模工具方面开展了工作 [212]，但对异常值具有弹性的全局技术的设计以及可以在存在异常值的情况下证明给定估计的正确性的验证技术的设计仍然处于开放状态。

八. 主动SLAM

到目前为止，我们将 SLAM 描述为机器人被动执行的估计问题，即机器人对传感器数据执行 SLAM *given*，但没有刻意采取行动来收集数据。在本节中，我们讨论如何利用机器人的运动来改进映射和定位结果。

控制机器人运动以最小化其地图表示和定位的不确定性的问题通常被命名为 *active SLAM*。这个定义源于众所周知的 Bajcsy 的主动感知 [9] 和 Thrun 的机器人探索 [240, 第 1 章]。17] 范式。

A. Brief Survey

主动 SLAM 算法的第一个提议和实现可以追溯到 Feder [78]，而这个名字是在 [152] 中创造的。然而，主动 SLAM 的根源可以追溯到 80 年代初的人工智能和机器人探索思想（参见 [11]）。Thrun 在 [239] 中得出结论，解决 *exploration-exploitation* 困境，即在访问新地方（探索）和通过重新访问已知区域（开发）来减少不确定性之间找到平衡，为随机探索或纯粹开发提供了更有效的替代方案。

主动 SLAM 是一个决策问题，有几种通用的决策框架可以用作探索-利用决策的支柱。这些框架之一是最优实验设计理论 (TOED) [198]，它应用于主动 SLAM [42]、[44]，允许根据预测的地图不确定性选择未来的机器人动作。信息论 [164]、[208] 方法也已应用于主动 SLAM [41]、[232]；在这种情况下，决策通常由 *information gain* 的概念指导。主动 SLAM 的控制理论方法包括使用模型预测控制 [152]、[153]。另一些工作在部分可观察马尔可夫决策过程 [123] 的形式下制定了主动 SLAM，众所周知，这在计算上是困难的；主动 SLAM 的近似但易于处理的解决方案包括贝叶斯优化 [169] 或有效的高斯信念传播 [195] 等。

主动 SLAM 的流行框架包括在一组有限的备选方案中选择最佳的未来行动。这一系列主动 SLAM 算法分三个主要步骤进行 [16]、[36]，如下所示：

- 1) 机器人在其当前对地图的估计中识别出可能探索或利用的位置，即有利位置。
- 2) 机器人计算访问每个有利位置的效用，并选择效用最高的动作。
- 3) 机器人执行选定的动作并决定是否有必要继续或终止任务。

下面，我们详细讨论每一点。

1) *Selecting Vantage Points*: 理想情况下，执行主动 SLAM 算法的机器人应该评估机器人和地图空间中的每一个可能的动作，但评估的计算复杂性随着搜索空间呈指数增长，这在实际应用中被证明是计算困难的 [25]、[169]。在实践中，使用基于边界的探索 [127]、[262] 等技术选择地图中的一小部分位置。最近的工作 [250] 和 [116] 提出了不确定性下连续空间规划的方法，可用于主动 SLAM；目前这些方法只能保证收敛到局部最优策略。主动 SLAM 算法的另一个最新连续域途径是使用势场。一些例子

是[249], 它使用卷积技术来计算熵并选择机器人的动作, 以及[122], 它诉诸边界值问题的解决方案。

2) *Computing the Utility of an Action*: 理想情况下, 为了计算给定动作的效用, 机器人应该推理机器人姿势和地图的后验演化, 同时考虑未来(可控)动作和未来(未知)测量。如果这样的后验已知, 则可以使用信息论函数(作为信息增益)对不同的动作进行排序[23]、[233]。然而, 一般来说, 通过分析方式计算这种联合概率在计算上是困难的[36]、[77]、[233]。在实践中, 人们会求助于近似值。最初的工作认为地图和机器人的不确定性是独立的[246]或有条件独立的[233]。大多数这些方法将效用定义为量化机器人和地图不确定性的指标的线性组合[23]、[36]。这种方法的一个缺点是两个不确定性的数值范围不具有可比性, 即地图的不确定性通常比机器人的不确定性大几个数量级, 因此需要手动调整来纠正它。已经针对基于粒子滤波器的 SLAM [36] 和位姿图优化 [41] 提出了解决这个问题的方法。

TOED [198]也可以用来解释执行一个动作的效用。在 TOED 中, 每个动作都被视为随机设计, 设计之间的比较是通过所谓的最优性标准(例如 *A-opt*、*D-opt* 和 *E-opt*)使用其关联的协方差矩阵来完成的。关于主动 SLAM 中最优性标准的使用的研究可以在 [44] 和 [43] 中找到。

3) *Executing Actions or Terminating Exploration*: 虽然执行动作通常是一项简单的任务, 但使用运动规划中成熟的技术, 决定探索任务是否完成, 目前是一个公开的挑战, 我们将在下一段中讨论。

B. Open Problems

为了使主动 SLAM 在实际应用中产生影响, 仍有几个问题需要解决。

1) *Fast and Accurate Predictions of Future States*: 在主动 SLAM 中, 机器人的每个动作都应该有助于减少地图中的不确定性, 提高定位精度; 为此, 机器人必须能够预测未来动作对地图和机器人定位的影响。预测必须快速以满足延迟限制, 并且必须精确才能有效支持决策过程。在 SLAM 社区中, 众所周知, 闭环对于减少不确定性以及提高定位和建图精度非常重要。尽管如此, 尚未设计出预测闭环发生及其影响的有效方法。此外, 预测未来行动的影响仍然是一项计算成本高昂的任务[116]。最近预测未来机器人状态的方法可以在机器学习文献中找到, 并且涉及谱技术 [230]和深度学习[252]的使用。

Enough is Enough: When do you stop doing active SLAM? 主动 SLAM 是一项计算成本较高的任务: 因此: 一个自然的问题是我们何时可以停止主动 SLAM 并切换到经典(被动) SLAM, 以便将资源集中在其他任务上。平衡主动 SLAM 决策和

外生任务至关重要, 因为在大多数现实世界的任务中, 主动 SLAM 只是实现预期目标的一种手段。此外, 有一个停止标准是必要的, 因为在某些时候, 可以证明更多的信息不仅会导致回报效应递减, 而且在信息矛盾的情况下, 还会导致不可恢复的状态(例如, 几个错误的闭环)。与难以跨系统进行比较的信息论指标相比, TOED 的不确定性指标(面向任务)似乎有望作为停止标准 [40]。

2) *Performance Guarantees*: 另一个重要途径是寻找主动 SLAM 和近乎最优策略的数学保证。由于精确地解决问题很困难, 因此需要具有明确性能界限的近似算法。这种努力的例子是在有源传感器放置的相关领域中使用子模块化[94]。

九. 新领域: 传感器和学习

新传感器的开发和新计算工具的使用通常是 SLAM 的关键驱动力。第 IX-A 节回顾了非常规和新型传感器, 以及它们在 SLAM 背景下带来的挑战和机遇。第 IX-D 节讨论了(深度)学习作为 SLAM 重要前沿领域的作用, 分析了该工具改进、影响甚至重述 SLAM 问题的可能方式。

A. New and Unconventional Sensors for SLAM

除了新算法的开发之外, SLAM (以及一般的移动机器人技术)的进步往往是由新型传感器的可用性引发的。例如, 2D 激光测距仪的引入使得能够创建非常强大的 SLAM 系统, 而 3D 激光雷达一直是自动驾驶汽车等近期应用的主要推动力。在过去的十年中, 大量的研究致力于视觉传感器, 并在增强现实和基于视觉的导航方面取得了成功的应用。

机器人技术中的传感主要由激光雷达和传统视觉传感器主导。然而, 有许多替代传感器可用于 SLAM, 例如深度、光场和基于事件的相机, 这些传感器现在已成为商品硬件, 以及磁、嗅觉和热传感器。

1) *Brief Survey*: 我们回顾了最相关的新型传感器及其 SLAM 应用, 并将对未决问题的讨论推迟到本节末尾。

a) *Range cameras*: 发光深度摄像头并不是新传感器, 但随着 2010 年 Microsoft Kinect 游戏机的出现, 它们成为商品硬件。它们根据不同的原理工作, 例如结构光、飞行时间、干涉测量或编码孔径。结构光相机通过三角测量工作; 因此, 它们的精度受到相机和图案投影仪(结构光)之间的距离的限制。相比之下, 飞行时间 (ToF) 相机的精度仅取决于 TOF 测量设备; 因此, 它们提供最高的测距精度(几米处亚毫米)。ToF 相机投入商用

2000 年左右用于民用, 但 2004 年才开始用于移动机器人[256]。虽然第一代 ToF 和结构光相机的特点是信噪比低且价格昂贵, 但它们很快在视频游戏应用中流行起来, 这有助于使其价格实惠并提高其准确性。由于测距相机带有自己的光源, 因此它们也可以在黑暗和无纹理的场景中工作, 从而实现了显着的 SLAM 效果[183]。

b) Light-field cameras: 与仅记录照射到每个像素的光强度的标准相机相反, 光场相机(也称为全光相机)记录光线的强度和方向[186]。一种流行的光场相机使用放置在传统图像传感器前面的微透镜阵列来感测强度、颜色和方向信息。由于制造成本的原因, 商用光场相机的分辨率仍然相对较低($<1\text{MP}$), 当前的技术努力正在克服这一问题。与标准相机相比, 光场相机具有多种优势, 例如深度估计、降噪[58]、视频稳定[227]、干扰物隔离[59]和镜面反射消除[119]。与传统相机相比, 它们的光学器件还提供大光圈和大景深[15]。

c) Event-based cameras: 与以固定帧速率发送整个图像的标准基于帧的相机相反, 基于事件的相机, 例如动态视觉传感器(DVS)[156]或基于异步时间的图像传感器(ATIS)[205], 仅发送由场景中的运动发生时引起的局部像素级变化。

与传统的基于帧的相机相比, 它们具有五个关键优势: 1毫秒的时间延迟、高达1 MHz的更新速率、高达140 dB的动态范围(标准相机为60-70 dB)、20 mW的功耗(标准相机为1.5 W)以及非常低的带宽和存储要求(因为仅传输强度变化)。这些特性使得能够设计出一类新型 SLAM 算法, 该算法可以在以高速运动[90]和高动态范围[132]、[207]为特征的场景中运行, 而标准相机在这些场景中无法做到这一点。然而, 由于输出由一系列异步事件组成, 因此传统的基于帧的计算机视觉算法不适用。这需要过去 50 年开发的传统计算机视觉方法中的 *paradigm shift*。最近提出了基于事件的实时定位和映射算法[132]、[207]。此类算法的设计目标是每个传入事件都可以异步更改系统的估计状态, 从而保留传感器基于事件的性质并允许设计微秒延迟控制算法[178]。

2) Open Problems: 主动测距相机的主要瓶颈是最大范围和对其他外部光源(例如太阳光)的干扰; 然而, 这些弱点可以通过发射更多的光功率来改善。

光场相机很少用于 SLAM, 因为它们通常被认为会增加产生的数据量并且需要更多的计算能力。然而, 最近的研究表明它们特别适合 SLAM 应用, 因为它们允许制定运动估计

问题作为线性优化, 如果设计得当, 可以提供更准确的运动估计[66]。

基于事件的相机是革命性的图像传感器, 克服了标准相机在高动态范围和高速运动场景中的局限性。未解决的问题涉及传感器噪声和传感器非理想性的完整表征: 基于事件的相机具有复杂的模拟电路, 其非线性和偏差可以改变像素的灵敏度, 以及其他动态特性, 这使得事件容易受到噪声的影响。由于单个事件没有携带足够的信息用于状态估计, 并且事件相机平均每秒生成 100 000 个事件, 因此由于状态空间大小的快速增长, 在单个事件的离散时间执行 SLAM 可能变得很困难。使用连续时间框架[13], 估计轨迹可以使用基函数(例如三次样条)通过刚体运动空间中的平滑曲线来近似, 并根据观察到的事件进行优化[177]。虽然时间分辨率非常高, 但基于事件的相机的空间分辨率相对较低(QVGA), 当前的技术努力正在克服这一问题[155]。新开发的事件传感器克服了一些原始限制: ATIS 传感器发送像素级亮度的大小; DAVIS 传感器[155]可以输出帧和事件(这是通过将标准的基于帧的传感器和 DVS 嵌入到同一像素阵列中来实现的)。这将允许在帧之间的盲区内跟踪特征和运动[144]。

我们通过一些关于 SLAM 新型传感模式使用的一般观察来结束本节。

a) Other sensors: 大多数 SLAM 研究都致力于范围和视觉传感器。然而, 人类或动物能够通过使用触觉、嗅觉、声音、磁和热刺激来提高其感知能力。例如, 盲人或啮齿类动物利用触觉线索对物体进行触觉探索, 蜜蜂利用嗅觉来寻找回家的路, 信鸽利用磁场进行导航, 蝙蝠利用声音进行障碍物检测和导航, 而一些蛇可以看到热物体发出的红外辐射。不幸的是, 这些替代传感器并没有像距离和视觉传感器一样被考虑来执行 SLAM。触觉 SLAM 可用于对象或场景的触觉探索[237]、[263]。嗅觉传感器可用于定位气体或其他气味源[167]。尽管基于超声波的定位在早期移动机器人中占主导地位, 但随着廉价光学距离传感器的出现, 它们的使用迅速下降。然而, 蝙蝠等动物仅使用回声定位就可以以非常高的速度导航。热传感器在夜间和恶劣天气条件下提供重要线索[165]。许多室内环境中存在的环境磁场的局部异常为定位提供了极好的线索[248]。最后, 现有的无线网络(例如 WiFi)可用于改进机器人导航, 而无需事先了解天线的位置[79]。

Which sensor is best for SLAM? 自然出现的一个问题是: 推动未来长期 SLAM 研究的下一个传感器技术是什么? 显然, SLAM 的给定算法-传感器对的性能取决于传感器和算法参数以及环境[228]。一个完整的

如何选择算法和传感器以达到最佳性能的治疗方法尚未找到。Censi *et al.* [46] 的一项初步研究表明, 给定任务的性能还取决于可用于传感的功率。它还表明, 最佳传感架构可能具有多个传感器, 这些传感器可以根据所需的性能水平瞬时打开和关闭, 或者通过不同的物理原理测量相同的现象以实现鲁棒性[69]。

B. Deep Learning

一篇旨在考虑 SLAM 未来发展方向的论文是失职的, 更不用说深度学习了。它对计算机视觉的影响是革命性的, 在撰写本文时, 它已经对包括 SLAM 在内的传统机器人技术产生了重大影响。

研究人员已经证明, 可以学习深度神经网络来直接从原始图像对中回归从移动机器人获取的两个图像之间的帧间姿态[53], 从而有效地取代视觉里程计的标准几何结构。同样, 可以使用回归森林[247]和深度卷积神经网络[129]来定位相机的6DoF, 并从单个视图估计场景(实际上是地图)的深度, 仅作为输入图像的函数[28]、[71]、[158]。

在我们看来, 这并不意味着传统的 SLAM 已经消亡, 而且现在说这些方法是否只是简单地展示原则上可以做什么的好奇心, 但它们不会取代传统的、易于理解的方法, 或者它们是否会完全取代, 还为时过早。

1) *Open Problems*: 我们在此强调了 SLAM 的一系列未来方向, 我们相信机器学习和更具体的深度学习将产生影响, 或者 SLAM 应用将为深度学习带来挑战。

a) *Perceptual tool*: 显然, 一些现有的计算机视觉算法无法解决的感知问题现在可以得到解决。例如, imagenet 类 [213] 的对象识别现在在某种程度上可以被视为黑匣子, 从机器人专家或 SLAM 研究人员的角度来看, 它工作得很好。同样, 各种场景类型中像素的语义标记达到了约 80% 准确度或更高的性能水平 [75]。我们已经对 SLAM 系统向语义更有意义的地图的发展进行了广泛的评论, 而这些黑盒工具将加速这一进程。但还有更多的利害关系: 与之前的任何网络相比, 深度网络在将原始传感器数据连接到理解或将原始传感器数据连接到行动方面显示出了更多的前景。

b) *Practical deployment*: 深度学习的成功主要取决于超级计算机上的长时间训练以及专用 GPU 硬件上的推理以获得一次性结果。SLAM 研究人员(或者实际上任何想要将令人印象深刻的结果嵌入到他们的系统中的人)面临的挑战是如何在嵌入式系统中提供足够的计算能力。我们是简单地等待技术迎头赶上, 还是研究更小、更便宜、能够产生“足够好”结果的神经网络, 并考虑长期传感的影响?

c) *Online and life-long learning*: 一个更大、更重要的挑战是在线学习和适应, 这对于任何未来的长期 SLAM 系统都至关重要。SLAM 系统通常在一个持续观察的开放世界中运行, 在那里可以遇到新的物体和场景。但迄今为止, 深度网络通常是在具有固定数量的对象类的封闭世界场景中进行训练的。一个重大挑战是在单次或零次场景(即一个新类的一个甚至零个训练示例)中利用深度网络的力量, 以实现持续移动、持续观察的 SLAM 系统的终身学习。

同样, 现有网络倾向于在大量标记数据上进行训练, 但不能总是保证存在合适的数据集或可用于标记监督训练。最近取得一些进展的一个领域是单视图深度估计: Garg *et al.* [91] 最近展示了如何通过观察大量立体对语料库来简单地训练用于单视图深度估计的深度网络, 而不需要显式地观察或计算深度。是否可以为语义场景标记等任务开发类似的方法还有待观察。

d) *Bootstrapping*: 越来越多的证据表明, 有关场景的先验信息可以为 SLAM 系统提供显着的提升。迄今为止文献中的例子包括已知的对象[57]、[217]或有关场景中预期结构的先验知识, 例如DTAM[184]中的平滑度、[80]中的曼哈顿约束, 甚至对象之间的预期关系[10]。显然, 深度学习能够为特定任务(例如估计场景标签或场景深度)提炼此类先验知识。如何最好地提取和使用这些信息是一个重大的开放性问题。它在 SLAM 中比其他一些领域更相关, 因为在 SLAM 中, 我们对场景几何的数学有扎实的掌握——接下来的问题是如何将这种易于理解的几何与深度网络的输出融合起来。必须解决的一个特殊挑战是表征从深层网络得出的估计的不确定性。

SLAM 为探索深度学习架构和大规模图形模型中的递归状态估计之间的潜在联系提供了一个具有挑战性的环境。例如, Krishan *et al.* [142]最近提出了深度卡尔曼滤波器; 也许有一天可以使用深层架构创建一个端到端的 SLAM 系统, 而不需要显式的特征建模、数据关联等。

十、结论

同步定位和地图绘制问题在过去 30 年中取得了巨大进展。一路走来, 随着新应用、新传感器和新计算工具的发展, 一些重要问题得到了解答, 同时也提出了许多新的有趣的问题。

重新审视“SLAM 有必要吗?”这个问题。我们相信答案取决于应用程序, 但答案通常是响亮的yes。SLAM 和相关技术(例如视觉惯性里程计)正越来越多地部署在从自动驾驶汽车到移动设备的各种现实环境中。在基于基础设施的解决方案(例如 GPS)不可用或不提供的情况下, 将越来越依赖 SLAM 技术来提供可靠的度量定位

足够的准确度。由于移动设备和代理的定位信息的价值,人们可以预见基于云的位置即服务功能即将上线,地图将变得商品化。

在某些应用中,例如自动驾驶汽车,通常通过将当前传感器数据与预先创建的高清环境地图进行匹配来执行精确定位[154]。如果[a priori](#)地图准确,则不需要在线SLAM。然而,在高度动态的环境中运营将需要动态在线地图更新,以应对道路基础设施的建设或重大变化。由大型自动驾驶车辆创建的视觉地图的分布式更新和维护是未来工作的一个引人注目的领域。

人们可以识别出不同风格的 SLAM 公式比其他公式更适合的任务。例如,拓扑图可用于分析给定地点的可达性,但它不适合运动规划和低级控制;局部一致的度量地图非常适合避障和与环境的局部交互,但它可能会牺牲准确性;全局一致的度量地图允许机器人执行全局路径规划,但计算和维护可能需要大量计算。

人们甚至可以设计一些例子,其中 SLAM 完全没有必要,可以用其他技术代替,例如用于本地控制和稳定的视觉伺服,或“教导和重复”来执行重复的导航任务。选择最合适的 SLAM 系统的一种更通用的方法是将 SLAM 视为一种计算足够统计量的机制,该统计量总结了机器人过去的所有观察结果,从这个意义上说,在这种压缩表示中保留哪些信息是深度依赖于任务的。

至于大家熟悉的问题“SLAM 解决了吗?”在这篇立场文件中,我们认为,当我们输入 *robust-perception age* 时,如果不指定机器人/环境/性能组合,则无法回答该问题。对于许多应用和环境来说,许多重大挑战和重要问题仍然悬而未决。为了实现长寿命自主机器人真正强大的感知和导航,需要对 SLAM 进行更多研究。作为一项具有重要现实意义的学术努力,SLAM 已得到解决。

未解决的问题涉及四个主要方面:*robust per-、formance*、*high-level understanding*、*resource awareness*和*task-driven inference*。从鲁棒性的角度来看,故障安全自调整 SLAM 系统的设计是一个艰巨的挑战,许多方面在很大程度上尚未被探索。对于长期自治,构建和维护大规模时变地图的技术,以及定义何时记住、更新或忘记信息的策略,仍然需要大量的基础研究;在资源严重受限的机器人系统中,也会出现不同规模的类似问题。

另一个基本问题涉及环境的度量和语义表示的设计。尽管与环境的交互对于大多数机器人应用来说至关重要,但现代 SLAM 系统无法提供对周围世界的几何形状和语义的紧密耦合的高级理解;此类表示的设计必须是任务驱动的,并且当前

缺乏将任务与最佳表示联系起来的易于处理的框架。开发这样的框架将把机器人和计算机视觉社区聚集在一起。

除了讨论 SLAM 社区的许多成就和未来挑战之外,我们还研究了与使用新型传感器、新工具(例如凸松弛和对偶理论或深度学习)以及主动传感的作用相关的机会。SLAM 仍然是大多数机器人应用不可或缺的支柱,尽管过去几十年取得了惊人的进步,但现有的 SLAM 系统远不能提供有洞察力、可操作且紧凑的环境模型,与人类轻松创建和使用的模型相比。

致谢

作者要感谢 Google Plus 社区 [26] 的所有贡献者和成员,特别是 L. Paul、A. Handa、S. Griffith、H. Tomé、A. Censi 和 R. M. Artal,他们为 SLAM 中的开放问题的讨论提供了意见。他们还感谢 RSS 研讨会的所有演讲者 [26], J. D. Tardos、S. Huang、R. Eustice、P. Pfaff、J. Meltzer、J. Hesch、E. Nerurkar、R. Newcombe、Z. Zia 和 A. Geiger; 在准备本文件期间请 G. (Paul) Huang 和 U. Frese 进行讨论;感谢 G. Gallego 和 J. Delmerico 对本文件的早期评论。最后,他们深深感谢 T-RO 编辑团队,包括主编 F. Park、副主编和所有审稿人,感谢他们及时、有价值和建设性的反馈意见,极大地提高了本文的质量。

参考

- [1] P. A. Absil, R. Mahony 和 R. Sepulchre, *Optimization Algorithms on Matrix Manifolds*. 美国新泽西州普林斯顿: 普林斯顿大学. 出版社, 2007 年.
- [2] E. Ackerman, “戴森扫地机器人配备 360 度摄像头、罐体履带、旋风吸力”, *IEEE Spectr.*, 2014 年. [在线]. 可用: <http://spectrum.ieee.org/automaton/robotics/home-robots/dyson-the-360-eye-robot-vacuum>
- [3] S. Agarwal, N. Snavely, I. Simon, S. M. Seitz, and R. Szeliski, “Bundle adjustment in the large,” in *Proc. Eur. Conf. Comput. Vis.*, 2010, pp. 29–42.
- [4] S. Anderson, T. D. Barfoot, C. H. Tong 和 S. Särkkä, “批量非线性连续时间轨迹估计作为精确的稀疏高斯过程回归”, *Auton. Robots*, 卷. 39, 没有. 3, 第 221–238 页, 2015 年 10 月.
- [5] S. Anderson, F. Dellaert 和 T. D. Barfoot, “连续时间 SLAM 的分层小波分解.” 见 *Proc. IEEE Int. Conf. Robot. Autom.*, 2014 年, 第 373–380 页.
- [6] R. Aragues, J. Cortes 和 C. Sagues, “用于动态合并基于特征的地图的机器人网络的分布式共识”, *IEEE Trans. Robot.*, 卷. 28, 没有. 4, 第 840–854 页, 2012 年 8 月.
- [7] J. Aulinas, Y. Petillot, J. Salvi 和 X. Lladó, “SLAM 问题: 一项调查”, *Proc. Int. Conf. Catalan Assoc. Artif. Intell.*, 2008 年, 第 363–371 页.
- [8] T. Bailey 和 H. F. Durrant-Whyte, “同步定位和地图构建 (SLAM): 第二部分”, *Robot. Auton. Syst.*, 卷. 13, 没有. 3, 第 108–117 页, 2006 年.
- [9] R. Bajcsy, “主动感知”, *Proc. IEEE*, 卷. 76, 没有. 8, 第 966–1005 页, 1988 年 8 月.
- [10] S. Y. Bao, M. Bagra, Y. W. Chao 和 S. Savarese, “点、区域和对象运动的语义结构”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2012 年, 第 2703–2710 页.
- [11] A. G. Barto 和 R. S. Sutton, “自适应智能的目标寻求组件: 初步评估”, 空军赖特航空实验室. 莱特-帕特森空军基地, 美国俄亥俄州代顿, 科技大学. 众议员 AFWAL-TR-81-1070, 1981 年 1 月.

- [12] C. Bibby 和 I. Reid, “具有可逆数据关联的动态环境中的同步定位和建图 (SLAMIDE)”, 载于 *Proc. Robot.: Sci. Syst. Conf.*, 美国佐治亚州亚特兰大, 2007 年 6 月, 第 105-112 页。[13] C. Bibby 和 I. D. Reid, “动态海洋环境的混合 SLAM 表示”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2010 年, 第 1050-4729 页。[14] T. O. Binford, “计算机视觉感知”, 载于 *Proc. IEEE Conf. Syst. Controls*, 1971 年, 第 116-123 页。[15] T. E. Bishop 和 P. Favaro, “光场相机: 扩展景深、混叠和超分辨率”, *IEEE Trans. Pattern Anal. Mach. Intell.*, 卷. 34, 没有。[16] J. L. Blanco, J. A. Fernández-Madriral 和 J. Gonzalez, “采用 RaoBlackwellized 粒子滤波器的移动机器人 SLAM 不确定性的新颖测量”, *Int. J. Robot. Research*, 第 5 期, 第 972-986 页, 2012 年 5 月。27、没有。1, 第 73-89 页, 2008 年。[17] J. Bloomenthal, *Introduction to Implicit Surfaces*. 美国加利福尼亚州圣马特奥: Morgan Kaufmann, 1997。[18] A. Bodis-Szomoru, H. Riemenschneider 和 L. Van Gool, “城市场景的高效边缘感知表面网格重建”, *J. Comput. Vis. Image Understanding*, 卷. 66, 第 91-106 页, 2015 年。[19] M. Bosse, P. Newman, J. J. Leonard 和 S. Teller, “使用图卷积框架在大规模循环环境中进行同步定位和地图构建”, *Int. J. Robot. Research*, 卷. 23、没有。12, 第 1113-1139 页, 2004 年。[20] M. Bosse 和 R. Zlot, “使用旋转 2D 激光进行连续 3D 扫描匹配”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2009 年, 第 4312-4319 页。[21] M. Bosse 和 R. Zlot, “2D LIDAR 地图中地点识别的关键点设计和评估”, *Robot. Auton. Syst.*, 卷. 57、没有。12, 第 1211-1224 页, 2009 年。[22] M. Bosse, R. Zlot 和 P. Flick, “Zebedee: 弹簧安装 3D 距离传感器的设计及其在移动测绘中的应用”, *IEEE Trans. Robot.*, 卷. 28、没有。5, 第 1104-1119 页, 2012 年 10 月。[23] F. Bourgault, A. A. Makarenko, S. B. Williams, B. Grocholsky 和 H. F. Durrant-Whyte, “基于信息的自适应机器人探索”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2002 年, 第 540-545 页。[24] C. Brand, M. J. Schuster, H. Hirschmüller 和 M. Suppa, “用于室内/室外 SLAM 的基于立体视觉的障碍物测绘”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2014 年, 第 2153-0858 页。[25] W. Burgard, M. Moors, C. Stachniss 和 F. E. Schneider, “协调多机器人探索”, *IEEE Trans. Robot.*, 卷. 21、没有。3, 第 376-386 页, 2005 年 6 月。[26] C. Cadena et al., “机器人: 科学与系统 (RSS), 研讨会”, 移动传感器问题: 为 SLAM 设定未来目标和进度指标, 2015 年 6 月。[在线]。可用: <http://ylatif.github.io/movingsensors/>, Google Plus 社区: <https://plus.google.com/communities/102832228492942322585> [27] C. Cadena, A. Dick 和 I. D. Reid, “使用上下文感知对象检测的快速模块化场景理解系统”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 4859-4866 页。[28] C. Cadena, A. Dick 和 I. D. Reid, “多模态自动编码器作为机器人场景理解的联合估计器”, *Proc. Robot.: Sci. Syst. Conf.*, 2016 年, 第 377-386 页。[29] N. Carlevaris-Bianco 和 R. M. Eustice, “姿态图 SLAM 的基于通用因子的节点边缘化和边缘稀疏化”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 5748-5755 页。[30] L. Carlone, “通过高斯-牛顿方法进行位姿图优化的收敛分析”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 965-972 页。[31] L. Carlone, R. Aragues, J. A. Castellanos 和 B. Bona, “平面位姿图优化的快速准确近似”, *Int. J. Robot. Res.*, 卷. 33、没有。7, 第 965-987 页, 2014 年。[32] L. Carlone, G. Calafiore, C. Tommolillo 和 F. Dellaert, “平面位姿图优化: 对偶性、最优解和验证”, *IEEE Trans. Robot.*, 卷. 32、没有。3, 第 545-565 页, 2016 年 6 月。[33] L. Carlone 和 A. Censi, “从角度流形到整数晶格: 保证方向估计及其应用于位姿图优化”, *IEEE Trans. Robot.*, 卷. 30, 没有。2, 第 475-492 页, 2014 年 4 月。[34] L. Carlone, A. Censi 和 F. Dellaert, “通过 ℓ_1 松弛选择良好的测量: 对图进行鲁棒估计的凸方法”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2014 年, 第 2667-2674 页。[35] L. Carlone 和 F. Dellaert, “基于对偶性的 2D SLAM 验证技术”, *Proceedings IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 4589-4596 页。[36] L. Carlone, J. Du, M. Kaouk, B. Bona 和 M. Indri, “使用 Kullback-Leibler 散度的粒子滤波器的主动 SLAM 和探索”, *J. Intell. Robot. Syst.*, 卷. 75, 没有。2, 第 291-311 页, 2014 年。[37] L. Carlone, D. Rosen, G. Calafiore, J. J. Leonard 和 F. Dellaert, “3D SLAM 中的拉格朗日对偶性: 验证技术和最优解决方案”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2015 年, 第 125-132 页。[38] L. Carlone, R. Tron, K. Daniilidis 和 F. Dellaert, “3D SLAM 的初始化技术: 旋转估计及其在位姿图优化中的应用的调查”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 4597-4604 页。[39] J. C. Carr et al., “利用径向基函数重建和表示 3D 对象”, *Proc. SIGGRAPH 28th Annu. Conf. Comput. Graph. Interactive Techn.*, 2001 年, 第 67-76 页。[40] H. Carrillo, O. Birbach, H. Taubig, B. Bauml, U. Frese 和 J. A. Castellanos, “机器人校准中配置选择的任务导向标准”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 3653-3659 页。[41] H. Carrillo, P. Dames, K. Kumar 和 J. A. Castellanos, “基于 Shannon 和 Rényi 熵的使用占用网格图和图 SLAM 的自主机器人探索”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 487-494 页。[42] H. Carrillo, Y. Latif, J. Neira 和 J. A. Castellanos, “图形地图表示上的快速最小不确定性搜索”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2012 年, 第 2504-2511 页。[43] H. Carrillo, Y. Latif, M. L. Rodríguez, J. Neira 和 J. A. Castellanos, “主动 SLAM 探索过程中最优性标准的单调性”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 1476-1483 页。[44] H. Carrillo, I. Reid 和 J. A. Castellanos, “主动 SLAM 不确定性标准的比较”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 2080-2087 页。[45] R. O. Castle, D. J. Gawley, G. Klein 和 D. W. Murray, “实现手持式和可穿戴相机的同步识别、定位和映射”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2007 年, 第 4102-4107 页。[46] A. Censi, E. Mueller, E. Frazzoli 和 S. Soatto, “比较传感器系列的功耗性能方法, 以及用于比较神经形态传感器和传统视觉传感器的应用”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 3319-3326 页。[47] A. Chiuso, G. Picci 和 S. Soatto, “特殊正交群的广义估计”, *Commun. Infor. Syst.*, 卷. [48] S. Choudhary, L. Carlone, C. Nieto, J. Rogers, H. I. Christensen 和 F. Dellaert, “具有隐私和通信约束的分布式轨迹估计: 两阶段分布式 Gauss-Seidel 方法”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 8 页, 第 185-200 页, 2008 年。5261-5268。[49] W. Churchill 和 P. Newman, “基于经验的长期本地化导航”, *Int. J. Robot. Res.*, 卷. 32、没有。14, 第 1645-1661 页, 2013 年。[50] T. Cieslewski, L. Simon, M. Dymczyk, S. Maguenat 和 R. Siegwart, “Map API — 用于机器人的可扩展去中心化地图构建”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 6241-6247 页。[51] J. Civera, D. Gálvez-López, L. Riazuelo, J. D. Tardós 和 J. M. M. Montiel, “使用单目相机实现语义 SLAM”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2011 年, 第 1277-1284 页。[52] A. Cohen, C. Zach, S. Sinha 和 M. Pollefeys, “从运动中发现和利用结构中的 3D 对称性”, 载于 *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2012 年, 第 1514-1521 页。[53] G. Costa, M. Mancini, P. Valigi 和 T. A. Ciarfuglia, “探索使用 CNN 进行帧到帧自我运动估计的表示学习”, *IEEE Robot. Autom. Lett.*, 卷. 1、没有。1, 第 18-25 页, 2016 年 1 月。[54] M. Cummins 和 P. Newman, “FAB-MAP: 外观空间中的概率定位和映射”, *Int. J. Robot. Res.*, 卷. 27、没有。6, 第 647-665 页, 2008 年。[55] A. Cunningham, V. Indelman 和 F. Dellaert, “DDF-SAM 2.0: 一致的分式平滑和映射”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 5220-5227 页。[56] B. Curless 和 M. Levoy, “从距离图像构建复杂模型的体积方法”, *Proc. SIGGRAPH 23rd Annu. Conf. Comput. Graph. Interactive Techn.*, 1996 年, 第 303-312 页。[57] A. Dame, V. A. Prisacariu, C. Y. Ren 和 I. D. Reid, “使用 3D 对象形状先验的密集重建”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2013 年, 第 1288-1295 页。

- [58] D. G. Dansereau, D. L. Bongiorno, O. Pizarro 和 S. B. Williams, “使用线性 4D 频率超扇全焦点滤波器进行光场图像去噪”, *Proc. SPIE Conf. Comput. Imag.*, 2013 年, 第 1 卷. 8657, 第 1-14 页.
- [59] D. G. Dansereau, S. B. Williams 和 P. Corke, “移动光场相机的简单变化检测”, *Comput. Vis. Image Understanding*, 卷. 145, 第 160-171 页, 2016 年.
- [60] A. Davison, I. Reid, N. Molton 和 O. Stasse, “MonoSLAM: 实时单相机 SLAM”, *IEEE Trans. Pattern Anal. Mach. Intell.*, 卷. 29, 没有. 6, 第 1052-1067 页, 2007 年 6 月.
- [61] F. Dayoub, G. Cielniak 和 T. Duckett, “在不断变化的环境中使用自适应球形视图表示进行导航的长期实验”, *Robot. Auton. Syst.*, 卷. 59, 没有. 5, 第 285-295 页, 2011 年.
- [62] F. Dellaert, “因子图和 GTSAM: 实践介绍”, 佐治亚理工学院, 亚特兰大, 佐治亚州, 美国, Tech. 报告 GT-RIM-CP&R-2012-002, 2012 年 9 月.
- [63] F. Dellaert, J. Carlson, V. Ila, K. Ni 和 C. E. Thorpe, “大规模 SLAM 的子图预处理共轭梯度”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2010 年, 第 2566-2571 页.
- [64] F. Dellaert 和 M. Kaess, “平方根 SAM: 通过平方根信息平滑进行同步定位和映射”, *Int. J. Robot. Res.*, 卷. 25, 没有. 12, 第 1181-1203 页, 2006 年.
- [65] G. Dissanayake, S. Huang, Z. Wang 和 R. Ranasinghe, “同时定位和地图绘制的最新发展回顾”, *Proc. Int. Conf. Ind. Inform. Syst.*, 2011 年, 第 477-482 页.
- [66] F. Dong, S.-H. Ieng, X. Savatier, R. Etienne-Cummings 和 R. Benosman, “实时机器人技术中的全光相机”, *Int. J. Robot. Res.*, 卷. 32, 没有. 2, 第 206-217 页, 2013 年.
- [67] J. Dong, E. Nelson, V. Indelman, N. Michael 和 F. Dellaert, “使用不确定性感知期望最大化方法进行分布式实时协作定位和地图绘制”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 5807-5814 页.
- [68] R. Dubé, H. Sommer, A. Gawel, M. Bosse 和 R. Siegwart, “基于连续校正的轨迹估计的非均匀采样策略”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2016 年, 第 4792-4798 页.
- [69] H. F. Durrant-Whyte, “用于货物装卸应用的自动引导车辆”, *Int. J. Robot. Res.*, 卷. 15, 没有. 5, 第 407-440 页, 1996 年.
- [70] H. F. Durrant-Whyte 和 T. Bailey, “*IEEE Robot. Autom. Mag.*”, 第 13 卷, 第 2 期, 第 99-110 页, 2006 年 6 月.
- [71] D. Eigen 和 R. Fergus, “使用通用的多尺度卷积预测深度、表面法线和语义标签架构”, 载于 *Proc. IEEE Int. Conf. Comput. Vis.*, 2015 年, 第 2650-2658 页.
- [72] A. Elfes, “占用网格: 机器人感知和导航的概率框架”, *J. Robot. Autom.*, 第 RA-3 卷, 第 3 期, 第 249-265 页, 1987 年.
- [73] J. Engel, J. Schöps 和 D. Cremers, “LSD-SLAM: 大规模直接单目 SLAM”, *Eur. Conf. Comp. Vision*, 2014 年, 第 834-849 页.
- [74] R. M. Eustice, H. Singh, J. J. Leonard 和 M. R. Walter, “可视化绘制 RMS 泰坦尼克号: SLAM 信息的保守协方差估计”过滤器”, 第 25 卷, 第 12 期, 第 1223-1242 页, 2006 年.
- [75] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn 和 A. Zisserman, “PASCAL 视觉对象类 (VOC) 挑战”, *Int. J. Comput. Vis.*, 第 88 卷, 第 12 期. 2, 第 303-338 页, 2010 年.
- [76] N. Fairfield, G. Kantor 和 D. Wettergreen, “用于水下隧道探索的实时 SLAM 八叉树证据网格”, 第 24 卷, 第 1-2 页, 第 3-21 页, 2007 年.
- [77] N. Fairfield 和 D. Wettergreen, “使用简化模型的分段地图进行主动 SLAM 和循环预测”, 2010 年, 第 173-182 页.
- [78] H. J. S. Feder, “同步随机映射和定位”, 博士论文, 麻省理工学院机械系, 美国马萨诸塞州剑桥市. 1999.
- [79] B. Ferris, D. Fox 和 N. D. Lawrence, “使用高斯过程潜变量模型的 WiFi-SLAM”, 载于 *Proc. 20th Int. Joint Conf. Artif. Intell.*, 2007 年, 第 2480-2485 页.
- [80] A. J. Flint, D. Murray 和 I. D. Reid, “使用单目、立体和 3D 特征的曼哈顿场景理解”, 载于 *Proc. IEEE Int. Conf. Comput. Vis.*, 2011, 第 2228-2235 页.
- [81] J. Foley, A. van Dam, S. Feiner 和 J. Hughes, *Computer Graphics: Principles and Practice*. Reading, MA, 美国: Addison-Wesley, 1992.
- [82] J. Folkesson 和 H. Christensen, “户外应用的图形 SLAM”, 第 23 卷, 第 1 期, 第 51-70 页, 2006 年.
- [83] C. Forster, L. Carlone, F. Dellaert 和 D. Scaramuzza, “实时视觉惯性里程计的流形预积分”, *IEEE Trans. Robot.* [在线]. 网址: <http://ieeexplore.ieee.org/document/7557075/>
- [84] C. Forster, Z. Zhang, M. Gassner, M. Werlberger 和 D. Scaramuzza, “SVO: 单目和多摄像头系统的半直接视觉里程计”, *IEEE Trans. Robot.*, 即将出版.
- [85] D. Fox, J. Ko, K. Konolige, B. Limketkai, D. Schulz 和 B. Stewart, “分布式多机器人探索和绘图”, *Proc. IEEE*, 卷. 94, 没有. 7, 第 1325-1339 页, 2006 年 7 月.
- [86] F. Fraundorfer 和 D. Scaramuzza, “视觉里程计. 第二部分: 匹配、鲁棒性、优化和应用”, *IEEE Robot. Autom. Mag.*, 卷. 19, 没有. 2, 第 78-90 页, 2012 年 6 月.
- [87] J. Fredriksson 和 C. Olsson, “使用拉格朗日对偶性进行同步多重旋转平均”, *Proc. Asian Conf. Comput. Vis.*, 2012 年, 第 245-258 页.
- [88] U. Frese, “访谈: SLAM 解决了吗?” *KI—Künstliche Intelligenz*, 卷. 24, 没有. 3, 第 255-257 页, 2010 年.
- [89] P. Furgale, T. D. Barfoot 和 G. Sibley, “使用时间基函数的连续时间批量估计”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 2088-2095 页.
- [90] G. Gallego, J. Lund, E. Mueggler, H. Rebecq, T. Delbruck 和 D. Scaramuzza, “用于高速应用的基于事件的 6-DOF 相机跟踪”, *CoRR*, arXiv: 1607.03468, 第 1-8 页, 2016 年.
- [91] R. Garg, V. Kumar, G. Carneiro 和 I. Reid, “用于单视图深度估计的无监督 CNN: 几何救援”, *Proc. Eur. Conf. Comput. Vis.*, 2016 年, 第 740-756 页.
- [92] R. Garg, A. Roussos 和 L. Agapito, “单目视频非刚性表面的密集变形重建”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2013 年, 第 1272-1279 页.
- [93] J. J. 吉布森, *The Ecological Approach to Visual Perception, Classic ed.* Hove, U.K.: 心理学出版社, 2014.
- [94] D. Golovin 和 A. Krause, “自适应子模块性: 主动学习和随机优化中的理论和应用”, *J. Artif. Intell. Res.*, 卷. 42, 没有. 1, 第 427-486 页, 2011 年.
- [95] 谷歌. 探戈计划. 2016. [在线]. 可用: <https://www.google.com/atap/projecttango/>
- [96] V. M. Govind, “结合两个视图约束进行运动估计”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2001 年, 第 218-225 页.
- [97] O. Grasa, E. Bernal, S. Casado, I. Gil 和 J. M. M. Montiel, “手持式单目内窥镜的视觉 SLAM”, *IEEE Trans. Med. Imag.*, 卷. 33, 没有. 1, 第 135-146 页, 2014 年 1 月.
- [98] G. Grisetti, R. Kümmerle, C. Stachniss 和 W. Burgard, “基于图的 SLAM 教程”, *IEEE Intell. Transp. Syst. Mag.*, 卷. 2, 没有. 4, 第 31-43 页, 2010 年冬季.
- [99] G. Grisetti, R. Kümmerle, C. Stachniss, U. Frese 和 C. Hertzberg, “在线 2D 和 3D 映射流形的分层优化”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2010 年, 第 273-278 页.
- [100] G. Grisetti, C. Stachniss 和 W. Burgard, “高效地图学习的非线性约束网络优化”, *IEEE Trans. Intell. Transp. Syst.*, 卷. 10, 没有. 3, 第 428-439 页, 2009 年 9 月.
- [101] G. Grisetti, C. Stachniss, S. Grzonka 和 W. Burgard, “使用梯度下降有效计算最大似然图的树参数化”, *Proc. Robot.: Sci. Syst. Conf.*, 2007 年, 第 65-72 页.
- [102] J. S. Gutmann 和 K. Konolige, “大循环环境的增量映射”, *Proc. IEEE Int. Symp. Comput. Intell. Robot. Autom.*, 1999 年, 第 318-325 页.
- [103] C. Häne, C. Zach, A. Cohen, R. Angst 和 M. Pollefeys, “联合 3D 场景重建和类分割”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2013 年, 第 97-104 页.
- [104] R. Hartley, J. Trumpf, Y. Dai 和 H. Li, “旋转平均”, *Int. J. Comput. Vis.*, 卷. 103, 没有. 3, 第 267-305 页, 2013 年.
- [105] P. Henry, M. Krainin, E. Herbst, X. Ren 和 D. Fox, “RGB-D 映射: 使用深度相机对室内环境进行密集 3D 建模”, *Proc. Int. Symp. Exp. Robot.*, 2010 年, 第 477-491 页.
- [106] J. A. Heshe, D. G. Kottas, S. L. Bowman 和 S. I. Roumeliotis, “基于相机 IMU 的定位: 可观测性分析和一致性改进”, *Int. J. Robot. Res.*, 卷. 33, 没有. 1, 第 182-201 页, 2014 年.
- [107] K. L. Ho 和 P. Newman, “通过结合视觉和空间外观进行 SLAM 中的环路闭合检测”, *Robot. Auton. Syst.*, 卷. 54, 没有. 9, 第 740-749 页, 2006 年.
- [108] G. Huang, M. Kaess 和 J. J. Leonard, “图优化的一致稀疏化”, *Proc. Eur. Conf. Mobile Robots*, 2013 年, 第 150-157 页.

- [109] G. P. Huang, A. I. Mourikis and S. I. Roumeliotis, “用于 SLAM 的可观察性约束滑动窗口滤波器”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2011 年, 第 65-72 页。[110] S. Huang 和 G. Disanayake, “对同步定位和绘图当前发展的批评”, *Int. J. Adv. Robot. Syst.*, 卷. 13, 第 5 页, 2016 年, 第 1-13 页。[111] S. Huang, Y. Lai, U. Frese 和 G. Dissanayake, “SLAM 距离线性最小二乘问题有多远?” 载于 *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2010 年, 第 3011-3016 页。[112] S. Huang, H. Wang, U. Frese 和 G. Dissanayake, “关于基于点特征的 SLAM 问题的局部极小值”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 2074-2079 页。[113] P. J. Huber, *Robust Statistics*. 美国新泽西州霍博肯: Wiley, 1981。[114] IEEE RAS 地图数据表示工作组, IEEE 导航机器人地图数据表示标准, 赞助商: IEEE 机器人与自动化协会, 2016 年 6 月。IEEE。[在线的]。可用: <http://standards.ieee.org/findstds/standard/1873-2015.html> [115] V. Ila, J. M. Porta 和 J. Andrade-Cetto, “基于信息的紧凑姿势 SLAM”, *IEEE Trans. Robot.*, 卷. 26, 没有. 1, 第 78-93 页, 2010 年 2 月。[116] V. Indelman, L. Carlone 和 F. Dellaert, “连续域中的规划: 未知环境中自主导航的广义置信空间方法”, *Int. J. Robot. Res.*, 卷. 34, 没有. 7, 第 849-882 页, 2015 年。[117] V. Indelman, E. Nelson, J. Dong, N. Michael 和 F. Dellaert, “来自任意姿势和未知数据关联的增量分布式推理: 使用协作机器人建立共同参考”, *IEEE Control Syst. Mag.*, 卷. 36, 没有. 2, 第 41-74 页, 2016 年 4 月。[118] M. Irani 和 P. Anandan, “关于直接方法的一切”, *Proc. Int. Workshop Vis. Algorithms: Theory Practice*, 1999 年, 第 267-277 页。[119] J. J. Achnik, R. A. Newcombe 和 A. J. Davison, “用于增强平面镜面反射的实时表面光场捕获”, *Proc. IEEE ACM Int. Symp. Mixed Augmented Reality*, 2012 年, 第 91-97 页。[120] H. Johannsson, M. Kaess, M. Fallon 和 J. J. Leonard, “使用简化姿态图的时间可扩展视觉 SLAM”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 54-61 页。[121] J. Johnson, R. Krishna, M. Stark, J. Li, M. Bernstein 和 L. Fei-Fei, “使用场景图进行图像检索”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015 年, 第 3668-3678 页。[122] V. A. M. Jorge et al., “Ouroboros: 利用未探索区域的势场来闭合循环”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 2125-2131 页。[123] L. P. Kaelbling, M. L. Littman 和 A. R. Cassandra, “在部分可观察的随机域中进行规划和行动”, *Artif. Intell.*, 卷. 101, 没有. 12, 第 99-134 页, 1998。[124] M. Kaess, “无限平面的同步定位和建图”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 4605-4611 页。[125] M. Kaess, H. Johannsson, R. Roberts, V. Ila, J. J. Leonard 和 F. Dellaert, “iSAM2: 使用贝叶斯树进行增量平滑和映射”, *Int. J. Robot. Res.*, 卷. 31, 第 217-236 页, 2012 年。[126] M. Kaess, A. Ranganathan 和 F. Dellaert, “iSAM: 增量平滑和映射”, *IEEE Trans. Robot.*, 卷. 24, 没有. 6, 第 1365-1378 页, 2008 年 12 月。[127] M. Keidar 和 G. A. Kaminka, “机器人探索的有效前沿检测”, *Int. J. Robot. Res.*, 卷. 33, 没有. 2, 第 215-236 页, 2014 年。[128] A. Kelly, *Mobile Robotics: Mathematics, Models, and Methods*. 英国剑桥, 剑桥大学 Press, 2013。[129] A. Kendall, M. Grimes 和 R. Cipolla, “PoseNet: 用于实时 6-DOF 相机重定位的卷积网络”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2015 年, 第 2938-2946 页。[130] K. Khosroussi, S. Huang 和 G. Dissanayake, “利用 SLAM 的可分离结构”, *Proc. Robot.: Sci. Syst. Conf.*, 2015 年, 第 208-218 页。[131] A. Kim 和 R. M. Eustice, “使用视觉显著性进行自主水下船体检查的实时视觉 SLAM”, *IEEE Trans. Robot.*, 卷. 29, 没有. 3, 第 719-733 页, 2013 年 6 月。[132] H. Kim, S. Leutenegger 和 A. J. Davison, “使用事件相机进行实时 3D 重建和 6-DoF 跟踪”, *Proc. Eur. Conf. Comput. Vis.*, 2016 年, 第 349-364 页。[133] J. H. Kim, C. Cadena 和 I. D. Reid, “卷帘快门相机的直接半密集 SLAM”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2016 年 5 月, 第 1308-1315 页。[134] V. G. Kim, S. Chaudhuri, L. Guibas 和 T. Funkhouser, “Shape2Pose: 以人为中心的形状分析”, *ACM Trans. Graphics*, 卷. 33, 没有. 4, 第 120:1-120:12 页, 2014 年。[135] G. Klein 和 D. Murray, “小型 AR 工作空间的并行跟踪和映射”, *Proc. IEEE ACM Int. Symp. Mixed Augmented Reality*, 2007 年, 第 225-234 页。[136] M. Klingensmith, I. Dryanovski, S. Srinivasa 和 J. Xiao, “Chisel: 使用空间散列符号距离场在移动设备上实时大规模 3D 重建”, *Proc. Robot.: Sci. Syst. Conf.*, 2015 年, 第 367-376 页。[137] J. Knuth 和 P. Barooah, “通过黎曼优化实现异构机器人测量的协作定位”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 1534-1539 页。[138] J. Knuth 和 P. Barooah, “噪声相对姿态测量中位置估计的误差增长”, *Robot. Auton. Syst.*, 卷. 61, 没有. 3, 第 229-224 页, 2013 年。[139] D. G. Kottas, J. A. Hesch, S. L. Bowman 和 S. I. Roumeliotis, “关于视觉辅助惯性导航的一致性”, *Proc. Int. Symp. Exp. Robot.*, 2012 年, 第 303-317 页。[140] T. Krajník, J. P. Fentanes, O. M. Mozos, T. Duckett, J. Ekekrantz 和 M. Hanheide, “使用频谱图在动态环境中服务机器人的长期拓扑定位”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2014 年, 第 4537-4542 页。[141] H. Kretschmar, C. Stachniss 和 G. Grisetti, “使用激光测距仪对基于图的 SLAM 进行有效的信息理论图修剪”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2011 年, 第 865-871 页。[142] R. G. Krishnan, U. Shalit 和 D. Sontag, “深度卡尔曼滤波器”, *NIPS 2016 Workshop: Advances in Approximate Bayesian Inference*, 第 1-7 页, 2016。[143] F. R. Kschischang, B. J. Frey 和 H. A. Loeliger, “因子图和和积算法”, *IEEE Trans. Infor. Theory*, 第 1 卷. 47, 没有. 2, 第 498-519 页, 2001 年 2 月。[144] B. Kueng, E. Mueggler, G. Gallego 和 D. Scaramuzza, “使用基于事件的特征轨迹的低延迟视觉里程计”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2016 年, 第 16-23 页。[145] 库卡机器人, 库卡导航解决方案, 2016。[在线]。可用: http://www.kuka-robotics.com/res/robotics/Products/PDF/EN/KUKA_Navigation_Solution_EN.pdf。[146] R. Kümmerle, G. Grisetti, H. Strasdat, K. Konolige 和 W. Burgard, “g2o: 图优化的通用框架”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2011 年, 第 3607-3613 页。[147] A. Kundu, Y. Li, F. Dellaert, F. Li 和 J. M. Rehg, “单目视频的联合语义分割和 3D 重建”, *Proc. Eur. Conf. Comput. Vis.*, 2014 年, 第 703-718 页。[148] K. Lai, L. Bo 和 D. Fox, “3D 场景标记的无监督特征学习”, *Proc. IEEE Int. Conf. Robot. Autom. (ICRA)*, 2014。[149] K. Lai 和 D. Fox, “使用 Web 数据和域适应的 3D 点云中的对象识别”, *Int. J. Robot. Res.*, 卷. 29, 没有. 8, 第 1019-1037 页, 2010 年。[150] Y. Latif, C. Cadena 和 J. Neira, “姿势图 slam 随时间推移的鲁棒循环闭合”, *Int. J. Robot. Res.*, 卷. 32, 没有. 14, 第 1611-1626 页, 2013 年。[151] M. T. Lazaro, L. Paz, P. Pinies, J. A. Castellanos 和 G. Grisetti, “使用压缩测量的多机器人 SLAM”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2013 年, 第 1069-1076 页。[152] C. Leung, S. Huang 和 G. Dissanayake, “使用模型预测控制和基于吸引子的探索的主动 SLAM”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2006 年, 第 5026-5031 页。[153] C. Leung, S. Huang, N. Kwok 和 G. Dissanayake, “使用模型预测控制进行信息收集的不确定性下的规划”, *Robot. Auton. Syst.*, 卷. 54, 没有. 11, 第 898-910 页, 2006 年。[154] J. Levinson, “自动驾驶车辆的自动激光校准、绘图和定位”, 博士论文, 计算系, Sci., 斯坦福大学, 2011。[155] C. Li et al., “RGBW 彩色 VGA 滚动和全局快门动态和活动像素视觉传感器的设计”, 载于 *Proc. IEEE Int. Symp. Circuits Syst.*, 2015 年, 718-721。[156] P. Lichtsteiner, C. Posch 和 T. Delbruck, “128×128 120 dB 15 μ s 延迟异步时间对比视觉传感器”, *IEEE J. Solid-State Circuits*, 卷. 43, 没有. 2, 第 566-576 页, 2008 年 2 月。[157] J. J. Lim, H. Pirsiavash 和 A. Torralba, “解析宜家物体: 精细姿势估计”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2013 年, 第 2992-2999 页。[158] F. Liu, C. Shen 和 G. Lin, “用于从单个图像进行深度估计的深度卷积神经网络”, 载于 *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015 年, 第 5162-5170 页。[159] M. Liu, S. Huang, G. Dissanayake 和 H. Wang, “基于凸优化的姿态 SLAM 问题方法”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2012 年, 第 1898-1903 页。[160] S. Lowry et al., “视觉地点识别: 一项调查”, *IEEE Trans. Robot.*, 卷. 32, 没有. 1, 第 1-19 页, 2016 年 2 月。[161] F. Lu 和 E. Milios, “环境测绘的全局一致范围扫描对齐”, *Auton. Robots*, 卷. 4, 没有. 4, 第 333-349 页, 1997 年。

- [162] Y. Lu 和 D. Song, “使用异构地标和无监督几何约束的视觉导航”, *IEEE Trans. Robot.*, 卷. 31, 没有. 3, 第 736–749 页, 2015 年 6 月。
- [163] S. Lynen, T. Sattler, M. Bosse, J. Hesch, M. Pollefeys 和 R. Siegwart, “走出我的实验室: 大规模实时视觉惯性定位”, *Proc. Robot., Sci. Syst. Conf.*, 2015 年, 第 338–347 页。
- [164] D.J.C. 麦凯, *Information Theory, Inference & Learning Algorithms*. 英国剑桥: 剑桥大学出版社, 2002 年。
- [165] M. Magnabosco 和 T. P. Breckon, “具有传感器切换的跨光谱视觉同步定位和映射 (slam)”, *Robot. Auton. Syst.*, 卷. 61, 没有. 2, 第 195–208 页, 2013 年。
- [166] M. Maimone, Y. Cheng 和 L. Matthies, “火星探测车视觉里程计的两年”, *J. Field Robot.*, 24, 第 1 期. 3, 第 169–186 页, 2007 年。
- [167] L. Marques, U. Nunes 和 A. T. de Almeida, “基于嗅觉的移动机器人导航”, *Thin Solid Films*, 卷. 418, 没有. 1, 第 51–58 页, 2002 年。
- [168] D. Martinec 和 T. Pajdla, “多视图重建中的鲁棒旋转和平移估计”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2007 年, 第 1–8 页。
- [169] R. Martinez-Cantin, N. de Freitas, E. Brochu, J. Castellanos 和 A. Doucet, “利用视觉引导移动机器人实现最佳在线感知和规划的贝叶斯探索-利用方法”, *Auton. Robots*, 卷. 27, 没有. 2, 第 93–103 页, 2009 年。
- [170] M. Mazuran, W. Burgard 和 G. D. Tipaldi, “长期 SLAM 的非线性因子恢复”, *Int. J. Robot. Res.*, 卷. 35, 没有. 1–3, 第 50–72 页, 2016 年。
- [171] J. 孟德尔, *Lessons in Estimation Theory for Signal Processing, Communications, and Control*. 美国新泽西州恩格尔伍德悬崖: Prentice-Hall, 1995。
- [172] P. Merrell 和 D. Manocha, “模型综合: 通用过程建模算法”, *IEEE Trans. Vis. Comput. Graph.*, 卷. 17, 没有. 6, 第 715–728 页, 2010 年 6 月。
- [173] M. J. Milford 和 G. F. Wyeth, “SeqSLAM: 阳光明媚的夏日和暴风雨的冬夜基于视觉路线的导航”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 1643–1649 页。
- [174] J. M. M. Montiel, J. Civera 和 A. J. Davison, “单目 SLAM 的统一逆深度参数化”, *Proc. Robot., Sci. Syst. Conf.*, 2006 年 8 月, 第 81–88 页。
- [175] A. I. Mourikis 和 S. I. Roumeliotis, “用于视觉辅助惯性导航的多状态约束卡尔曼滤波器”, *Proc. IEEE Int. Conf. Robot. Autom. (ICRA)*, 第 3565–3572 页. IEEE, 2007。
- [176] O. M. Mozos, R. Triebel, P. Jensfelt, A. Rottmann 和 W. Burgard, “使用从传感器数据中提取的信息对地点进行监督语义标记”, *Robot. Auton. Syst.*, 卷. 55, 没有. 5, 第 391–402 页, 2007 年。
- [177] E. Mueggler, G. Gallego 和 D. Scaramuzza, “基于事件的视觉传感器的连续时间轨迹估计”, 见 *Proc. Robot.: Sci. Syst. Conf.*, 2015 年。
- [178] E. Mueller, A. Censi 和 E. Frazzoli, “低延迟航向反馈”使用高效近似增量推理对神经形态视觉传感器进行控制”, 见 *Proc. IEEE Conf. Decision Control (CDC)*, 第 992–999 页. IEEE, 2015。
- [179] R. Mur-Artal, J. M. M. Montiel 和 J. D. Tardós, “ORB-SLAM: 一种多功能且精确的单目 SLAM 系统”, *IEEE Trans. Robot.*, 卷. 31, 没有. 5, 第 1147–1163 页, 2015 年。
- [180] J. Neira 和 J. D. Tardós, “使用联合兼容性测试的随机映射中的数据关联”, *IEEE Trans. Robot. Autom.*, 卷. 17, 没有. 6, 第 890–897 页, 2001。
- [181] E. D. Nerurkar, S. I. Roumeliotis 和 A. Martinelli, “多机器人协作定位的分布式最大后验估计”, 见 *Proc. IEEE Int. Conf. Robot. Autom.*, 第 1402–1409 页, 2009。
- [182] R. Newcombe, D. Fox 和 S. M. Seitz, “DynamicFusion: 实时非刚性场景重建和跟踪”, 见 *Proc. IEEE Conf. Comput. Vision Pattern Recog.*, 第 343–352 页, 2015。
- [183] R. A. Newcombe et al., “KinectFusion: 实时密集表面映射和跟踪”, 见 *IEEE/ACM Int. Symp. Mixed Augmented Reality*, 第 343–352 页. 1 27–136, 瑞士巴塞尔, 2011 年 10 月。
- [184] R. A. Newcombe, S. J. Lovegrove 和 A. J. Davison, “DTAM: 实时密集跟踪和地图绘制”, 载于 *Proc. IEEE Int. Conf. Comput. Vision*, 第 2320–2327 页, 2011 年。
- [185] P. Newman, J. J. Leonard, J. D. Tardos 和 J. Neira, “探索与回归: 实时并发映射和定位的实验验证”, *Proc. IEEE Int. Conf. Robot. Autom.*, 第 1802–1809 页, 2002 年。
- [186] R. Ng, M. Levoy, M. Bredif, G. Duval, M. Horowitz 和 P. Hanrahan, “手持式全光相机的光场摄影”, Dept. Comp. 科学, 斯坦福大学, 斯坦福, 加利福尼亚州, 美国, 技术. Rep. CSTR 2005-02, 2005。
- [187] K. Ni 和 F. Dellaert, “使用嵌套解剖的基于多层子图的 SLAM”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2010 年, 第 2558–2565 页。
- [188] M. Nießner, M. Zollhöfer, S. Izadi 和 M. Stamminger, “使用体素哈希进行大规模实时 3D 重建”, *ACM Trans. Graphics*, 卷. 32, 没有. 6, 第 169:1–169:11, 2013 年 11 月。
- [189] D. Nistér 和 H. Stewénius, “使用词汇树进行可扩展识别”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2006 年, 第 1 卷. 2, 第 2161–2168 页。
- [190] A. 纽赫特, *3D Robotic Mapping: The Simultaneous Localization and Mapping Problem With Six Degrees of Freedom*, 卷. 52. 美国纽约州纽约: Springer, 2009。
- [191] E. Olson 和 P. Agarwal, “鲁棒机器人绘图混合网络推理”, *Int. J. Robot. Res.*, 卷. 32, 没有. 7, 第 826–840 页, 2013 年。
- [192] E. Olson, J. J. Leonard 和 S. Teller, “初始估计较差的姿态图的快速迭代对齐”, 见 *Proc. IEEE Int. Conf. Robot. Autom.*, 2006 年, 第 2262–2269 页。
- [193] 开放地理空间联盟 (OGC), CityGML 2.0. 0., 2016 年 6 月。[在线]。可用: <http://www.citygml.org/>
- [194] 开放地理空间联盟 (OGC), OGC IndoorGML 标准, 2016 年 6 月。[在线]。可用: <http://www.opengeospatial.org/standards/indoorgml>
- [195] S. Patil, G. Kahn, M. Laskey, J. Schulman, K. Goldberg 和 P. Abbeel, “通过无协方差轨迹优化和自动微分扩展高斯信念空间规划”, *Proc. Int. Workshop Algorithmic Found. Robot.*, 2015 年, 第 515–533 页。
- [196] A. Patron-Perez, S. Lovegrove 和 G. Sibley, “传感器融合和卷帘快门相机的基于样条的轨迹表示”, *Int. J. Comput. Vis.*, 卷. 113, 没有. 3, 第 208–219 页, 2015 年。
- [197] L. Paull, G. Huang, M. Seto 和 J. J. Leonard, “通信约束的多 AUV 协作 SLAM”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 509–516 页。
- [198] A. Pázmán, *Foundations of Optimum Experimental Design*. 美国纽约州: Springer, 1986。
- [199] J. R. Peters, D. Borra, B. Paden 和 F. Bullo, “三维位移组上的传感器网络定位”, *SIAM J. Control Optim.*, 卷. 53, 没有. 6, 第 3534–3561 页, 2015 年。
- [200] C. J. Phillips, M. Lecce, C. Davis 和 K. Daniilidis, “抓取旋转表面: 从两个视图中同步姿势和形状恢复”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 1352–1359 页。
- [201] S. Pillai 和 J. J. Leonard, “单目 SLAM 支持的对象识别”, *Proc. Robot., Sci. Syst. Conf.*, 2015 年, 第 310–319 页。
- [202] G. Piovan, I. Shames, B. Fidan, F. Bullo 和 B. Anderson, “相对传感网络的框架和方向定位”, *Automatica*, 卷. 49, 没有. 1, 第 206–213 页, 2013 年。
- [203] M. Pizzoli, C. Forster 和 D. Scaramuzza, “REMODE: 实时概率、单目密集重建”, 载于 *Proc. IEEE Int. Conf. Robot. Autom.*, 2014 年, 第 2609–2616 页。
- [204] L. Polok, V. Ila, M. Solony, P. Smrz 和 P. Zemcik, “机器人中非线性最小二乘的增量块乔列斯基分解”, *Proc. Robot., Sci. Syst. Conf.*, 2013 年, 第 328–336 页。
- [205] C. Posch, D. Matolin 和 R. Wohlgenannt, “一种基于时间的异步图像传感器”, *Proc. IEEE Int. Symp. Circuits Syst.*, 2008 年, 第 2130–2133 页。
- [206] A. Pronobis 和 P. Jensfelt, “大规模语义映射和异质模式推理”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 3515–3522 页。
- [207] H. Rebecq, T. Horstschaefer, G. Gallego 和 D. Scaramuzza, “EVO: 基于事件的 6-DOF 并行实时跟踪和绘图的几何方法”, *IEEE Robot. Autom. Lett.*, 即将出版。
- [208] A. Rényi, “关于熵和信息的度量”, 载于 *Proc. 4th Berkeley Symp. Math. Statist. Prob.*, 1960 年, 第 547–561 页。
- [209] A. G. Requicha, “刚性固体的表示: 理论、方法和系统”, *ACM Comput. Surveys*, 卷. 12, 没有. 4, 第 437–464 页, 1980 年。
- [210] L. Riazuelo, J. Civera 和 J. M. M. Montiel, “C2TAM: 协作跟踪和绘图的云框架”, *Robot. Auton. Syst.*, 卷. 62, 没有. 4, 第 401–413 页, 2014 年。
- [211] D. M. Rosen, C. DuHadway 和 J. J. Leonard, “同时定位和映射中近似全局优化的凸松弛”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 5822–5829 页。

- [212] D. M. Rosen, M. Kaess 和 J. J. Leonard, “稀疏因子图上的鲁棒增量在线推理: 超越高斯情况”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2013 年, 第 1025-1032 页。[213] O. Russakovsky et al., “ImageNet 大规模视觉识别挑战”, *Int. J. Comput. Vis.*, 卷. 115, 没有. 3, 第 211–252 页, 2015 年。[214] S. Agarwal et al., 谷歌. 谷神星求解器. 2016 年 6 月。[在线]. 可用: <http://ceres-solver.org> [215] D. Sabatta, D. Scaramuzza 和 R. Siegwart, “使用词汇树在相似和动态环境中改进基于外观的匹配”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2010 年, 第 1008-1013 页。[216] S. Saeedi, M. Trentini, M. Seto 和 H. Li, “多机器人同时定位和建图: 综述”, *J. Field Robot.*, 卷. 33, 没有. 1, 第 3-46 页, 2016 年。[217] R. Salas-Moreno, R. Newcombe, H. Strasdat, P. Kelly 和 A. Davison, “SLAM++: 对象级别的同步定位和建图”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2013 年, 第 1352-1359 页。[218] D. Scaramuzza 和 F. Fraundorfer, “视觉里程计[教程]. 第一部分: 前 30 年和基础知识”, *IEEE Robot. Autom. Mag.*, 卷. 18, 没有. 4, 第 80-92 页, 2011 年 6 月。[219] S. Sengupta 和 P. Sturgess, “语义八叉树: 通过八叉树约束的高阶 MRF 统一识别、重建和表示”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 1874-1879 页。[220] J. Shah 和 M. Mäntylä, *Parametric and Feature-Based CAD/CAM: Concepts, Techniques, and Applications*. 美国新泽西州霍博肯: Wiley, 1995。[221] V. Shapiro, “实体建模”, 载于 *Handbook of Computer Aided Geometric Design*, G. E. Farin, J. Hoschek 和 M. S. Kim 编辑. 荷兰阿姆斯特丹: Elsevier, 2002 年, 第 1 章. 20, 第 473-518 页。[222] C. Shen, J. F. O’ Brien 和 J. R. Shewchuk, “从多边形场中插值和逼近隐式曲面.” *Proc. ACM SIGGRAPH*, 2004 年, 第 896-904 页。[223] G. Sibley, C. Mei, I. D. Reid 和 P. Newman, “自适应束调整”, *Proc. Robot., Sci. Syst. Conf.*, 2009 年, 第 177-184 页。[224] A. Singer, “特征向量和半定规划的角度同步”, *Appl. Comput. Harmonic Anal.*, 卷. 30, 没有。[225] A. Singer 和 Y. Shkolnisky, “通过特征向量和半定规划从 Cryo-EM 中的公共线确定三维结构”, *SIAM J. Imag. Sci.*, 卷. 1, 第 20-36 页, 2010 年。4, 没有. 2, 第 543–572 页, 2011 年。[226] J. Sivic 和 A. Zisserman, “Video Google: 视频中对象匹配的文本检索方法”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2003 年, 第 1470–1477 页。[227] B. M. Smith, L. Zhang, H. Jin 和 A. Agarwala, “光场视频稳定”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2009 年, 第 341-348 页。[228] S. Soatto, “走向视觉信息理论的步骤: 主动感知、信号到符号转换以及传感与控制之间的相互作用”, *CoRR*, arXiv: 1110.2053, 第 1-214 页, 2011。[229] S. Soatto 和 A. Chiuso, “视觉表示: 定义属性和深度近似”, *CoRR*, arXiv: 1411.7676, 第 1-20 页, 2016 年。[230] L. Song, B. Boots, S. M. Siddiqi, G. J. Gordon 和 A. J. Smola, “隐马尔可夫模型的希尔伯特空间嵌入”, 见 *Proc. Int. Conf. Mach. Learning*, 2010 年, 第 127 页. 991–998。[231] N. Srinivasan, L. Carlone 和 F. Dellaert, “用于场景重建和理解的运动的结构对称性”, 载于 *Proc. Brit. Mach. Vis. Conf.*, 2015 年, 第 1-13 页。[232] C. Stachniss, *Robotic Mapping and Exploration*. 美国纽约: Springer, 2009。[233] C. Stachniss, G. Grisetti 和 W. Burgard, “使用 Rao-Blackwellized 粒子滤波器进行基于信息增益的探索”, *Proc. Robot., Sci. Syst. Conf.*, 2005 年, 第 65-72 页。[234] C. Stachniss, S. Thrun 和 J. J. Leonard, “同步定位和绘图”, 载于 *Springer Handbook of Robotics*, B. Siciliano 和 O. Khatib 主编, 第 2 版. 美国纽约州纽约: Springer, 2016 年, 第 1 章. 46, 第 1153–1176 页。[235] H. Strasdat, A. J. Davison, J. M. M. Montiel 和 K. Konolige, “恒定时间视觉 SLAM 的双窗口优化”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2011 年, 第 2352-2359 页。[236] H. Strasdat, J. M. M. Montiel 和 A. J. Davison, “视觉 SLAM: 为什么要过滤?” *Comput. Vis. Image Understanding*, 卷. 30, 没有. 2, 第 65–77 页, 2012 年。[237] C. Strub, F. Worgotter, H. Ritterz 和 Y. Sandamirskaya, “在物体形状的触觉探索过程中校正姿势估计: 神经机器人研究”, *Proc. Int. Conf. Develop. Learning Epigenetic Robot.*, 2014 年, 第 26–33 页。[238] N. Sünderhauf 和 P. Protzel, “迈向姿势图 SLAM 的稳健后端”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2012 年, 第 1254-1261 页。[239] S. Thrun, “主动学习中的探索”, 载于 *Handbook of Brain Science and Neural Networks*, M. A. Arbib, Ed. 美国马萨诸塞州剑桥: 麻省理工学院出版社, 1995 年, 第 381–384 页。[240] S. Thrun, W. Burgard 和 D. Fox, *Probabilistic Robotics*. 美国马萨诸塞州剑桥: 麻省理工学院出版社, 2005 年。[241] S. Thrun 和 M. Montemerlo, “GraphSLAM 算法及其在城市结构大规模测绘中的应用”, *Int. J. Robot. Res.*, 卷. 25, 没有. 5-6, 第 403-430 页, 2005 年。[242] G. D. Tipaldi 和 K. O. Arras, “二维范围数据的调情兴趣区域”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2010 年, 第 3616-3622 页。[243] C. H. Tong, P. Furgale 和 T. D. Barfoot, “用于非参数同时定位和映射的高斯过程高斯-牛顿”, *Int. J. Robot. Res.*, 卷. 32, 没有. 5, 第 507-525 页, 2013 年。[244] B. Triggs, P. McLauchlan, R. Hartley 和 A. Fitzgibbon, “束调整——现代综合”, 载于 *Vision Algorithms: Theory and Practice*, W. Triggs, A. Zisserman 和 R. Szeliski, 编辑. 美国纽约州纽约: Springer, 2000 年, 第 298–375 页。[245] R. Tron, B. Afsari 和 R. Vidal, “SO(3) 的内在共识, 几乎具有全局收敛性”, *Proc. IEEE Conf. Decision Control*, 2012 年, 第 2052–2058 页。[246] R. Valencia, J. Vallvé, G. Dissanayake 和 J. Andrade-Cetto, “主动姿势 SLAM”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2012 年, 第 1885-1891 页。[247] J. Valentin, M. Nienner, J. Shotton, A. Fitzgibbon, S. Izadi 和 P. Torr, “利用回归森林中的不确定性实现精确的相机重新定位”, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015 年, 第 4400-4408 页。[248] I. Vallivaara, J. Haverinen, A. Kemppainen 和 J. Rönning, “使用环境磁场进行同步定位和绘图”, 载于 *Proc. IEEE Conf. Multisensor Fusion Integration Intell. Syst.*, 2010 年, 第 4-19 页。[249] J. Vallvé 和 J. Andrade-Cetto, “移动机器人探索的潜在信息领域”, *Robot. Auton. Syst.*, 卷. 69, 第 68-79 页, 2015 年。[250] J. van den Berg, S. Patil 和 R. Alterovitz, “在置信空间中使用迭代局部优化的不确定性下的运动规划”, *Int. J. Robot. Res.*, 卷. 31, 没有. 11, 第 1263–1278 页, 2012。[251] V. Vineet et al., “用于大规模语义场景重建的增量密集语义立体融合”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2015 年, 第 75–82 页。[252] N. Wahlström, T. B. Schön 和 M. P. Deisenroth, “从图像像素学习深度动态模型”, *Proc. IFAC Symp. Syst. Identification*, 2015 年, 第 1059-1064 页。[253] C. C. Wang, C. Thorpe, S. Thrun, M. Hebert 和 H. F. Durrant-Whyte, “同时定位、地图绘制和移动对象跟踪”, *Int. J. Robot. Res.*, 卷. 26, 没有. 9, 第 889–916 页, 2007 年。[254] L. Wang 和 A. Singer, “精确稳定的旋转恢复以实现稳健的同步”, *Inf. Inference, J. IMA*, 卷. 2, 没有. 2, 第 145–193 页, 2013 年。[255] Z. Wang, S. Huang 和 G. Dissanayake, *Simultaneous Localization and Mapping: Exactly Sparse Information Filters*. 新加坡: 世界科学, 2011 年。[256] J. W. Weingarten, G. Gruener 和 R. Siegwart, “用于机器人导航的最先进的 3D 传感器”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2004 年, 第 2155-2160 页。[257] T. Whelan, S. Leutenegger, R. F. Salas-Moreno, B. Glocker 和 A. J. Davison, “ElasticFusion: 无姿态图的密集 SLAM”, 载于 *Proc. Robot.: Sci. Syst. Conf.*, 2015 年。[258] T. Whelan, J. B. McDonald, M. Kaess, M. F. Fallon, H. Johansson 和 J. J. Leonard, “Kintinously: 空间扩展的 kinect 融合”, *Proc. RSS Workshop RGB-D: Adv. Reasoning Depth Cameras*, 2012 年。[259] S. Williams, V. Indelman, M. Kaess, R. Roberts, J. J. Leonard 和 F. Dellaert, “并发过滤和平滑: 用于实时导航和完全平滑的并行架构”, *Int. J. Robot. Res.*, 第 1 卷. 33, 没有. 12, 第 1544–1568 页, 2014 年。[260] R. W. Wolcott 和 R. M. Eustice, “自动城市驾驶 LIDAR 地图中的视觉定位”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2014 年, 第 176–183 页。[261] R. Wood, RoboBees 项目, 2015 年 6 月。[在线]. 可用: <http://robobeas.seas.harvard.edu/> [262] B. Yamauchi, “基于前沿的自主探索方法”, *Proc. IEEE Int. Symp. Comput. Intell. Robot. Autom.*, 1997 年, 第 146-151 页。[263] K.-T. Yu, A. Rodriguez 和 J. J. Leonard, “触觉探索: 平面推动的形状和姿势恢复”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2015 年, 第 1208-1215 页。

[264] C. Zach, T. Pock 和 H. Bischof, “鲁棒 TV-L1 范围图像集成的全局最优算法”, *Proc. IEEE Int. Conf. Comput. Vis.*, 2007 年, 第 1-8 页。[265] J. Zhang, M. Kaess 和 S. Singh, “基于优化的状态估计问题的简并性”, *Proc. IEEE Int. Conf. Robot. Autom.*, 2016 年, 第 809-816 页。[266] S. Zhang, Y. Zhan, M. Dewan, J. Huang, D. Metaxas, X. Zhou, “走向稳健有效的形状建模: 稀疏形状组合”, *Med. Image Anal.*, 卷. 16, 没有. 1, 第 265-277 页, 2012 年。[267] L. Zhao, S. Huang 和 G. Dissanayake, “线性 SLAM: 基于子图连接的基于特征和姿态图 SLAM 的线性解决方案”, *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2013 年, 第 24-30 页。



塞萨尔·卡德纳 (Cesar Cadena) 获得博士学位。2011 年, 获得西班牙萨拉戈萨萨拉戈萨大学计算机科学博士学位。

他是瑞士苏黎世联邦理工学院自治系统实验室的高级研究员。他的研究兴趣包括机器人场景理解的感知领域, 包括几何学和语义学, 包括语义映射、数据关联、位置识别和动态环境中的持久映射。



卢卡·卡隆 (Luca Carlone) 获得博士学位。2012 年获得意大利都灵都灵理工大学机电一体化博士学位。

他是美国马萨诸塞州剑桥市麻省理工学院 (MIT) 信息与决策系统实验室的研究科学家。在加入麻省理工学院之前, 他于 2013 年至 2015 年在美国佐治亚州亚特兰大佐治亚理工学院工程学院担任博士后研究员。他的研究兴趣包括非线性和分布式优化、概率分布优化、

参考、决策

应用于单机器人和多机器人系统的传感、感知和控制。



亨利·卡里略 (Henry Carrillo) 获得工程学士学位 2007 年获得哥伦比亚巴兰基亚北方大学电子工程学位; 硕士学位 2010 年, 获得哥伦比亚波哥大哈维里亚纳天主教大学电子工程学位; 和博士学位。2014 年获得西班牙萨拉戈萨大学计算机科学博士学位。

他是哥伦比亚波哥大 Sergio Arboleda 大学 Escuela de Ciencias Exactas e Ingenierías 的副教授。他的研究兴趣包括自主系统的绘图和定位问题。



Yasir Latif 于 2009 年获得德国慕尼黑工业大学通信工程硕士学位, 并于 2009 年获得德国慕尼黑工业大学通信工程博士学位。2014 年获得西班牙萨拉戈萨萨拉戈萨大学计算机科学博士学位。

他是澳大利亚南澳州阿德莱德市阿德莱德大学的高级研究员。他的主要研究领域包括同步定位和绘图, 特别关注长期鲁棒性。他的研究兴趣包括语义理解和视觉推理。



Davide Scaramuzza 1980 年出生于意大利。瑞士苏黎世联邦理工学院机器人和计算机视觉学位。他是 ETH 和宾夕法尼亚大学 (美国宾夕法尼亚州费城) 的博士后。

他是瑞士苏黎世苏黎世大学的机器人学教授, 研究机器人技术和计算机视觉的交叉点。

Scaramuzza 博士因其研究贡献而获得了 SNSF-ERC 启动资助、IEEE 机器人和自动化早期职业奖以及 Google 研究奖。



José Neira 于 1986 年在哥伦比亚波哥大洛桑第斯大学获得计算机科学和系统工程学位, 并于 1999 年在哥伦比亚大学获得博士学位。1993 年获得西班牙萨拉戈萨大学计算机科学博士学位。

自 2010 年起, 他担任西班牙萨拉戈萨大学计算机科学与工程系正教授。他的研究兴趣包括自主机器人、计算机视觉和人工智能。



伊恩·里德 (Ian Reid) 获得理学学士学位 1987 年获得澳大利亚珀斯西澳大利亚大学博士学位 (荣誉), 1992 年获得英国牛津大学博士学位。

他目前是澳大利亚南澳州阿德莱德市阿德莱德大学的计算机科学教授和 ARC 澳大利亚桂冠研究员。在 2012 年移居澳大利亚之前, 他是英国牛津大学的工程科学教授。他的大部分研究都是在计算机视觉和机器人技术之间的边界进行的。

兼任机器人视觉多机构协作卓越中心副主任。他的重大贡献包括主动视觉、视觉跟踪、SLAM 和人体动作捕捉方面的工作。



John J. Leonard (F'14) 获得 B.S.E.E. 1987 年获得美国宾夕法尼亚州费城宾夕法尼亚大学电气工程与科学学士学位, 并于 1987 年获得博士学位。1994 年获得英国牛津大学工程科学博士学位。

他是美国马萨诸塞州剑桥市麻省理工学院机械工程系 Samuel C. Collins 教授。他的研究解决了自主移动机器人的导航和地图绘制问题。